

Activación Endógena mediante Homeostasis Epistémica en Sistemas Multi-Agente Basados en LLMs

¿Puede la coherencia en un debate multi-agente sostenerse endógenamente — no impuesta por un planificador, sino emergente del estado regulatorio de cada agente?

Patricio Julián Gerpe · Universidad de Buenos Aires

Los frameworks contemporáneos (AutoGen, MetaGPT, LangGraph) externalizan la activación: un orquestador decide **cuándo** habla cada agente. Esto desacopla la participación de la presión epistémica que el agente acumula. ¿Qué pasa si la activación **emerge del estado interno** del agente — como la homeostasis biológica — en vez de ser programada externamente? Presentamos **EPR** (Ecuación Pro-Acción Reducida), la reducción escalar del operador Pro-Action Γ ($n=1$), sin Q-learning.

1 El problema: colapso de contexto

En deliberación adversarial extendida, los agentes LLM pierden registro de argumentos previos, repiten puntos o producen monólogos desconectados — el **colapso de contexto**. En debates competitivos cada argumento presupone los anteriores: esta pérdida no degrada el debate, lo **invalida**.

Los orquestadores exógenos (LangGraph, AutoGen) rutean turnos según el estado del flujo, no seg&u;n la presión epistémica del agente. Un agente que acumula contra-argumentos sin responder espera pasivamente hasta que el scheduler lo elige.

! **Ashby's law: un regulador debe modelar la variedad de lo que controla. La activación exógena no ve el estado interno del agente.**

3 Background: orquestación exógena

AutoGen (Wu et al. 2023), **CAMEL** (Li et al. 2023) y **MetaGPT** (Hong et al. 2023) estructuran interacciones mediante grafos de control y enrutadores centralizados. **LangGraph** añadió estado durable y transiciones condicionales, dando al orquestador mayor expresividad.

El paradigma **heartbeat** (OpenClaw 2025) incorporó persistencia temporal mediante activación periódica con memoria entre latidos. **D2A** (Wang et al. 2025) reconoce que el estado interno debería importar, pero no cierra el lazo: carece de señal explícita de calidad que module la activación.

En todos estos casos, la decisión de cuándo participa cada agente queda fijada por el diseñador, no emerge del agente mismo.

2 Motivación: homeostasis epistémica

La biología describe cómo los sistemas regulan desequilibrios sin control externo: variables internas acumulan tensión, desencadenan respuesta y retoman al equilibrio (**homeostasis**, Sterling & Eyer 1988). HRRL (Keramati & Gutkin 2014) formalizó esto derivando la recompensa como reducción de impulso.

Analogía estructural: donde un organismo acumula hambre y actúa para reducirla, un agente deliberativo acumula **déficit epistémico** — tensión por argumentos no respondidos, información no procesada, presión competitiva — y actúa para reducirlo.

La frecuencia de participación no se fija ni se rutea: emerge del estado regulatorio de cada agente.

4 Axiomas de Autonomía Homeostática (AAH)

Los supuestos sobre el agente que el experimento requiere para ser interpretable.

A1 · Autonomía

$$Aut(a) \Leftrightarrow \exists \delta_i: \pi_i = \pi(\delta_i(t))$$

La política del agente depende de su estado interno.

A2 · Impulso

$$D(e)=\alpha, D(\delta_i)>\alpha, p_i = \sigma(D(\delta_i(t)))$$

Un impulso interno que crece con el desvío del equilibrio y determina monótonamente la probabilidad de activación.

A3 · Compuerta de calidad

$$\Delta \delta_i = -\alpha g(e^{(t)}, e^{(t+1)}), \alpha > 0$$

Un cambio efectivo g en el estado del entorno regulado; el impulso decrece proporcionalmente a ese cambio.

5 Operador Pro-Acción reducido: EPR = $\Gamma(n=1)$

EPR es la reducción escalar del operador Pro-Action Γ (Gerpe 2026): un solo subsistema ($n=1$), sin Q-learning, sin cross-coupling. Un termostato epistémico que mantiene el déficit δ en un rango viable.

$$\delta_i^{(t+1)} = \delta_i^{(t)} + \lambda - \alpha \cdot g_i^{(t)}$$

$\lambda = 0.02$ decaimiento basal · $\alpha = 4.0$ saciación por debate · g = señal de calidad estructural (engagement $\times$ novelty + diversity)

$$p_i^{(t)} = \sigma(k \cdot (\delta_i^{(t)} - \theta))$$

$k = 10$ · $\theta = 0.7$ · σ = sigmoide logística



RSVI (Regulatory State Verbalized Interception): el estado regulatorio se inyecta al prompt como contexto descriptivo — no prescriptivo. El LLM puede seguir o ignorar la señal. A diferencia de Γ (6 subsistemas), EPR tiene un solo δ escalar.

6 Diseño experimental

Condición	Activación	RSVI	Propósito
EPR	Endógena (sigmoid + drive)	Sí	Condición principal
EPR_Q	Endógena + Q-learning	Sí	Ablación: ¿Q-learner aporta?
EPR_SHAM	δ aleatorio (sigmoid roto)	No	Ablación: ¿el loop importa?
LANGGRAPH	Exógena (LLM router)	No	Baseline exógeno

Ablación limpia: EPR y LangGraph difieren sólo en el locus de control (endógeno vs exógeno) y la presencia de RSVI. Mismo LLM, mismos agentes, mismo grato, mismo throughput (1 agente/tick). Hiperparámetros calibrados con seed independiente (grid 3×3, $\alpha \in \{3,4,5\}$, $\lambda \in \{0.02, 0.03, 0.05\}$).

7 Configuración de reproducibilidad

Rol	Modelo	Temp	Seed
Agentes (10)	DeepSeek V4-Flash	0.0	Por agente (SeedFactory)
Router LG	DeepSeek V4-Flash	0.0	router_llm (SeedFactory)
Juez 1	DeepSeek V4-Pro	0.0	JUDGE_SEED (fijo)
Juez 2	GLM-5.2 (Z.AI)	do_sample=False	JUDGE_SEED (fijo)
Embeddings	text-embedding-3-small (OpenAI)	—	—

Master seed: 20260308. SeedFactory deriva primos únicos por componente (agentes, router, simulación) vía SHA-256. Calibración: grid 3×3, $\alpha \in \{3,4,5\}$, $\lambda \in \{0.02, 0.03, 0.05\}$, seed 196379. Selección: $\alpha=4.0$, $\lambda=0.02$.

RSVI: el déficit δ se inyecta al prompt como contexto descriptivo. LangGraph no recibe RSVI. Código y logs: github.com/codewithpatel/langclaw_experiment.

deficit = 0.82 (high = epistemic pressure)
→ "Your epistemic deficit is HIGH. You have not contributed to the debate recently."

8 Resultados preliminares — 2ª seed de cada lote (8/20 seeds)

Métrica	EPR	Q	SHAM	LG
Debates	38.2	43.2	36.5	62.8
Max-share	0.118	0.110	0.211	0.249
Max deficit	1.13	0.96	3.73	2.47
Avg Δφ*	0.468	0.456	0.452	0.444
Anomalías	0	0	3	3

Media de 4 corridas (lotes 1-4, 2ª seed de cada lote). $\alpha=4.0$, $\lambda=0.02$, $k=10$, $\theta=0.7$, $T=80$.

Colapso de contexto: Δφ* por ventana

Ventana	EPR	Q	SHAM	LG
Ticks 0-15	0.493	0.501	0.453	0.487
Ticks 16-31	0.490	0.480	0.494	0.454
Ticks 32-47	0.456	0.448	0.454	0.436
Ticks 48-63	0.458	0.441	0.428	0.429
Ticks 64-79	0.450	0.423	0.432	0.420
Degrad.	8.8%	15.6%	3.9%*	13.9%

Resultados preliminares: 2ª seed de cada lote (8/20 seeds). Experimento completo: 20 seeds × 4 modos × 80 ticks en curso. Análisis estadístico (Wilcoxon signed-rank, Bonferroni $\alpha=0.0167$) pendiente. *SHAM: degradación media con alta varianza (rango -5.5% a 14.8%).

(A) DISTRIBUCIÓN DE TURNOS

EPR: max-share **0.118** vs LangGraph **0.249** (2.1×). Sin monopolización (0/4 lotes >0.25). LangGraph monopoliza en 2/4 lotes (hasta 0.284). La activación endógena distribuye turnos orgánicamente.

(B) ABLACIÓN SHAM — EL LOOP IMPORTA

SHAM produce **deficit explosivo (3.73 vs 1.13)** en 3/4 lotes. La sigmoide sola no basta: el **loop homeostático** es lo que controla el deficit. Además degrada la equidad (max-share 0.211 vs 0.118).

(C) Q-LEARNING NO APORTA Y PODRÍA PERJUDICAR

EPR_Q (43.2 debates, deficit 0.96) vs EPR (38.2, 1.13): mejora marginal en deficit, pero **degrada más rápido** (slope -0.019 vs -0.012, 15.6% vs 8.8%). El Q-learning añade complejidad sin beneficio claro.

(D) LANGGRAPH: MÁS VOLUMEN, MENOS EQUITAD

62.8 debates vs 38.2, pero mayor concentración (0.249 vs 0.118) y mayor deficit (2.47 vs 1.13). Además no mantiene consistencia de rol (IR=0.00 vs 1.00).

(E) COLAPSO DE CONTEXTO — H1

Todos los modos degradan Δφ* temporalmente, pero a distintas tasas. **EPR degrada menos (8.8%, slope -0.012)** vs LangGraph (13.9%, -0.016): el loop homeostático modula el colapso. **EPR_Q degrada más (15.6%)**: el Q-learning no amortigua y podría amplificarlo. SHAM (3.9%*) con alta varianza (rango -5.5% a 14.8%): trayectorias erráticas. **Conclusión:** el colapso de contexto es parcialmente endógeno — el mecanismo de activación lo modula pero no lo elimina. El loop homeostático es necesario pero no suficiente; falta un mecanismo de gestión de memoria a largo plazo.

9 Limitaciones

- **Proveedor único:** DeepSeek V4-Flash para todos los agentes. Efectos dependientes del modelo no controlados. Replicación multi-LLM pendiente.
- **Tópico único:** "Gestión gubernamental de la crisis sanitaria y sus consecuencias económicas". Efectos de tópico no controlados.
- **N preliminar:** 8/20 seeds completadas (2ª seed de cada lote). 20 seeds en curso. Poder estadístico limitado hasta completar el experimento.
- **Pesos calibrados:** StimulusEvaluator con perfil faction-dominant calibrado con seed independiente (grid 3×3, $\alpha \in \{3,4,5\}$, $\lambda \in \{0.02, 0.03, 0.05\}$). Diferente calibración podría cambiar el comportamiento, aunque el perfil fue seleccionado por estabilidad.
- **RSVI integrado, no confundido:** RSVI verbaliza δ_i que drivea la activación endógena. Sin loop homeostático no hay δ_i que verbalizar. Inyectar RSVI en LangGraph sería enviar estado ficticio que no drivea ninguna decisión — ruido, no control. La comparación es entre arquitecturas completas, no entre factores independientes.
- **80 ticks:** Puede ser demasiado corto para comportamiento asintótico.

10 Trabajo futuro y contribuciones

1 · Reframe. Tratar la activación como un proceso endógeno regulado — no una decisión de scheduling externa. Nombra un gap estructural en el paradigma de orquestación actual.

2 · Mechanism. EPR ($\Gamma(n=1)$, sin Q-learning) + RSVI exponen el estado regulatorio al LLM como superficie de control inspeccionable — sin prescribir qué acción tomar.

3 · Evidence. 8/20 seeds muestran distribución de turnos 2.1× más equitativa que LangGraph, la ablación sham confirma que el loop homeostático — no sólo la forma del gate — es lo que produce el efecto, y la degradación temporal de Δφ* (colapso de contexto) es menor bajo EPR (8.8%) que bajo LangGraph (13.9%).

Extensiones planificadas: (1) Reasoning effort modulado por deficit ($\delta \rightarrow$ reasoning_effort en DeepSeek V4-Flash); (2) Drive metabólico para regular consumo de API ($\Gamma(n=2)$); (3) Replicación multi-LLM (GLM-5.2, Claude); (4) Jueces LLM duales con Cohen's κ + validación humana (Spearman ρ); (5) Integración formal de DeLP.

Referencias