LangClaw — Informe de Deep Research para Submission JAIIO

Resumen Ejecutivo

Este informe responde sistemáticamente a los cuatro bloques del prompt de deep research para el paper **LangClaw**, un framework de orquestación multi-agente con regulación homeostática endógena (HRRL) propuesto como alternativa a LangGraph. Se verifican referencias específicas, se auditan claims de gaps de literatura, se diseña el protocolo MCDA para la rúbrica argumentativa y se establece el diseño del juicio LLM-as-judge con análisis de poder estadístico.

Bloque 1 — Verificación de Referencias Específicas

1.1 "Peer-Reference Rate" — Marandi 2026 (marandi2026prr)

Veredicto: La referencia `marandi2026prr` tal como fue citada NO EXISTE. Es una alucinación parcial, pero el concepto es real.

El término **Peer-Reference Rate (PRR)** aparece como métrica real y operacionalizada en un paper reciente de arXiv, pero no de un autor llamado Marandi. La referencia correcta es:

> *"The impact of multi-agent debate protocols on debate quality"* (arXiv:2603.28813, marzo 2026). Este trabajo introduce PRR como métrica formal definida como:[1][2]

$$\text{PRR} = \frac{1}{N}\sum_{i=1}^{N} \mathbf{1}\{\text{turno } i \text{ contiene mención de par y palabra de postura}\}$$

donde la detección es determinista con lexicón fijo {*agree, disagree, challenge, support*}. El paper compara tres protocolos de debate (Within-Round, Cross-Round, Rank-Adaptive Cross-Round) y establece la existencia de un trade-off entre interaction richness (PRR alto) y convergence pressure.[2][1]

BibTeX correcto para reemplazar marandi2026prr:

```
@article{anonymous2026madprotocols,
  title={The impact of multi-agent debate protocols on debate quality},
  author={Anonymous},
  journal={arXiv preprint arXiv:2603.28813},
  year={2026},
  url={https://arxiv.org/abs/2603.28813}
}
```

Referencias equivalentes adicionales si se necesita un trabajo previo citando engagement quality en debate multi-agente:

- Du et al. (EMNLP 2024): *"Encouraging Divergent Thinking in Large Language Models through Multi-Agent Debate"* — introduce el problema Degeneration-of-Thought (DoT) y propone MAD como solución.[^3]
- Xu et al. (EMNLP 2024): *"MAgIC: Investigation of LLM Powered Multi-Agent in Cognition, Adaptability, Rationality and Collaboration"* — métricas de proceso en MAS adversarial. [^4]

1.2 OpenClaw — Framework Heartbeat

Veredicto: El framework existe y tiene documentación pública verificable. La URL canónica es real.

OpenClaw es un framework open-source que introduce el paradigma de **heartbeat** (turnos periódicos proactivos) en agentes LLM. Su mecanismo de heartbeat corre por defecto cada 30 minutos como daemon de fondo, lee el archivo `HEARTBEAT.md` en el workspace del agente y decide si hay acción necesaria. El framework es model-agnostic (soporta GPT, Claude, Gemini, modelos locales vía Ollama).[5][6] [^7]

La documentación oficial se encuentra en dos URLs:

- `https://openclawlab.com/en/docs/gateway/heartbeat/`[^8]
- `https://docs.openclaw.ai/gateway/heartbeat`[^6]

¿Cómo citar un software sin paper formal en un paper académico (JAIIO/AAAI/IJCAI)?

El estándar aceptado es la entrada `@misc` o `@software` con campos `author`, `title`, `year`, `howpublished`, `url` y `note` (fecha de acceso). Ejemplos de papers que citan LangGraph, AutoGen y CrewAI de este modo:

- Duan & Wang (arXiv:2411.18241, 2024) citan LangGraph y CrewAI dentro del texto con referencia a sus repositorios oficiales.[^9]
- Wang & Duan (arXiv:2412.03801, 2024) citan LangGraph como framework de software con URL oficial.[10][11]

BibTeX recomendado para OpenClaw:

```
@misc{openclaw2025heartbeat,
  author       = {{OpenClaw Contributors}},
  title        = {{OpenClaw Gateway: Heartbeat}},
  year         = {2025},
  howpublished = {Open-source software documentation},
  url          = {https://openclawlab.com/en/docs/gateway/heartbeat/},
  note         = {Accessed: April 2026}
}
```

1.3 GPT-5-nano — Documentación Oficial OpenAI

Veredicto: El modelo existe. Fue lanzado el 7 de agosto de 2025. La URL canónica es verificable.

GPT-5 nano es la variante más pequeña y rápida de la familia GPT-5, lanzada el 7 de agosto de 2025. Tiene una ventana de contexto de 400,000 tokens de entrada y 128,000 de salida, con un costo de $0.05/M tokens de entrada. Su knowledge cutoff es mayo 31 de 2024. La URL canónica de la documentación oficial es:[12][13][14][15]

`https://platform.openai.com/docs/models/gpt-5-nano`[^16]

El identificador de modelo es `gpt-5-nano-2025-08-07`.[^16]

BibTeX estándar recomendado:

```
@misc{openai2025gpt5nano,
  author       = {{OpenAI}},
  title        = {{GPT-5 nano}},
  year         = {2025},
  howpublished = {OpenAI Platform Documentation},
  url          = {https://platform.openai.com/docs/models/gpt-5-nano},
  note         = {Model version: gpt-5-nano-2025-08-07. Accessed: August 2025}
}
```

Bloque 2 — Verificación de Gaps de Literatura

2.1 Claim: "No existe marco formal que trate la activación como variable endógena derivable de un estado interno del agente LLM"

Veredicto: Parcialmente defendible. Requiere reformulación.

Existen trabajos que se aproximan al concepto. El paper *"A Control-Theoretic Foundation for Agentic Systems"* (arXiv:2603.10779, 2026) desarrolla un marco que formaliza el comportamiento agéntico como sistema de control en lazo cerrado con estado interno de memoria $m(t) \in \mathbb{R}^{n_m}$, e introduce explícitamente el concepto de **endogenous switching** como mecanismo que determina qué herramientas o subagentes se activan según el estado interno del sistema. Además, el paper *"Self-Organizing LLM Agents Outperform Structures"* (Emergent Mind, 2025) identifica el **endogeneity paradox**: ni el control exógeno completo ni la autonomía endógena completa optimizan el rendimiento en MAS.[17][18][19][20]

Sin embargo, **ninguno de estos trabajos trata la activación como variable endógena derivable de un estado interno en el contexto de orquestación de MAS-LLM**. El trabajo de arXiv:2603.10779 opera en el nivel de agente individual, no de orquestador.

Reformulación sugerida:

> "Si bien existen aproximaciones control-teóricas que modelan el estado interno del agente en sistemas de lazo cerrado [citar arXiv:2603.10779], no existe, a nuestro conocimiento, un marco formal de orquestación multi-agente para LLMs que trate la decisión de activación de agentes como variable endógena derivable de un estado interno colectivo del sistema, en contraste con los enfoques de enrutamiento exógeno prevalentes."

2.2 Claim: "La regulación homeostática como principio de orquestación para agentes LLM permanece subexplorada"

Veredicto: Defendible con precisión. El claim específico sobre HRRL como mecanismo de orquestación en MAS-LLM es sólido.

No se encontraron papers que apliquen explícitamente regulación homeostática como principio de orquestación en sistemas multi-agente LLM. Trabajos relacionados en regulación y autonomía:

- *"From the logic of coordination to goal-directed reasoning: the agentic turn"* (Frontiers in AI, 2026) propone una "synthetic teleology" con ecuaciones de goal-maintenance recursivo, aproximándose a la idea de auto-regulación pero sin abordar la homeostasis como mecanismo de orquestación.[^21]
- El VSM (Viable System Model) de Beer ha sido aplicado a MAS en contextos prácticos, pero sin LLMs ni mecanismo homeostático formal como regulador de activación.[22][23]

El claim es defendible como está, con la aclaración de que la HRRL en neurociencia computacional y sistemas clásicos sí existe (para distanciarla del dominio LLM-MAS).

2.3 Claim: "No existe sensor de calidad estructural explícito que cierre el lazo regulatorio en MAS-LLM"

Veredicto: Defendible. No se encontró trabajo equivalente.

Existen métricas de calidad estructural en debate multi-agente (PRR, coherencia, diversidad), pero ningún paper de MAS-LLM las usa como **señal de feedback que cierre un lazo regulatorio** para ajustar dinámicamente la activación de agentes. El paper de problem drift (arXiv:2502.19559) propone DRIFTJudge como detector de deriva, pero es un mecanismo de detección post-hoc, no un sensor que cierre un lazo de control interno.[2][24]

2.4 Claim: "El uso de AAF (Dung 1995) como sensor de regulación en MAS-LLM no ha sido explorado"

Veredicto: Mayormente defendible. Hay combinaciones AAF+LLMs, pero no en orquestación adaptativa.

Existen trabajos que combinan Abstract Argumentation Frameworks con LLMs para resolución de conflictos: *"Enhancing Conflict Resolution in Language Models via Abstract*

Argumentation" (arXiv:2412.16725) usa AAF para mejorar las capacidades de resolución de conflictos en LLMs. Sin embargo, **ningún trabajo usa AAF como sensor de calidad que regule dinámicamente la activación de agentes en un sistema de orquestación MAS-LLM.**[^25]

Reformulación sugerida:

> "Si bien la combinación de AAF con LLMs ha sido explorada en contextos de resolución de conflictos [citar arXiv:2412.16725], el uso de Argumentation Frameworks como sensor de calidad para regular dinámicamente la activación de agentes en sistemas de orquestación MAS-LLM no ha sido abordado en la literatura."

2.5 Papers Adicionales: Context Collapse y Coherence Degradation en MAD (2024–2026)

Los siguientes 5 papers de venues top no están en la bibliografía habitual de LangClaw y fortalecen la revisión sobre degradación de contexto y coherencia en debate multi-agente:

Paper	Venue	Aporte relevante
Becker et al. (2025/2026). *"Stay Focused: Problem Drift in Multi-Agent Debate"*. arXiv:2502.19559	EACL 2026 Findings [24][26]	Define y cuantifica *problem drift* como degradación de foco en MAD a lo largo de múltiples turnos
Anonymous (2026). *"The impact of multi-agent debate protocols on debate quality"*. arXiv:2603.28813	arXiv 2026 [1][2]	Trade-off entre PRR (interacción) y convergencia; el protocolo afecta cualitativamente el debate
NeurIPS 2024. *"Multi-LLM Debate: Framework, Principals, and Interventions"*. Proceedings NeurIPS 2024 [27][28]	NeurIPS 2024	Formaliza echo-chamber effects y tyranny of majority en debate multi-agente LLM
ACL 2025 Findings. *"CortexDebate: Debating Sparsely and Equally for Multi-Agent Debate"*. arXiv	ACL 2025 [^29]	Aborda "getting lost in plenty of input information" (context overload) y overconfidence dilemma en MAD
arXiv:2510.07517 (2025/2026). *"Anonymization for Bias-Reduced Multi-Agent Reasoning"*	arXiv [^30]	Sycophancy e identity-driven biases en MAD; agentes adoptan ciegamente la posición de pares

Bloque 3 — MCDA para Rúbrica de Evaluación Argumentativa

3.1 Comparación de Métodos MCDA

Método	Procedimiento	Pros para este caso	Contras para este caso	Referencia canónica
AHP (Saaty 1977/1980)	Comparaciones pareadas entre todos los criterios; pesos derivados por eigenvector principal; verificación via Consistency Ratio (CR < 0.1)	Altamente citado; CR verifica consistencia formalmente; precedente directo en evaluación NLP/LLM (Lu et al., EMNLP 2024 [31][32]); fácil de defender ante revisores	Requiere n(n-1)/2 comparaciones (15 para 6 criterios); sensible a inconsistencia del experto	Saaty, T.L. (1980). *The Analytic Hierarchy Process*. McGraw-Hill [33][34]
BWM (Best-Worst Method)	Identificar criterio mejor y peor; comparar solo esos dos vectores (2n-3 comparaciones); resolver modelo min-max	Requiere menos comparaciones (9 para 6 criterios vs 15 de AHP); mayor consistencia estadística demostrada vs AHP [35][36][^37]	Menos conocido en comunidad NLP; pocos precedentes en evaluación de argumentación	Rezaei, J. (2015). *Best-worst multi-criteria decision-making method*. Omega, 53, 49-57[37][36]
SMART/SMARTER	Ranking de criterios + asignación de puntajes (SMART) o solo ranking + fórmula ROC (SMARTER)	Extremadamente simple; SMARTER solo requiere ranking ordinal	No tiene verificación de consistencia formal; pesos derivados mecánicamente del ranking pueden no reflejar diferencias reales	Edwards & Barron (1994). *SMARTS and SMARTER*. Organ. Behavior & Human Decision Processes, 60(3), 306-325 [38][39]
SWING Weighting	Definir peor escenario; "balancear" cada criterio del peor al mejor; asignar puntos relativos	Intuitivo; considera rangos de variación de los criterios	No produce verificación de consistencia; puede confundirse con importancia intrínseca vs. importancia por rango	Von Winterfeldt & Edwards (1986). *Decision Analysis and Behavioral Research*. Cambridge UP [39][40]
TOPSIS	Requiere alternativas y pesos previos; no es un método de derivación de pesos sino de ranking	No aplica directamente a derivación de pesos	No resuelve el problema de origen (derivar pesos); es un método de ranking de alternativas dado pesos	Hwang & Yoon (1981). *Multiple Attribute Decision Making*. Springer

3.2 Recomendación Fundada: AHP con verificación de CR

Se recomienda AHP por las siguientes razones en el contexto específico de LangClaw:

1. **Precedente directo en NLP/LLM**: Lu et al. (EMNLP 2024 Findings, arXiv:2410.01246) aplicaron AHP exactamente para multi-criteria evaluation de respuestas a preguntas abiertas con LLMs, obteniendo resultados superiores a baselines. Este paper es la referencia metodológica más directamente citable como precedente.[31][32] [^41]
2. **Aún más relevante**: Iyer et al. (arXiv:2604.03742, abril 2026) adaptan AHP para evaluación de LLMs con extensión Fuzzy AHP, validado en JudgeBench, demostrando que AHP estructurado supera consistent-scoring directo. Citar este trabajo fortalece la justificación metodológica considerablemente.[42][43]
3. **CR verificable**: El Consistency Ratio (CR < 0.1) provee un criterio matemático formal que los revisores de JAIIO/IJCAI pueden verificar, haciendo la derivación de pesos **transparente y replicable**.[^33]
4. **Un solo experto**: Con un único tomador de decisiones, AHP es particularmente adecuado porque el proceso de comparación pareada hace explícita la estructura de preferencias, lo que facilita la defensa ante revisores.[^44]

> **Nota sobre BWM como alternativa**: Si se prefiere reducir comparaciones (9 vs 15 para 6 criterios), BWM es la mejor alternativa con CR propio y resultados estadísticamente más consistentes que AHP. Sin embargo, tiene menos precedente en evaluación de NLP. [^37]

3.3 Protocolo Paso a Paso: AHP para la Rúbrica de LangClaw

Paso 1 — Definir los criterios (C1–C6)

Propuesta de 6 criterios para la rúbrica argumentativa:

- **C1**: Relevancia temática (el argumento responde al tema del debate)
- **C2**: Novedad argumentativa (aporta información/perspectiva nueva respecto a turnos previos)
- **C3**: Calidad lógica (estructura argumento-evidencia-conclusión)
- **C4**: Especificidad del ataque (el contra-argumento se dirige a claims específicos del adversario)
- **C5**: Ausencia de falacias (no contiene falacias ad hominem, strawman, etc.)
- **C6**: Coherencia con contexto (mantiene continuidad con argumentos previos del mismo agente)

Paso 2 — Construir la matriz de comparación pareada

Comparar todos los pares (i,j) usando la escala de Saaty (1 = igual importancia, 3 = moderadamente más importante, 5 = fuertemente más importante, 7 = muy fuertemente, 9 = extremadamente). Para 6 criterios: 15 comparaciones.

Ejemplo de matriz A (6×6):

$$A = \begin{pmatrix} 1 & a_{12} & a_{13} & a_{14} & a_{15} & a_{16} \\ 1/a_{12} & 1 & a_{23} & \cdots & & \\ \vdots & & \ddots & & & \vdots \\ 1/a_{16} & \cdots & & & & 1 \end{pmatrix}$$

Paso 3 — Derivar pesos por eigenvector principal

Calcular el eigenvector principal $\mathbf{w}$ de A (normalizado) como vector de pesos. En la práctica, el método aproximado de suma de filas normalizadas es suficiente para 6 criterios.[^33]

Paso 4 — Verificar consistencia (CR < 0.1)

$$CI = \frac{\lambda_{\max} - n}{n-1}, \quad CR = \frac{CI}{RI_n}$$

donde $RI_6 = 1.24$ (índice aleatorio de Saaty para n=6). Si CR > 0.1, revisar las comparaciones más inconsistentes. Herramienta sugerida: AHP-OS (online) o el paquete `ahp` en R.[^33]

Paso 5 — Reportar en el paper de forma transparente

Incluir en la sección de metodología:

- La matriz A completa (tabla 6×6)
- El vector de pesos derivado $\mathbf{w} = (w_1, \ldots, w_6)$
- El valor de CR obtenido
- Frase: *"Los pesos fueron derivados mediante el Proceso Analítico Jerárquico (Saaty, 1980) con CR = X.XX < 0.10, confirmando consistencia aceptable."*

Citar como precedentes metodológicos

- Lu et al. (2024). AHP-Powered LLM Reasoning for Multi-Criteria Evaluation. EMNLP 2024 Findings. arXiv:2410.01246[^31]
- Iyer et al. (2026). Structured Multi-Criteria Evaluation of LLMs with AHP. arXiv:2604.03742[^43]
- Gompf et al. (2021). Using AHP to introduce weights to social life cycle assessment. DOI:10.13182/NT20-A47736[^45]

Bloque 4 — Diseño del LLM-as-Judge

4.1 Estado del Arte en LLM-as-Judge (2023–2026)

El paradigma LLM-as-judge fue formalizado por **Zheng et al. (NeurIPS 2023)**: *"Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena"* (arXiv:2306.05685). Este paper establece que jueces LLM fuertes como GPT-4 alcanzan >80% de acuerdo con evaluadores humanos, e identifica sistemáticamente tres clases de sesgos:[46][47]

1. **Position bias**: el juez favorece respuestas según su posición en el prompt (primera vs. segunda)[48][49][^50]
2. **Verbosity bias**: preferencia por respuestas más largas independientemente de su calidad sustantiva[51][52]
3. **Self-preference bias**: el LLM tiende a asignar puntuaciones más altas a outputs similares a los suyos propios[^52]

Trabajos canónicos adicionales:

- Chiang & Lee (ACL 2023): *"Can Large Language Models Be an Alternative to Human Evaluations?"* (arXiv:2305.01937) — primer trabajo sistemático en mostrar el potencial de LLM evaluation[53][54][^55]
- Liu et al. (EMNLP 2023): *"G-Eval: NLG Evaluation using GPT-4 with Better Human Alignment"* (arXiv:2303.16634) — propone evaluación estructurada con chain-of-thought y form-filling, logrando Spearman = 0.514 con humanos en summarization[56][57][^58]
- Shi et al. (IJCNLP 2025): *"A Systematic Study of Position Bias in LLM-as-a-Judge"* — introduce métricas Position Consistency, Preference Fairness y Repetition Stability[49][48]
- Survey completo: ScienceDirect 2026 sobre LLM-as-judge[^59]

Prácticas consideradas rigurosas (2024–2026):

- Usar múltiples jueces independientes (multi-judge setup)[^60]
- Presentar la misma muestra en orden invertido y promediar scores (mitiga position bias)[^50]
- Anonimizar la fuente del output al juez (HRRL vs LangGraph no visibles)[^30]
- Usar escala de puntaje con probabilidades de tokens (como G-Eval) en lugar de scoring discreto[^56]
- Reportar inter-rater reliability entre jueces[61][62]

Críticas y limitaciones activas:

- LLM-as-judge puede no detectar errores fácticos sutiles[^59]
- Sycophancy en contexto multi-turn puede contaminar evaluaciones si el juez ve el historial completo[63][64]

4.2 Métricas de Inter-Rater Reliability (IRR)

Para el diseño con dos jueces (Claude Opus y Gemini Pro), escala ordinal 1–5, ~300 ítems, la métrica recomendada es **Krippendorff's Alpha** (α):

Justificación:

- Krippendorff's alpha es la métrica dominante en evaluación NLP reciente para IRR: *"Rating Roulette: Self-Inconsistency in LLM-As-A-Judge"* (EMNLP 2025 Findings, arXiv:2510.27106) la adopta como métrica primaria precisamente por su robustez ante escalas ordinales y su manejo de missing data.[61][62]
- Cohen's kappa asume solo dos evaluadores (compatible aquí) pero no maneja adecuadamente escalas ordinales a menos que se use la variante ponderada.[^65]
- **ICC (Intraclass Correlation Coefficient)** es apropiado si los puntajes se tratan como continuos, pero para escala 1–5 con 2 jueces, Krippendorff's alpha ordinal es preferible.[^61]

Métrica	Recomendación	Nota
Krippendorff's **α** ordinal	✅ Primera opción	Estándar NLP, maneja ordinales, no requiere complete cases[61][62]
Cohen's **κ** ponderado	✅ Complementaria	Reportar junto a Krippendorff's para comparabilidad con literatura previa[^65]
ICC(2,1) two-way mixed	⚠ Opcional	Útil si se quieren reportar confidence intervals de confiabilidad
Spearman **ρ** entre jueces	⚠ Contexto	Útil como descripción pero no como métrica de IRR en sentido estricto

Umbrales de interpretación para Krippendorff's α:

- α < 0.20: acuerdo pobre
- 0.20–0.40: débil
- 0.40–0.60: moderado
- 0.60–0.80: sustancial ← mínimo deseable para publicación
- 0.80: casi perfecto

4.3 Tamaño Muestral y Diseño de Muestreo

Situación: 5 seeds × 2 condiciones (HRRL: ~390 argumentos/seed, LangGraph: ~70 argumentos/seed). Total estimado: HRRL ≈ 1950 argumentos, LangGraph ≈ 350 argumentos.

Diseño recomendado: Muestreo Estratificado por Seed con cuota balanceada

El desbalance severo (390 vs 70) hace necesario controlar el tamaño muestral por condición para evitar que seeds individuales dominen. Se recomienda:

1. **Estratificar por seed**: tomar N/5 argumentos por seed en cada condición

2. **Balancear condiciones**: usar n = min(n_HRRL, n_LangGraph) × 5 como total, o cuotas fijas por celda
3. **Cuota sugerida**: 30–50 argumentos por seed × condición → total 300–500 ítems evaluados por juez

Justificación del tamaño:

- Para Wilcoxon Mann-Whitney con power = 0.80, α = 0.05 y un tamaño de efecto medio (d ≈ 0.5), se necesitan aproximadamente 64 ítems por grupo. Con 5 seeds como factor, 30 por seed × 2 condiciones = 300 total provee poder adecuado.[^66]
- El análisis de seeds individuales como random effect requiere LMM, que es más potente y no necesita un tamaño muestral tan elevado por celda.[^67]

4.4 Tests Estadísticos y Reporte de Resultados

Test recomendado principal: Linear Mixed-Effects Model (LMM)

Para comparar HRRL vs LangGraph en scores LLM-judge con seeds como random effect:

$$y_{ijk} = \mu + \beta \cdot \text{condición}_i + u_j + \epsilon_{ijk}$$

donde $u_j \sim \mathcal{N}(0, \sigma_u^2)$ es el efecto aleatorio de seed j. Este modelo es el estándar recomendado para diseños de mediciones repetidas en NLP pequeños.[^67]

Alternativa no paramétrica: Wilcoxon / Mann-Whitney U

Si se prefiere no asumir distribución normal para los scores 1–5, el test de Mann-Whitney U es apropiado para dos grupos independientes. Sin embargo, **no captura la estructura de seeds**, por lo que LMM es superior metodológicamente.[^66]

Tabla de reporte típica:

Criterio	HRRL Mean (SD)	LangGraph Mean (SD)	Δ	W / t	p-value	Cohen's d
Relevancia						
Novedad						
Calidad lógica						
Ataque específico						
Ausencia falacias						
Coherencia						
Promedio global						

Umbrales de "diferencia significativa" defendibles:

- p < 0.05 (estándar) con corrección de Bonferroni para comparaciones múltiples si se testean 6 criterios (α_ajustado = 0.0083)

- **Efecto práctico**: Cohen's d > 0.5 (efecto mediano) como umbral de relevancia sustantiva, más allá de la significancia estadística
- Reportar tanto la significancia como el tamaño del efecto siguiendo mejores prácticas actuales de evaluación NLP[^67]

Apéndice — BibTeX Consolidado


```
@inproceedings{zheng2023judging,
  title={Judging LLM-as-a-judge with {MT-Bench} and {Chatbot Arena}},
  author={Zheng, Lianmin and Chiang, Wei-Lin and others},
  booktitle={Advances in Neural Information Processing Systems},
  year={2023},
  url={https://arxiv.org/abs/2306.05685}
}

@inproceedings{chiang2023llm,
  title={Can Large Language Models Be an Alternative to Human Evaluations?},
  author={Chiang, Cheng-Han and Lee, Hung-yi},
  booktitle={Proceedings of ACL 2023},
  year={2023},
  url={https://arxiv.org/abs/2305.01937}
}

@inproceedings{liu2023geval,
  title={{G-Eval}: {NLG} Evaluation using {GPT-4} with Better Human Alignment},
  author={Liu, Yang and Iter, Dan and others},
  booktitle={Proceedings of EMNLP 2023},
  year={2023},
  url={https://arxiv.org/abs/2303.16634}
}

@inproceedings{lu2024ahp,
  title={{AHP}-Powered {LLM} Reasoning for Multi-Criteria Evaluation of Open-Ended R
  author={Lu, Xiaotian and Li, Jiyi and others},
  booktitle={Findings of EMNLP 2024},
  year={2024},
  url={https://arxiv.org/abs/2410.01246}
}

@article{iyer2026fahp,
  title={Structured Multi-Criteria Evaluation of Large Language Models with {AHP} an
  author={Iyer et al.},
  journal={arXiv preprint arXiv:2604.03742},
  year={2026}
}

@article{rezaei2015bwm,
  title={Best-worst multi-criteria decision-making method},
  author={Rezaei, Jafar},
  journal={Omega},
  volume={53},
  pages={49--57},
  year={2015},
```

```bibtex
  doi={10.1016/j.omega.2014.11.009}
}

@article{becker2025problemdrift,
  title={Stay Focused: Problem Drift in Multi-{A}gent Debate},
  author={Becker, Jonas and Kaesberg, Lars Benedikt and others},
  journal={arXiv preprint arXiv:2502.19559},
  year={2025},
  note={Accepted at EACL 2026}
}

@article{anonymous2026madprotocols,
  title={The impact of multi-agent debate protocols on debate quality},
  journal={arXiv preprint arXiv:2603.28813},
  year={2026}
}

@misc{openai2025gpt5nano,
  author       = {{OpenAI}},
  title        = {{GPT-5 nano}},
  year         = {2025},
  howpublished = {OpenAI Platform Documentation},
  url          = {https://platform.openai.com/docs/models/gpt-5-nano},
  note         = {Model: gpt-5-nano-2025-08-07. Released August 7, 2025}
}

@misc{openclaw2025heartbeat,
  author       = {{OpenClaw Contributors}},
  title        = {{OpenClaw Gateway: Heartbeat}},
  year         = {2025},
  howpublished = {Open-source software documentation},
  url          = {https://openclawlab.com/en/docs/gateway/heartbeat/},
  note         = {Accessed: April 2026}
}
```

References

1. The impact of multi-agent debate protocols on debate quality - arXiv - These results reveal a trade-off between interaction (peer-referencing rate) and convergence (consen...
2. The impact of multi-agent debate protocols on debate quality - arXiv
3. Encouraging Divergent Thinking in Large Language Models through ... - We propose a Multi-Agent Debate (MAD) framework, in which multiple agents express their arguments in...
4. Investigation of Large Language Model Powered Multi-Agent in ... - This work introduces a novel competition-based benchmark framework specifically designed to assess L...
5. What Is OpenClaw? Complete Guide to the Open-Source AI Agent - Complete guide to OpenClaw (Clawdbot/Moltbot) — how it works, setup walkthrough, use cases, Moltbook...
6. Heartbeat - OpenClaw Docs

7. OpenClaw AI Agent Masterclass - HelloPM - Hello PM Enthusiasts and Professionals, Here are the recordings and resources from masterclass on “C...
8. Heartbeat - Open Source AI Coding Assistant - OpenClaw - Heartbeat polling messages and notification rules
9. [2411.18241] Exploration of LLM Multi-Agent Application ... - arXiv - This study aims to delve into the application of LangGraph and CrewAI in multi-agent systems, provid...
10. [2412.03801] Agent AI with LangGraph: A Modular Framework for ... - This paper explores the transformative role of Agent AI and LangGraph in advancing the automation an...
11. Agent AI with LangGraph: A Modular Framework for Enhancing Machine Translation Using Large Language Models - This paper explores the transformative role of Agent AI and LangGraph in advancing the automation an...
12. GPT-5 Nano - API Pricing & Providers - OpenRouter - GPT-5-Nano is the smallest and fastest variant in the GPT-5 system, optimized for developer tools, r...
13. GPT-5: Key characteristics, pricing and model card - I’ve had preview access to the new GPT-5 model family for the past two weeks (see related video and ...
14. GPT-5 nano - CometAPI - All AI Models in One API - GPT-5 Nano is an artificial intelligence model provided by OpenAI.
15. GPT-5 - Wikipedia
16. GPT-5 nano (2025-08-07) - OpenAI Platform - Explore resources, tutorials, API docs, and dynamic examples to get the most out of OpenAI's develop...
17. Self-Organizing LLM Agents Outperform Structures - Emergent Mind - This study shows that a sequential, self-organizing protocol boosts multi-agent LLM system quality b...
18. A Control-Theoretic Foundation for Agentic Systems - arXiv
19. [2603.10779] A Control-Theoretic Foundation for Agentic Systems - This paper develops a control-theoretic framework for analyzing agentic systems embedded within feed...
20. A Control-Theoretic Foundation for Agentic Systems - arXiv - This paper develops a control-theoretic framework for analyzing agentic systems embedded within feed...
21. From the logic of coordination to goal-directed reasoning - Frontiers - Recent work in multi-agent orchestration employs LLM-based agents that communicate, negotiate, and s...
22. Building a Multi-Agent Code Review System Using the Viable ... - This post explores how VSM can serve as a foundation for implementing a multi-agent code review syst...
23. From Prolog to Agentic AI: Implementing the Viable System Model in ... - This transition from static inference rules to agentic AI enables continuous learning, real-time ada...
24. [2502.19559] Stay Focused: Problem Drift in Multi-Agent Debate - Stay Focused: Problem Drift in Multi-Agent Debate. Authors:Jonas Becker, Lars Benedikt Kaesberg, And...
25. [PDF] Enhancing Conflict Resolution in Language Models via Abstract ... - In this paper, we aim to enhance the conflict-solving capabilities of LLMs by leveraging formal abst...
26. Stay Focused: Problem Drift in Multi-Agent Debate - ACL Anthology - We analyze how multi-agent debate drifts away from the initial problem over multiple turns, thus har...

27. Multi-LLM Debate: Framework, Principals, and
28. Multi-LLM Debate: Framework, Principals, and Interventions - We propose a theoretical framework for multi-LLM debate that draws on connections from in-context le...
29. CortexDebate: Debating Sparsely and Equally for Multi-Agent Debate - To mitigate these issues, Multi-Agent Debate (MAD) has emerged as an effective strategy, where LLM a...
30. Anonymization for Bias-Reduced Multi-Agent Reasoning - arXiv - In this paper, we show that LLM agents engaged in multi-agent debate are susceptible to identity-dri...
31. AHP-Powered LLM Reasoning for Multi-Criteria Evaluation of Open ... - Question answering (QA) tasks have been extensively studied in the field of natural language process...
32. AHP-Powered LLM Reasoning for Multi-Criteria Evaluation ...
33. What is the Analytic Hierarchy Process (AHP)? - 1000minds - The weights on the criteria, representing their relative importance, are derived from your preferenc...
34. Enhancing consistency of AHP-based expert judgements - PMC - NIH - A pairwise comparison within a set containing n criteria means that each criterion undergoes (n – 1)...
35. Best Worst Method | A multi-criteria decision-making method - Best-Worst Method (BWM) is a multi-criteria decision-making (MCDM) method developed by Jafar Rezaei ...
36. Papers and Slides | Best Worst Method - The Best Worst Method (BWM) is a multi-criteria decision-making method that uses two vectors of pair...
37. Best-worst multi-criteria decision-making method - IDEAS/RePEc - In this paper, a new method, called best-worst method (BWM) is proposed to solve multi-criteria deci...
38. SMARTS and SMARTER: Improved Simple Methods for ... - This paper presents two approximate methods for multiattribute utility measurement, SMARTS and SMART...
39. rpoy97a.PDF
40. [PDF] Decision Support by Interval SMART/ SWING—Incorporating ... - In this article, we discuss the use of interval judgments in the SMART (Sim- ple Multi-Attribute Rat...
41. [Literature Review] AHP-Powered LLM Reasoning for Multi- ... - The paper titled "AHP-Powered LLM Reasoning for Multi-Criteria Evaluation of Open-Ended Responses" b...
42. Structured Multi-Criteria Evaluation of Large Language Models with ... - In this work, we adapt the Analytic Hierarchy Process (AHP) to LLM-based evaluation and, more import...
43. Structured Multi-Criteria Evaluation of Large Language Models with ... - In this work, we adapt the Analytic Hierarchy Process (AHP) to LLM-based evaluation and, more import...
44. Simple and objective determination of criteria weights for evaluating ... - This article presents a simple and objective method to construct the AHP pairwise comparison matrix,...
45. [PDF] Using Analytical Hierarchy Process (AHP) to introduce weights to ... - Thus, the goal of this research is to support decision-making through determining weightings for dif...
46. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena - This paper makes two contributions: (1) a systematic study of LLM-as-a-judge; and (2) human preferen...

47. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena - arXiv - View a PDF of the paper titled Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena, by Lianmin Zh...
48. [PDF] A Systematic Study of Position Bias in LLM-as-a-Judge
49. A Systematic Study of Position Bias in LLM-as-a-Judge - Lin Shi, Chiyu Ma, Wenhua Liang, Xingjian Diao, Weicheng Ma, Soroush Vosoughi. Proceedings of the 14...
50. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena
51. 5. Methodological... - Discover how advanced language models assess generative outputs, offering scalable, cost-effective e...
52. Self-Preference Bias in LLM-as-a-Judge - arXiv
53. [PDF] Can Large Language Models Be an Alternative to Human Evaluation? - We are the first to show the potential of using LLMs to assess the quality of texts and discuss the ...
54. Can Large Language Models Be an Alternative to Human ... - In this paper, we explore if such an ability of the LLMs can be used as an alternative to human eval...
55. Can Large Language Models Be an Alternative to Human Evaluations? - Human evaluation is indispensable and inevitable for assessing the quality of texts generated by mac...
56. NLG Evaluation using GPT-4 with Better Human Alignment - The quality of texts generated by natural language generation (NLG) systems is hard to measure autom...
57. [PDF] G-Eval: NLG Evaluation using GPT-4 with Better Human Alignment | Semantic Scholar - G-Eval is presented, a framework of using large language models with chain-of-thoughts (CoT) and a f...
58. G-Eval: NLG Evaluation using Gpt-4 with Better Human Alignment - Yang Liu, Dan Iter, Yichong Xu, Shuohang Wang, Ruochen Xu, Chenguang Zhu. Proceedings of the 2023 Co...
59. A survey on LLM-as-a-judge - ScienceDirect.com - Furthermore, score-based assessments often exhibit inconsistent inter-rater reliability, influenced ...
60. [PDF] Enhancing LLM-as-a-Judge via Multi-Agent Collaboration - Abstract. Large Language Models (LLMs) have revolutionized AI- generated content evaluation, with th...
61. [PDF] Rating Roulette: Self-Inconsistency in LLM-As-A-Judge Frameworks - Existing NLG research already uses metrics like Cohen's Kappa and Krippendorff's Alpha for measuring...
62. [PDF] Rating Roulette: Self-Inconsistency in LLM-As-A-Judge Frameworks
63. Understanding Sycophancy Propagation in Multi-Agent Systems - We ask whether awareness of other agents' sycophancy levels influences discussion outcomes. To inves...
64. [PDF] Measuring Sycophancy of Language Models in Multi-turn Dialogues - Large Language Models (LLMs) are expected to provide helpful and harmless responses, yet they often ...
65. An Empirical Study of LLM-as-a-Judge: How Design Choices Impact ... - In this work, we analyze key factors affecting its trustworthiness, focusing on alignment with human...
66. Power and sample size calculations for the Wilcoxon-Mann-Whitney ... - In this paper, we derive closed-form formulae for the power and sample size of the Wilcoxon-Mann-Whi...

67. Robust Estimation of Population-Level Effects in Repeated- ...