

Endogenous Activation via Epistemic Homeostasis in LLM-Based Multi-Agent Systems^{*}

Abstract. LLM-based multi-agent systems tend to lose coherence as interaction extends, a phenomenon known as context collapse that, in competitive deliberation settings, invalidates the debate. Contemporary frameworks (AutoGen, MetaGPT, LangGraph) maintain exogenous activation: the moment each agent speaks is decided outside its internal state, decoupling activation from the epistemic pressure the agent accumulates. Biology suggests an alternative: internal variables accumulate tension, trigger a response, and return to equilibrium without external instruction (homeostasis). We present an endogenous orchestration mechanism where each agent manages an internal epistemic deficit (δ_i) that increases steadily during inactivity and decreases after producing a useful linguistic contribution; a sigmoid function transforms this tension into an action probability. We formalize this framework through the Axioms of Homeostatic Autonomy (AAH) and present an experimental design aimed at isolating the behavior of the purely homeostatic model against traditional LangGraph routers in text debates. Our preliminary results show that pure endogenous activation mitigates conversation floor monopolization, distributing speaking turns organically without requiring the complexities associated with reinforcement learning mechanisms.

Keywords: multi-agent systems , large language models , homeostatic activation , endogenous orchestration , multi-agent debate , event-driven architecture

^{*} Dos modelos distintos intervienen en este trabajo y conviene separarlos. **Claude Sonnet 4** se empleó exclusivamente como herramienta de *redacción* para mejorar el lenguaje y la legibilidad del manuscrito; los autores revisaron y editaron el contenido y asumen plena responsabilidad. Los *experimentos* se ejecutan en **DeepSeek V4-Flash**: todos los agentes deliberativos, el enrutador LangGraph y los módulos auxiliares comparten ese mismo modelo. Los jueces offline usan DeepSeek V4-Pro y GLM-5.2 (ciegos al modo de orquestación).

Activación Endógena mediante Homeostasis Epistémica en Sistemas Multi-Agente Basados en LLMs

Abstract. Los sistemas multi-agente basados en modelos de lenguaje (LLMs) tienden a perder coherencia a medida que la interacción se extiende, un fenómeno conocido como colapso de contexto que, en entornos de deliberación competitiva, invalida el debate. Los marcos de trabajo contemporáneos (como AutoGen, MetaGPT o LangGraph) mantienen una activación exógena: el momento en que habla cada agente se decide por fuera de su estado interno, desacoplando la activación de la presión epistémica que el agente acumula.

La biología sugiere una alternativa: las variables internas acumulan tensión, gatillan una respuesta y regresan al equilibrio sin una instrucción externa (homeostasis). En este trabajo presentamos un mecanismo de orquestación endógena donde cada agente gestiona un déficit epistémico interno (δ_i) que aumenta de forma constante durante los periodos de inactividad y se reduce inmediatamente después de realizar una contribución lingüística útil; una función sigmoide transforma esta tensión en una probabilidad de acción.

Formalizamos este marco a través de los Axiomas de Autonomía Homeostática (AAH) y presentamos un diseño experimental orientado a aislar el comportamiento del modelo puramente homeostático frente a ruteadores tradicionales de LangGraph en debates de texto. Nuestros resultados preliminares muestran que la activación endógena pura logra mitigar la monopolización del piso conversacional, distribuyendo los turnos de habla de manera orgánica sin requerir las complejidades asociadas a mecanismos de aprendizaje por refuerzo.

Keywords: sistemas multi-agente , modelos de lenguaje , activación homeostática , orquestación endógena , debate multi-agente , arquitectura dirigida por eventos

1 Introducción

Los sistemas multiagente basados en LLM comienzan a emplearse en procesos deliberativos de larga duración —análisis de políticas, revisión científica, decisiones institucionales— donde la pérdida de coherencia no queda contenida en el software: una recomendación de política sostenida sobre un debate viciado puede afectar a millones, y una revisión científica con premisas alucinadas contamina la literatura sobre la que se construye más ciencia. El escalamiento del cómputo en inferencia (Snell et al., 2024) reabre una pregunta de asignación: dado un presupuesto fijo, ¿cómo conviene distribuirlo entre agentes? A medida que la interacción se extiende, los agentes pierden registro de argumentos previos, repiten puntos o producen monólogos desconectados (Park et al., 2023)—el *colapso del contexto*. En deliberación adversarial cada argumento presupone los anteriores: esta pérdida no degrada el debate, lo *invalida*.

El campo ha consolidado un paradigma generalista de orquestación. Una generación reciente de frameworks —AutoGen, CAMEL, MetaGPT (Hong et al., 2024; Li et al., 2023; Wu et al., 2023)— estructura las interacciones entre agentes mediante grafos de control y enrutadores centralizados que asignan turnos según el estado del flujo; LangGraph añadió estado durable y transiciones condicionales, dando al orquestador

mayor expresividad, y el paradigma de *heartbeat* (OpenClaw Contributors, 2025) incorporó persistencia temporal mediante activación periódica con memoria entre latidos. Ninguno de estos frameworks fue diseñado específicamente para deliberación adversarial extendida, pero proveen el sustrato sobre el que se construyen los MAS-LLM contemporáneos y heredan un supuesto estructural común: la decisión de *cuándo* y *con qué frecuencia* participa cada agente queda fijada por el diseñador, no emerge del agente mismo.

Un mecanismo bien establecido en biología describe cómo los sistemas regulan desequilibrios internos sin control externo: la homeostasis (Sterling & Eyer, 1988). Variables internas acumulan tensión, desencadenan respuesta y retornan al equilibrio; HRRL (Keramati & Gutkin, 2014) formalizó este principio derivando la recompensa como reducción de impulso. La analogía es estructural: donde un organismo acumula hambre y actúa para reducirla, un agente deliberativo podría acumular *déficit epistémico* y actuar para reducirlo. ¿Qué ocurriría si la coherencia en un debate multi-agente pudiera sostenerse endógenamente —no impuesta por un planificador, sino emergente del estado regulatorio de cada agente?

Exploramos esa pregunta mediante un mecanismo de regulación endógena donde cada agente mantiene un déficit epistémico que crece al permanecer inactivo y decrece tras una contribución estructuralmente útil. Una compuerta sigmoide traduce el déficit en probabilidad de acción. La frecuencia de participación no se fija ni se enruta: *emerge*. A diferencia de trabajos previos que incorporan Q-learning sobre la base homeostática, aquí nos concentramos en el *modelo puramente homeostático* —al que denominamos EPR (Ecuación Pro-Acción Reducida, $\Gamma(n=1)$)— para aislar la contribución del mecanismo regulatorio básico sin la complejidad del aprendizaje por refuerzo.

De ahí, cuatro contribuciones: (i) una axiomatización ontológica de Autonomía Homeostática (AAH) que explicita los supuestos sobre el agente requeridos para que el experimento subsiguiente sea interpretable; (ii) una arquitectura concreta de activación endógena para sistemas multi-agente de LLM que articula impulso, sensor estructural multicriterio y compuerta sigmoide en un lazo event-driven; (iii) una operacionalización empírica de coherencia estructural mediante grafos de argumentación abstracta (AAF) y un sensor de cinco criterios, con correcciones de conectividad y validación grafo-estructural; (iv) un diseño experimental controlado con 20 semillas pareadas (4 lotes de 5), hipótesis pre-registradas, jueces LLM duales ciegos al modo y cuatro condiciones (EPR, EPR_Q, EPR_SHAM, LangGraph).

2 Revisión bibliográfica

Orquestación exógena. AutoGen (Wu et al., 2023), CAMEL (Li et al., 2023) y MetaGPT (Hong et al., 2024) demostraron que grupos de agentes de LLM con roles especializados podían abordar tareas complejas, pero dependiendo de estructuras de turno predefinidas. LangGraph consolidó este paradigma añadiendo estado durable y transiciones condicionales, otorgando al orquestador mayor expresividad sin alterar el principio subyacente: la decisión de activación permanece fuera del agente. Huang et al. (2025) muestran que esta forma organizacional afecta la resiliencia, con estructuras centralizadas degradándose más rápido bajo estrés; Becker et al. (2026) documentan que este dete-

rioro suele tomar la forma de *problem drift* —pérdida progresiva de foco en debates extendidos.

Heartbeat y persistencia temporal. El paradigma (OpenClaw Contributors, 2025) extendió la persistencia con memoria entre latidos, sosteniendo interacciones largas; sin embargo la frecuencia de activación sigue siendo una constante del scheduler. El avance es temporal, no regulatorio.

Variables internas sin cierre regulatorio. Los agentes LLM dirigidos por deseo (Wang et al., 2025) reconocen que el estado interno debería importar, pero no cierran el lazo: carecen de señal explícita de calidad que module la activación.

Regulación homeostática. HRRL (Keramati & Gutkin, 2014) formalizó en neurociencia computacional la idea de que la recompensa es reducción de impulso. En el dominio LLM, trabajos recientes (Eslami & Yu, 2026) formalizan el comportamiento agéntico como sistema de control en lazo cerrado a nivel de agente individual; sin embargo, la traslación al orquestador multi-agente permanece subexplorada.

Modelo de discurso. Implementamos un *Abstract Argumentation Framework* (AAF) según Dung (Dung, 1995): nodos como argumentos, aristas como ataques, semántica fundamentada para aceptabilidad. El escenario adversarial se inspira en Sotopia (Zhou et al., 2024).

3 Fundamentos teóricos y diseño del sistema

3.1 Axiomas de Autonomía Homeostática (AAH)

Antes de presentar la arquitectura conviene explicitar los supuestos sobre el agente que el experimento subsiguiente requiere para ser interpretable. Denotamos esta axiomatización AAH.

Postulados. AAH-1 (Autonomía (Ashby, 1956; Beer, 1972)). Que la política del agente responda a su estado interno: dado entorno externo constante, dos valores distintos del estado interno inducen distribuciones de acción distinguibles.

$$\text{Aut}(a_i) \iff \exists \delta_i \in S_L(a_i) : \pi_i = \pi_i(\delta_i(t) | e = \bar{e}) \quad (1)$$

AAH-2 (Impulso (Sterling & Eyer, 1988)). Un impulso interno $D(\delta)$ que crece con el desvío del equilibrio ($D(\epsilon) = 0$, $D'(\delta_i) > 0 \forall \delta_i > \epsilon$), y una probabilidad de activación $p_i(t) = h(\delta_i(t))$ con h monótona creciente en δ_i .

$$p_i^{(t)} = \frac{1}{1 + e^{-k(\delta_i^{(t)} - \theta)}} \quad (2)$$

con $k=10$, $\theta=0.7$.

AAH-3 (Compuerta de calidad (Ryan & Deci, 2001)). Un cambio efectivo en el estado del entorno regulado. Sea $g(e(t), e(t+1)) \geq 0$ la medida de ese cambio; el impulso decrece, sujeto a un piso fisiológico $\epsilon \geq 0$:

$$\delta_i^{(t+1)} = \max(\epsilon, \delta_i^{(t)} - \alpha g(e(t), e(t+1))), \quad \alpha > 0 \quad (3)$$

El piso ϵ representa el déficit basal irreducible del agente (estado de reposo). La formulación axiomática coincide con la implementación concreta de la Sec. 3.2.

3.2 Dinámica del déficit epistémico

En cada heartbeat t actúan tres fuerzas: decaimiento basal $\delta^{(t+1)} = \delta^{(t)} + \lambda$ (Ec. 4, $\lambda=0.02$); estimulación por perturbaciones discursivas con utilidad $u=U(\text{stim})$ (Ec. 8), $\delta^{(t+)} = \delta^{(t)} + \gamma_{\text{stim}} \cdot u$ ($\gamma_{\text{stim}}=0.1$); y saciedad tras producir un argumento de calidad $\Delta\varphi^*$, $\delta^{\text{new}} = \max(\varepsilon, \delta - \alpha \cdot \Delta\varphi^*)$ con α por calibración.

$$\delta_i^{(t+1)} = \delta_i^{(t)} + \lambda \quad (4)$$

El impulso $D(\delta_i) = (\delta_i - \varepsilon)^m$ ($m=2$) penaliza desviaciones superlinealmente (Keremati & Gutkin, 2014).

Ecuación unificada. Las tres fuerzas se integran aditivamente dentro de cada heartbeat t en el siguiente orden: (1) decaimiento basal, (2) estimulación si ocurre un evento discursivo, (3) saciedad si el agente produce un argumento. La ecuación de actualización completa es:

$$\delta_i^{(t+1)} = \max\left(\varepsilon, \delta_i^{(t)} + \lambda + \gamma_{\text{stim}} \cdot u^{(t)} - \alpha \cdot \Delta\varphi^{*,(t)}\right) \quad (5)$$

donde $u^{(t)} = U(\text{stim})$ si hay estímulo en t (cero en caso contrario) y $\Delta\varphi^{*,(t)}$ es la calidad del argumento producido en t (cero si el agente no debatió). El $\max(\varepsilon, \cdot)$ asegura consistencia con AAH-3 (Ec. 3).

3.3 Grafo de argumentos y proxy $\Delta\varphi^*$

AAH-3 demanda una medida computable del cambio en el entorno regulado. Se construye $\Delta\varphi^*$ sobre el grafo de discurso $G=(V, E)$:

$$\Delta\varphi^* = \frac{1}{3}C_B(u) + \frac{1}{3}\mathbb{K}_{\text{cycle}}(v, u) + \frac{1}{3}\text{Div}(u) \quad (6)$$

donde $C_B(u)$ es centralidad de intermediación de u en el grafo de discurso, v es el nodo atacado por u (i.e., $v = \text{target}(u)$), $\mathbb{K}_{\text{cycle}}(v, u)$ indica si la arista (v, u) cierra un nuevo ciclo dialéctico, y $\text{Div}(u)$ es diversidad de agentes que han atacado a u . Nodos aislados obtienen $\Delta\varphi^* = 0$.

Corrección de conectividad. Cuando el LLM produce un `target_node_id` que no existe en el grafo (alucinación, truncamiento de UUID), el sistema intenta *fuzzy matching* por prefijo o sufijo. Si ningún match se encuentra y existen otros nodos, se selecciona el más reciente como *fallback*. Esto previene nodos aislados y asegura $\Delta\varphi^* > 0$ para todo argumento no-raíz, pero introduce una trade-off entre completitud estructural y fidelidad semántica: algunas aristas son “sintéticas” y no corresponden a la intención real del LLM.

3.4 PRR_G validado

La tasa de referencia entre pares (PRR_G) mide la fracción de turnos DEBATE cuyo target_node_id apunta a un nodo *realmente existente* en el grafo:

$$\text{PRR}_G = \frac{|\{d \in D : \text{target}(d) \in V_G\}|}{|D|} \quad (7)$$

A diferencia de una versión anterior que sólo verificaba target_node_id ≠ null, esta formulación valida contra el conjunto de nodos reales V_G, eliminando el sobrecuento por alucinaciones del LLM.

3.5 Arquitectura del agente

Cada agente selecciona entre cinco acciones: **DEBATE** (producir un argumento), **SEARCH**, **READ**, **MESSAGE** (acto comunicativo dirigido, FIPA ACL), o **PASS**. El *StimulusEvaluator* actúa como sensor: ante cada NewArgumentEvent, computa relevancia según cinco criterios ponderados:

$$U(\text{stimulus}) = w_F \cdot F + w_C \cdot C_B(u) + w_M \cdot M + w_N \cdot N + w_P \cdot P \quad (8)$$

con $w_F + w_C + w_M + w_N + w_P = 1$, calibrados como *faction-dominant* ($w_F=0.40$, restantes 0.15). Los componentes son: F = afinidad de facción (estímulo proviene de agente de facción opuesta), $C_B(u)$ = centralidad de intermediación del nodo atacado, M = novedad léxica (similitud coseno con argumentos previos del agente, invertida), N = novedad estructural (grado del nodo atacado), P = posición temporal (normalizada por tick).

3.6 Diseño del sistema multi-agente

Diez agentes en dos facciones espejo (Gobierno/Oposición), cada una con los cinco subsistemas del Modelo de Sistema Viable (Beer, 1972): **S1 Operaciones** produce y defiende argumentos; **S2 Coordinación** sincroniza aliados; **S3 Control** audita coherencia interna; **S4 Inteligencia** escanea al oponente; **S5 Estrategia** fija prioridades.

3.7 Condiciones experimentales

EPR (Ecuación Pro-Acción Reducida, $\Gamma(n=1)$): condición primaria. Activación endógena via sigmoide (Ec. 2); el LLM elige la acción (DEBATE, SEARCH, READ, MESSAGE, PASS) desde el diccionario de acciones. Sin Q-learning. Sigmoide, drive y StimulusEvaluator permanecen activos. RSVI verbaliza el estado regulatorio (δ_i) en el prompt del agente.

EPR_Q: EPR + Q-learning (ablación:

'el Q-learner aporta? responde a JAIIO R1b). Mismo mecanismo homeostático con política de selección de acción aprendida en lugar de heurística.

EPR_SHAM: sigmoide con δ aleatorio (ablación:

'el loop homeostático importa o basta la forma del gate?). Preserva la no-linealidad sigmoide pero desconecta la activación del drive epistémico real.

LangGraph (exógena): un enrutador LLM neutral decide qué agente ingresa al lazo cognitivo en cada heartbeat. El agente seleccionado ejecuta las mismas capacidades locales. Sin RSVI: el router no recibe el estado regulatorio porque en LangGraph no hay δ_i que se actualice — el momento de activación se decide fuera del agente. Inyectar RSVI sin un loop homeostático sería enviar un estado ficticio que no drivea ninguna decisión, introduciendo ruido, no un control válido. La única diferencia vs EPR es el locus de control (exógeno vs endógeno). Throughput idéntico (1 agente/tick) para aislar el efecto.

4 Diseño experimental

4.1 Hipótesis pre-registradas

H1 (Resiliencia de calidad): la pendiente temporal de $\Delta\phi^*$ es menos negativa bajo EPR que bajo LangGraph.

$$H_0 : \text{slope}_{\Delta\phi^*}(\text{EPR}) \leq \text{slope}_{\Delta\phi^*}(\text{LG}) \quad \text{vs} \quad H_1 : \text{slope}_{\Delta\phi^*}(\text{EPR}) > \text{slope}_{\Delta\phi^*}(\text{LG})$$

H2 (Resiliencia de coherencia): la pendiente temporal de aceptación AAF es más estable (cercana a cero) bajo EPR.

$$H_0 : |\text{slope}_{\alpha}(\text{EPR})| \geq |\text{slope}_{\alpha}(\text{LG})| \quad \text{vs} \quad H_1 : |\text{slope}_{\alpha}(\text{EPR})| < |\text{slope}_{\alpha}(\text{LG})|$$

H3 (Distribución de participación): la concentración de turnos (cuota máxima por agente) es menor bajo EPR.

$$H_0 : \text{max-share}(\text{EPR}) \geq \text{max-share}(\text{LG}) \quad \text{vs} \quad H_1 : \text{max-share}(\text{EPR}) < \text{max-share}(\text{LG})$$

4.2 Análisis estadístico

- **Primario:** Wilcoxon signed-rank pareado (aprovechando semillas compartidas entre condiciones). No-paramétrico, robusto ante $N=20$. Holm-Bonferroni como sensibilidad.
- **Secundario:** Welch’s t -test (unilateral para H1 y H3; bilateral para H2). Corrección Bonferroni: $\alpha_{\text{adj}} = 0.05/3 = 0.0167$.
- **Intervalos:** Bootstrap 95% CIs (10.000 resamples).
- **Tamaño de efecto:** Cohen’s d .

4.3 Juez LLM offline

Tras cada simulación, todos los *claims* se extraen y mezclan ciegos al modo de orquestación. Dos jueces LLM evalúan cada claim: **DeepSeek V4-Pro** y **GLM-5.2** (Z.AI). Cada juez evalúa: (1) calidad argumentativa (1–5), (2) engagement (1–5), (3) novelty (1–5). El juez ve el claim, el claim atacado (si lo hay) y el rol del agente, pero no el modo, semilla ni tick. Se calcula Cohen’s κ para concordancia inter-juez.

4.4 Configuración

Table 1. Hiperparámetros.

Parámetro	Valor	Parámetro	Valor
Decaimiento λ	0.02	Sigmoide k	10
Umbral θ	0.7	Saciedad α (calibrada)	4.0
Ganancia estímulo γ	0.1	Base / inicial ε, δ_0	0.1 / 0.5
Exponente impulso m	2	Heartbeats T / agentes N	80 / 10
Pesos estímulo	(0.40, 0.15, 0.15, 0.15, 0.15) — <i>faction-dominant</i>		
Semillas	Derivadas de master 20260308, 20 seeds (4 lotes de 5)		
LLM	DeepSeek V4-Flash, timeout=60s		
Jueces	DeepSeek V4-Pro + GLM-5.2 (offline, ciegos al modo)		

5 Resultados

[RESULTADOS PRELIMINARES: 8 de 20 seeds completadas (2 por lote). Los valores numéricos de esta sección corresponden a la segunda seed de cada lote (seeds 233297, 252079, 504521, 113497). El experimento completo (20 seeds $\times$ 4 modos $\times$ 80 ticks) está en ejecución. El análisis estadístico formal (Wilcoxon, Bootstrap CIs) se aplicará sobre el conjunto completo.]

5.1 Métricas agregadas

Table 2. Resultados preliminares (2^a seed de cada lote, $T=80$ heartbeats). Valores: media de 4 corridas.

Métrica	EPR	EPR_Q	EPR_SHAM	LangGraph
Total debates	38.2	43.2	36.5	62.8
Densidad (deb./hb.)	0.48	0.54	0.46	0.79
Cuota máxima por agente	0.118	0.110	0.211	0.249
$\Delta\phi^*$	0.468	0.456	0.452	0.444
Déficit máximo (agente)	1.13	0.96	3.73	2.47
Nodos grafo	38.2	43.2	36.5	62.8
Consistency (IR)	1.00	1.00	1.00	0.00
Anomalías (deficit > 3)	0/4	0/4	3/4	1/4
Anomalías (monopol. > 0.25)	0/4	0/4	0/4	2/4

5.2 Pendientes temporales

Table 3. $\Delta\phi^*$ por ventana temporal (2^a seed de cada lote). Cinco ventanas de 16 ticks cada una. Degradación = $(w_0 - w_4)/w_0$.

Ventana	EPR	EPR_Q	EPR_SHAM	LangGraph
Ticks 0–15	0.493	0.501	0.453	0.487
Ticks 16–31	0.490	0.480	0.494	0.454
Ticks 32–47	0.456	0.448	0.454	0.436
Ticks 48–63	0.458	0.441	0.428	0.429
Ticks 64–79	0.450	0.423	0.432	0.420
Degradación	8.8%	15.6%	3.9%	13.9%
Slope $\Delta\phi^*$	−0.012	−0.019	−0.011	−0.016

Todos los modos muestran degradación temporal de $\Delta\phi^*$ — evidencia del colapso de contexto. EPR presenta la pendiente menos negativa (−0.012) con una degradación del 8.8%, frente a LangGraph (−0.016, 13.9%), apoyando H1. EPR_Q degrada más (15.6%, slope −0.019): el Q-learning no amortigua el colapso y podría amplificarlo al sobre-explotar argumentos de alta recompensa inicial. EPR_SHAM muestra degradación baja (3.9%) pero con alta varianza (rango −5.5% a 14.8%): el δ aleatorio produce trayectorias erráticas que oscurecen la señal. El colapso de contexto es parcialmente endógeno: el mecanismo de activación lo modula pero no lo elimina.

5.3 Juez LLM

Table 4. Puntajes del juez *preliminar* (1–5, ciego al modo). [Pendiente: evaluación offline con DeepSeek V4-Pro y GLM-5.2 tras completar las 20 seeds.]

Dimensión	EPR	LangGraph	p (Wilcoxon)
Calidad argumentativa	por calcular	por calcular	pendiente
Engagement	por calcular	por calcular	pendiente
Novelty	por calcular	por calcular	pendiente

5.4 Validación de conectividad

Table 5. Conectividad preliminar (2^a seed de cada lote).

Check	EPR	EPR_Q	EPR_SHAM	LangGraph
Nodos aislados (post-fix)	0%	0%	0%	0%
Grafo (nodos finales)	38.2	43.2	36.5	62.8
Grafo (aristas finales)	37.2	42.2	35.2	61.8
PRR_G	0.974	0.976	0.959	0.984

6 Discusión

[INTERPRETACIÓN PRELIMINAR — basada en la 2^a seed de cada lote (4 lotes, 8/20 seeds completadas). Análisis estadístico formal pendiente hasta completar las 20 seeds.]

Colapso de contexto (H1). La degradación temporal de $\Delta\phi^*$ mide el colapso de contexto: todos los modos degradan, pero a distintas tasas. EPR presenta la pendiente menos negativa (-0.012 , degradación 8.8%) frente a LangGraph (-0.016 , 13.9%), apoyando H1. EPR_Q degrada más (15.6%, slope -0.019): el Q-learning no amortigua el colapso y podría amplificarlo al sobre-explotar argumentos de alta recompensa inicial. EPR_SHAM muestra degradación aparentemente baja (3.9%) pero con alta varianza (rango -5.5% a 14.8%): el δ aleatorio produce trayectorias erráticas que oscurecen la señal. El colapso de contexto es parcialmente endógeno: el mecanismo de activación lo modula pero no lo elimina.

Distribución de turnos (H3). La señal más clara es la distribución de participación: EPR produce max-share 0.118 vs LangGraph 0.249 — una diferencia de $2.1\times$. Ningún agente monopoliza el piso conversacional bajo activación homeostática (0/4 lotes con max-share > 0.25). LangGraph muestra monopolización en 2 de 4 lotes (max-share hasta 0.284). EPR_Q es aún más equitativo (0.110), mientras que EPR_SHAM degrada la equidad (0.211). Esto sugiere que la activación endógena distribuye turnos orgánicamente.

Ablación sham: el loop importa. EPR_SHAM (con δ aleatorio) produce déficit explosivo (3.73 vs 1.13 para EPR), con anomalías ($\delta > 3$) en 3 de 4 lotes. La forma sigmoide sola no basta: el loop homeostático ($\delta \rightarrow$ activación $\rightarrow$ calidad $\rightarrow$ saciación) es lo que controla el déficit. Esto valida que el efecto de EPR no es artefacto de la no-linealidad del gate. Adicionalmente, EPR_SHAM degrada la equidad (max-share 0.211 vs 0.118), confirmando que sin drive epistémico real la activación se concentra.

Q-learning no aporta y podría perjudicar. EPR_Q (43.2 debates, déficit 0.96) vs EPR (38.2 debates, déficit 1.13): el Q-learner mejora marginalmente el control de déficit pero degrada más rápido (slope -0.019 vs -0.012 , degradación 15.6% vs 8.8%). La activación homeostática pura es suficiente para controlar el déficit y distribuir turnos; el Q-learning añade complejidad sin beneficio claro e incluso podría amplificar el colapso de contexto al sobre-explotar patrones iniciales exitosos.

LangGraph produce más volumen pero menos equitativo. LangGraph genera 62.8 debates vs 38.2 de EPR, pero con mayor concentración (max-share 0.249 vs 0.118) y mayor déficit máximo (2.47 vs 1.13). El router exógeno parece favorecer agentes “dominantes”: en 2 de 4 lotes un agente acapara $> 25\%$ de los turnos. Adicionalmente, LangGraph no mantiene consistencia de rol (IR = 0.00 vs 1.00 para EPR), indicando que los agentes cambian de subsystem bajo orquestación exógena.

Amenazas a la validez. Interna:

- Un solo LLM (DeepSeek V4-Flash); no se puede descartar dependencia del proveedor.
- RSVI está integrado al locus de control, no confundido con él. RSVI verbaliza el estado regulatorio δ_i que *drivea* la activación endógena; sin el loop homeostático no hay δ_i que se actualice ni nada que verbalizar. En LangGraph, la activación se decide fuera del agente por un router exógeno: inyectar RSVI significaría enviar un estado

regulatorio estático o ficticio que no drivea ninguna decisión — ruido puro, no un control válido. La comparación es entre dos arquitecturas completas (endógena con RSVI vs. exógena sin él), no entre “con RSVI” y “sin RSVI” como factores independientes. Esto refleja una decisión metodológica deliberada: evaluar el mecanismo endógeno completo frente al paradigma exógeno establecido.

- Los pesos del StimulusEvaluator se calibraron con seed independiente (grid 3×3 , $\alpha \in \{3, 4, 5\}$, $\lambda \in \{0.02, 0.03, 0.05\}$); diferente calibración podría cambiar el comportamiento de EPR, aunque el perfil *faction-dominant* fue seleccionado por estabilidad.
- $g \equiv \Delta\phi^*$ sirve simultáneamente como señal de saciedad interna (AAH-3) y como métrica diagnóstica externa. Esta circularidad parcial podría sesgar las métricas estructurales automatizadas a favor de EPR, cuyo loop está optimizado para reducir $\Delta\phi^*$. La mitigación principal son los jueces LLM offline ciegos al modo, cuya evaluación es matemáticamente independiente de g . Sin embargo, las métricas estructurales ($\Delta\phi^*$, slope, AAF) deben interpretarse con cautela hasta confirmar concordancia con los jueces.
- Resultados preliminares de 8/20 seeds (2ª seed de cada lote); poder estadístico limitado hasta completar las 20 seeds. Las diferencias entre EPR y LangGraph son consistentes en dirección pero requieren validación con $N=20$.

Estadística:

- $N=20$ seeds pareadas; Wilcoxon signed-rank como test primario (no-paramétrico, aprovecha el diseño pareado).
- Bonferroni con 3 hipótesis es conservador; Holm-Bonferroni como sensibilidad.
- Bootstrap 95% CIs (10.000 resamples) para intervalos.
- Las pendientes temporales requieren el conjunto completo de seeds para estimar con suficiente poder.

Externa:

- Estructura VSM es una de varias posibles; otras descomposiciones pueden producir dinámicas distintas.
- Un solo tópico de debate; efectos de tópico no controlados.
- 80 heartbeats; comportamiento asintótico no observable.
- Jueces LLM duales (DeepSeek V4-Pro + GLM-5.2); Cohen’s κ para concordancia. Validación humana planificada.

Trabajo futuro. Replicación multi-LLM (GLM-5.2, Claude); reasoning effort modulado por déficit ($\delta \rightarrow \text{reasoning_effort}$ en DeepSeek V4-Flash); drive metabólico para regular consumo de API ($\Gamma(n=2)$); dominios cooperativos; integración formal de DeLP (García & Simari, 2007).

7 Conclusiones

Presentamos un mecanismo de activación endógena para sistemas multi-agente de LLM basado en homeostasis epistémica, formalizado mediante los Axiomas de Autonomía Homeostática (AAH). La condición EPR ($\Gamma(n=1)$, sin Q-learning) aísla el aporte del mecanismo regulatorio básico: sigmoide, déficit y sensor estructural. El diseño experimental con 20 semillas pareadas (4 lotes de 5), 4 condiciones (EPR, EPR_Q, EPR_SHAM,

LangGraph), hiperparámetros calibrados con seed independiente, y jueces LLM duales ciegos al modo, permite aislar el efecto del locus de control. Los resultados preliminares (8/20 seeds) muestran que EPR distribuye turnos $2.1\times$ más equitativamente que LangGraph (max-share 0.118 vs 0.249), presenta menor colapso de contexto (slope -0.012 vs -0.016) y controla el déficit (1.13 vs 2.47). La ablación sham confirma que el loop homeostático — no sólo la forma del gate — es lo que controla el déficit (3.73 vs 1.13). El Q-learning no aporta beneficio claro y podría amplificar el colapso. **El análisis estadístico formal está pendiente hasta completar las 20 seeds.**

References

- Ashby, W. R. (1956). *An introduction to cybernetics*. Chapman & Hall.
- Becker, J., Kaesberg, L. B., Stephan, A., Wahle, J. P., Ruas, T., & Gipp, B. (2026). Stay focused: Problem drift in multi-agent debate. *Findings of the Association for Computational Linguistics (EACL 2026)*, 5068–5102. <https://doi.org/10.18653/v1/2026.findings-eacl.268>
- Beer, S. (1972). *Brain of the firm*. Allen Lane / The Penguin Press.
- Dung, P. M. (1995). On the acceptability of arguments and its fundamental role in nonmonotonic reasoning, logic programming and n-person games. *Artificial Intelligence*, 77(2), 321–357.
- Eslami, A., & Yu, J. (2026). A control-theoretic foundation for agentic systems. *arXiv preprint arXiv:2603.10779*. <https://doi.org/10.48550/arXiv.2603.10779>
- García, A. J., & Simari, G. R. (2007). Defeasible logic programming: DeLP. *Artificial Intelligence*, 171(2–3), 105–160.
- Hong, S., Zhuge, M., Chen, J., et al. (2024). MetaGPT: Meta programming for multi-agent collaborative framework. *Proceedings of the International Conference on Learning Representations (ICLR)*.
- Huang, J.-T., Zhou, J., Jin, T., Zhou, X., Chen, Z., Wang, W., Yuan, Y., Lyu, M., & Sap, M. (2025). On the resilience of LLM-based multi-agent collaboration with faulty agents. *Proceedings of the 42nd International Conference on Machine Learning (ICML)*, 267, 26202–26226.
- Keramati, M., & Gutkin, B. (2014). Homeostatic reinforcement learning for integrating reward collection and physiological stability. *eLife*, 3, e04811. <https://doi.org/10.7554/eLife.04811>
- Li, G., Hammoud, H. A., Itani, H., et al. (2023). CAMEL: Communicative agents for “mind” exploration of large language model society. *Advances in Neural Information Processing Systems (NeurIPS)*.
- OpenClaw Contributors. (2025). *OpenClaw gateway: Heartbeat*. <https://openclawlab.com/en/docs/gateway/heartbeat/>
- Park, J. S., O’Brien, J. C., Cai, C. J., et al. (2023). Generative agents: Interactive simulacra of human behavior. *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology (UIST)*. <https://doi.org/10.1145/3586183.3606763>
- Ryan, R. M., & Deci, E. L. (2001). *On happiness and human potentials: A review of research on hedonic and eudaimonic well-being*. Annual Review of Psychology.
- Snell, C., Lee, J., Xu, K., & Kumar, A. (2024). Scaling llm test-time compute optimally can be more effective than scaling model parameters. *arXiv preprint arXiv:2408.03314*.
- Sterling, P., & Eyer, J. (1988). Allostasis: A new paradigm to explain arousal pathology. *Handbook of Life Stress, Cognition and Health*, 629–649.
- Wang, Y., Chen, Y., Zhong, F., Ma, L., & Wang, Y. (2025). Simulating human-like daily activities with desire-driven autonomy. *Proceedings of the International Conference on Learning Representations (ICLR)*.

- Wu, Q., Bansal, G., Zhang, J., et al. (2023). AutoGen: Enabling next-gen LLM applications via multi-agent conversation. *Proceedings of the Workshop on Programming Language Design and Implementation (PLDI)*.
- Zhou, X., Zhu, H., Mathur, L., et al. (2024). SOTOPIA: Interactive evaluation for social intelligence in language agents. *Proceedings of the International Conference on Learning Representations (ICLR)*.