LangClaw: Endogenous Homeostatic Regulation for Mitigating Context Collapse in Multi-Agent LLM Debate Systems*

Abstract. Multi-agent LLM systems tend to lose coherence as interaction extends—a problem known as *context collapse*. Existing frameworks address this through static orchestration or periodic heartbeats, but both treat participation frequency as a design constant. We ask whether it can instead be an emergent property of each agent's internal regulatory state. We present LangClaw, a framework grounded in a formal theory of homeostatic agency in which each agent maintains an epistemic deficit $\delta_i \in [\varepsilon, \infty)$ governed by a drive function $D(\delta) = (\delta - \varepsilon)^2$; reward is defined as drive reduction, implementing the equivalence theorem of Keramati and Gutkin (2014). A multi-criteria stimulus evaluator acts as sensor; an online Q-learner with ε-greedy exploration selects actions via TD(0). This represents a structural departure from the prevailing heartbeat paradigm: rather than firing on a fixed schedule, agents activate when internal pressure warrants it and learn which actions most effectively reduce drive. We evaluate LangClaw against a LangGraph-style LLM router under equal heartbeat budgets in a zero-sum political debate with ten GPT-5-nano agents organized as two VSM-inspired factions, measuring discourse structure through AAF metrics, graph-structural peer reference, and the quality proxy $\Delta\varphi^*$. We report two complementary readings: a primary contrast on *endogenous activation* (frequency, distribution, and structural acceptance under equal time budget) and a separate diagnostic on the *closed regulatory loop* (whether the TD signal converges within the horizon). Preliminary, exploratory results (n=4 seed pairs, one more in progress) show HRRL produces 5.5× more debates with higher AAF acceptance (0.667 ± 0.029 vs 0.543 ± 0.025) and no silenced agents (vs 3.25 ± 0.96 in LangGraph); under a post-hoc volume-matched re-analysis the acceptance gap persists (+0.10) while the $\Delta\varphi^*$ gap collapses, suggesting the structural advantage is not merely an artefact of higher debate count. The TD loop did not converge within the run (mean reward negative; α sub-dimensioned for the final stimulus regime); we therefore separate the activation finding from the loop diagnostic and treat the comparison as exploratory.

Keywords: multi-agent systems , large language models , homeostatic reinforcement learning , context collapse , multi-agent debate , event-driven architecture

* Durante la preparación de este trabajo, los autores utilizaron GPT-5.4 con el fin de mejorar el lenguaje y la legibilidad del manuscrito. Tras utilizar esta herramienta, los autores revisaron y editaron el contenido según fue necesario y asumen plena responsabilidad por el contenido de la publicación. El detalle completo de tooling de IA empleado en investigación, desarrollo e ilustraciones se documenta en el repositorio del proyecto.

LangClaw: Regulación Homeostática Endógena para Mitigar el Colapso del Contexto en Sistemas de Debate Multi-Agente basados en LLM

Abstract. Los sistemas multi-agente de LLM tienden a perder coherencia a medida que la interacción se extiende—un problema conocido como *colapso del contexto*. Los enfoques actuales—enrutadores, grafos, heartbeats periódicos—ampliaron capacidades sin alterar un supuesto estructural: la frecuencia de participación es un parámetro exógeno, no una propiedad del agente. Este trabajo propone invertir ese supuesto. Inspirado en el aprendizaje por refuerzo homeostático (Keramati y Gutkin, 2014), cada agente mantiene un déficit epistémico $\delta_i \in [\varepsilon, \infty)$ gobernado por $D(\delta) = (\delta - \varepsilon)^2$; la recompensa es reducción de impulso $r_t = D(\delta_t) - D(\delta_{t+1})$. Un evaluador multicriterio actúa como sensor; un Q-learner con política ε-greedy selecciona acciones vía TD(0). La frecuencia de participación no se fija ni se enruta: *emerge*. Evaluamos LangClaw contra un enrutador al estilo LangGraph en un debate político con diez agentes GPT-5-nano organizados como dos facciones inspiradas en el VSM, midiendo coherencia argumentativa mediante métricas AAF, PRR_G y $\Delta\varphi^*$. Reportamos dos lecturas complementarias: un contraste primario sobre *activación endógena* (frecuencia, distribución y aceptación estructural bajo presupuesto temporal equivalente) y un diagnóstico separado sobre el *lazo regulatorio cerrado* (si la señal TD converge en el horizonte). Resultados preliminares y exploratorios (n=4 pares de semillas; una en curso) muestran que HRRL produce 5.5× más debates con mayor aceptación AAF (0.667 ± 0.029 vs 0.543 ± 0.025) y sin agentes silenciados (vs 3.25 ± 0.96 en LangGraph); bajo un re-análisis post-hoc emparejado por volumen la brecha en aceptación persiste (+0.10) mientras la brecha en $\Delta\varphi^*$ colapsa, sugiriendo que la ventaja estructural no es mero artefacto del mayor número de debates. El lazo TD no convergió en el horizonte (recompensa media negativa; α sub-dimensionado para el régimen final de estímulos); separamos deliberadamente el hallazgo de activación del diagnóstico del lazo y tratamos la comparación como exploratoria.

Keywords: sistemas multi-agente , modelos de lenguaje , aprendizaje por refuerzo homeostático , colapso del contexto , debate multi-agente , arquitectura dirigida por eventos

1 Introducción

Los sistemas multiagente basados en LLM comienzan a emplearse en procesos deliberativos de larga duración—análisis de políticas, revisión científica, toma de decisiones institucionales—donde la pérdida de coherencia no queda contenida en el software: una recomendación de política sostenida sobre un debate internamente viciado puede afectar a millones o una revisión científica basada en premisas alucinadas contamina la literatura sobre la que se construye más ciencia —un problema creciente— El escalamiento del cómputo en tiempo de inferencia (Snell et al., 2024) reabre una pregunta de asignación: dado un presupuesto fijo, ¿cómo conviene distribuirlo entre agentes?

A medida que la interacción se extiende, los agentes tienden a perder registro de argumentos previos, repetir puntos o producir monólogos desconectados (Park et al., 2023)—una clase de fallas conocida como *colapso del contexto*. En deliberación adversarial, donde cada argumento presupone lógicamente los anteriores, esta pérdida no degrada la calidad del debate: lo invalida, porque un agente que olvida qué concedió puede contradecir su propia línea argumentativa. Michels (Michels, 1915) observó una dinámica análoga en organizaciones humanas: la coordinación centralizada tiende a concentrar influencia hasta erosionar el proceso deliberativo mismo.

La respuesta hasta ahora ha seguido una progresión incremental. Una generación reciente de frameworks—AutoGen, CAMEL, MetaGPT (Hong et al., 2023; Li et al., 2023; Wu et al., 2023)—introdujo grafos de control y enrutadores centralizados que asignan turnos según el estado del flujo. LangGraph añadió estado durable y transiciones condicionales, dando al orquestador mayor expresividad. Más recientemente, el paradigma de *heartbeat* (OpenClaw Contributors, 2025) incorporó persistencia temporal: los agentes se activan periódicamente, mantienen memoria entre latidos y pueden sostener conversaciones largas. Esta contribución supuso un avance concreto, pero no alteró el supuesto estructural subyacente: la decisión de *cuándo* y *con qué frecuencia* participa cada agente sigue siendo exógena—un parámetro fijado por el diseñador, no una propiedad emergente del agente mismo. Si bien estos enfoques producen buenos resultados en tareas cortas, ninguno altera el supuesto subyacente: la decisión de activación permanece fuera del agente, lo que puede tratar el síntoma sin abordar la causa.

Un mecanismo bien establecido en biología describe cómo los sistemas regulan desequilibrios internos sin depender de control externo: la homeostasis (Sterling & Eyer, 1988). En ese dominio, variables internas acumulan tensión, desencadenan respuesta y retornan al equilibrio; HRRL (Keramati & Gutkin, 2014) formalizó este principio, demostrando que la recompensa puede entenderse como reducción de impulso. A primera vista, un mecanismo de regulación visceral parece ajeno al problema de coordinar agentes de software. Sin embargo, la analogía estructural es precisa: donde un organismo acumula hambre y actúa para reducirla, un agente deliberativo podría acumular *déficit epistémico* y actuar para reducirlo. Esto motiva una pregunta más amplia: ¿qué ocurriría si la coherencia en un sistema de debate multi-agente pudiera sostenerse endógenamente—no impuesta por un planificador, sino emergente del estado regulatorio de cada agente? Si la respuesta es afirmativa, muchas estrategias actuales podrían estar abordando el síntoma en lugar de la causa.

Exploramos esa pregunta mediante LangClaw, una estrategia de regulación endógena donde cada agente mantiene un déficit epistémico que crece al permanecer inactivo y decrece tras una contribución estructuralmente útil. Una compuerta sigmoide traduce el déficit en probabilidad de acción; un Q-learner en línea selecciona acciones y aprende de la reducción de impulso. La frecuencia de participación no se fija ni se enruta: *emerge*. Si bien existen paradigmas que incorporan algunos de sus ingredientes —persistencia temporal, memoria, aprendizaje in-context—, su articulación como principio de orquestación para agentes LLM de razonamiento permanece subexplorada.

De ahí, tres contribuciones: (1) una teoría formal de agencia homeostática que hace falsificables autonomía, impulso y descarga condicionada por calidad; (2) una estrategia de activación endógena donde la frecuencia de participación emerge del estado regula-

torio, en contraste estructural con el control exógeno prevalente; (3) una evaluación comparativa que explora si esa regulación produce mayor autonomía, coherencia y persistencia temporal que la orquestación exógena bajo condiciones equiparables.

2 Revisión bibliográfica

Orquestación exógena. Una primera línea contemporánea de trabajo en coordinación multiagente con LLM se apoyó en grafos de control y enrutadores centralizados. AutoGen (Wu et al., 2023), CAMEL (Li et al., 2023) y MetaGPT (Hong et al., 2023) demostraron que grupos de agentes de LLM con roles especializados podían abordar tareas complejas, pero dependiendo de estructuras de turno predefinidas. LangGraph consolidó este paradigma añadiendo estado durable y transiciones condicionales, otorgando al orquestador mayor expresividad sin alterar el principio subyacente: la decisión de activación permanece fuera del agente. Huang, Zhao, et al. (2025) muestran que esta forma organizacional afecta la resiliencia, con estructuras centralizadas degradándose más rápido bajo estrés; Becker, Kaesberg, et al. (2025) documentan que este deterioro suele tomar la forma de *problem drift* —pérdida progresiva de foco en debates extendidos.

Heartbeat y persistencia temporal. El paradigma (OpenClaw Contributors, 2025) extendió la persistencia con memoria entre latidos, sosteniendo interacciones largas; sin embargo la frecuencia de activación sigue siendo una constante del scheduler. El avance es temporal, no regulatorio.

Variables internas sin cierre regulatorio. Los agentes LLM dirigidos por deseo (Wang et al., 2025) reconocen que el estado interno debería importar, pero no cierran el lazo: carecen de señal explícita de calidad que module la activación y de un mecanismo de aprendizaje que ajuste la política.

Regulación homeostática. El formalismo que esos trabajos necesitan existe, pero proviene de otro dominio. El aprendizaje por refuerzo homeostático (HRRL) (Keramati & Gutkin, 2014) formalizó en neurociencia computacional la idea de que la recompensa es reducción de impulso, y variantes continuas extendieron esta dinámica al control de agentes artificiales (Laurençon et al., 2024). En el dominio LLM, trabajos recientes (Anonymous, 2026) formalizan el comportamiento agéntico como sistema de control en lazo cerrado a nivel de agente individual; sin embargo, la traslación al *orquestador* multi-agente —con un sensor de calidad estructural explícito que cierre el lazo regulatorio entre estado interno y decisión de activación— permanece subexplorada. Así, la pregunta que motiva este trabajo es: ¿pueden las variables internas de un agente gobernar su activación y aprendizaje en un lazo regulatorio matemáticamente explícito, cerrando el circuito que las propuestas anteriores dejan abierto?

Modelo de discurso. El lazo regulatorio requiere distinguir contribuciones integradas de monólogos aislados. Implementamos un *Abstract Argumentation Framework* (AAF) según Dung (Dung, 1995): nodos como argumentos, aristas como ataques, semántica fundamentada para aceptabilidad. El escenario adversarial se inspira en Sotopia (Zhou et al., 2024). Trabajos recientes combinaron AAF con LLMs para *resolver* conflictos (Anonymous, 2024); en LangClaw el AAF actúa como *sensor regulatorio* que retroalimenta la activación de agentes en orquestación adaptativa —rol no abordado

previamente. La integración formal de DeLP (García & Simari, 2004) queda como trabajo futuro.

3 Fundamentos teóricos y diseño del sistema

3.1 Teoría de agencia homeostática

Del mecanismo homeostático introducido previamente, se derivan tres postulados que fijan qué requiere la autonomía, qué desencadena la acción y qué hace valiosa una contribución; toda decisión de diseño posterior descansa sobre ellos. Denotamos esta teoría T_{HA}, con $P1$–$P3$ como base axiomática y $T1$ como teorema derivable.

Postulados. P1 (Autonomía (Ashby, 1956; Beer, 1972)). *¿Qué es autonomía?* Que la política del agente dependa de su estado interno:

$$\mathrm{Aut}(a_i) \iff \exists\, \delta_i \in S_L(a_i) : \ \pi_i = \pi_i\big(\delta_i(t)\big) \tag{1}$$

P2 (Impulso (Sterling & Eyer, 1988)). *¿Qué hace a un agente actuar?* Un impulso interno $D(\delta)$ que crece con el desvío del equilibrio ($D(\varepsilon) = 0$, $D'(\delta_i) > 0 \,\forall\, \delta_i > \varepsilon$), y una probabilidad de activación $p_i(t) = h(\delta_i(t))$ con h monótona creciente en δ_i. La instancia adoptada (Sec. 3) usa $h = \sigma \circ \ell$ con ℓ afín en δ_i (Ec. 4), preservando la monotonicidad exigida por P2.
P3 (Compuerta de calidad (Huta & Waterman, 2014; Ryan & Deci, 2001)). *¿Qué hace valiosa a una acción?* Un cambio efectivo en el estado del entorno regulado. Sea $g(e(t), e(t+1)) \geq 0$ la medida de ese cambio; el impulso decrece y la recompensa se define como *reducción de impulso*:

$$\delta_i^{(t+1)} \leq \delta_i^{(t)} - \alpha\, g\big(e(t), e(t+1)\big), \quad r_t \ = \ D(\delta_i^{(t)}) - D(\delta_i^{(t+1)}) \ \geq 0, \quad \alpha > 0 \tag{2}$$

T1 (Implicación derivada de P1–P3).

$$\delta_i(t) > \varepsilon \ \Rightarrow \ p_i(t) = h(\delta_i(t)), \ \ \tfrac{\partial p_i}{\partial \delta_i} > 0 \tag{P2}$$

$$\pi_i(t) = \pi_i\big(\delta_i(t)\big) \tag{P1}$$

$$r_t = D(\delta_i^{(t)}) - D(\delta_i^{(t+1)}) \ \geq \ 0 \tag{P3}$$

Bajo r acotado y tasa η_t con $\sum \eta_t = \infty$, $\sum \eta_t^2 < \infty$ (Robbins–Monro), la actualización TD(0) sobre $Q(\cdot)$ converge a un punto fijo del operador de Bellman y la política greedy resultante maximiza, en expectativa, la reducción de impulso (Keramati & Gutkin, 2014). La predicción que se sigue —bajo perturbaciones, con impulso creciente con el desvío y recompensa definida como reducción de impulso, emerge acción sostenida con probabilidad creciente en el déficit— es condicional a que se verifique la *premisa observable*: $r_t \geq 0$ en expectativa y señal TD efectiva durante el horizonte. Si esa premisa no se satisface empíricamente, lo que se observa es *activación endógena* sin cierre del lazo regulatorio (Sec. 5).

3.2 Algoritmos empleados para el aprendizaje local

Aquí se instancia T_{HA} en el dominio de nuestro experimento. El impulso interno de P2 se realiza como un *déficit epistémico* $\delta_i \in [\varepsilon, \infty)$ con línea base $\varepsilon = 0.1$ (fundamentado en HRRL (Keramati & Gutkin, 2014)); por P3, es valiosa toda acción que reduzca esa presión.

Dinámica del déficit. En cada heartbeat t actúan tres fuerzas: decaimiento basal $\delta^{(t+1)} = \delta^{(t)} + \lambda$ (Ec. 3, λ=0.05); estimulación por perturbaciones discursivas con relevancia r (Ec. 8), $\delta^{(t+)} = \delta^{(t)} + \gamma_{\text{stim}} \cdot r$ (γ_{stim}=0.1); y saciedad tras producir un argumento de calidad $\Delta\varphi^*$, $\delta^{\text{new}} = \max(\varepsilon, \delta - \alpha \cdot \Delta\varphi^*)$ con α por calibración (Sec. 4). Si $\Delta\varphi^*$=0, el déficit no decrece (P3): hablar sin integrarse no provee alivio.

$$\delta_i^{(t+1)} = \delta_i^{(t)} + \lambda \tag{3}$$

Activación. La probabilidad de actuar es sigmoide en el déficit:

$$p_i^{(t)} = \frac{1}{1 + e^{-k(\delta_i^{(t)} - \theta)}} \tag{4}$$

con k=10, θ=0.7. Por debajo de θ el agente descansa; por encima, la urgencia por participar crece.

Impulso y recompensa. Siguiendo a Keramati and Gutkin (2014), el impulso $D(\delta_i) = (\delta_i - \varepsilon)^m$ (m=2) penaliza desviaciones superlinealmente; la recompensa es reducción de impulso:

$$D(\delta_i) = (\delta_i - \varepsilon)^2, \quad r_t = D(\delta_t) - D(\delta_{t+1}) \tag{5}$$

Por el teorema de equivalencia (Keramati & Gutkin, 2014), una política que maximiza recompensa descontada minimiza impulso futuro esperado.

Q-Learning. Q-learning lineal con estado $\phi(s) = [\delta, \delta^2, \rho_G, n_{\text{stim}}]$, $Q(s,a) = \mathbf{w}_a^\top \phi(s)$ y TD(0):

$$\mathbf{w}_a \leftarrow \mathbf{w}_a + \eta \left[r + \gamma \max_{a'} Q(s', a') - Q(s,a) \right] \phi(s) \tag{6}$$

Pesos inicializados en cero; selección ε-greedy (ε=0.1). No se asume convergencia dentro del horizonte: los pesos son parámetros de control adaptativos. Esto extiende HRRL proyectando observables discursivos continuos a características acotadas para decidir entre acciones heterogéneas, conservando la recompensa como reducción de impulso (Ec. 5).

3.3 Grafo de argumentos y proxy Φ^*

P3 demanda una medida computable del cambio en el entorno regulado; como el problema es coherencia estructural y no fluidez, las métricas superficiales (BLEU, ROUGE, BERTScore) son inadecuadas. Se construye $\Delta\varphi^*$ sobre el grafo de discurso G=(V,E) con nodos como argumentos y aristas como ataques (Dung, 1995). Cuando el agente i agrega el nodo v atacando a u:

$$\Delta\varphi^* = \tfrac{1}{3} C_B(u) + \tfrac{1}{3} \nVdash_{\text{cycle}}(v,u) + \tfrac{1}{3} \operatorname{Div}(u) \tag{7}$$

donde $C_B(u)$ es centralidad de intermediación, $\mathbb{1}_{\text{cycle}}$ indica un nuevo ciclo dialéctico, y $\text{Div}(u)$ es diversidad de agentes que han atacado a u. La asignación uniforme $1/3$ corresponde a un prior no informativo (ausencia de evidencia previa para preferir un componente sobre otro); nodos aislados obtienen $\Delta\varphi^* = 0$. Notar que $\Delta\varphi^*$ funciona simultáneamente como *señal de entrenamiento* del Q-learner (entra en r_t vía la saciedad) y como *insumo descriptivo* para diagnóstico; por esa circularidad parcial, las métricas primarias de evaluación (Sec. 4) son estructuralmente independientes de $\Delta\varphi^*$ (aceptación AAF, PRR_G, σ_s).

3.4 Arquitectura propuesta del agente

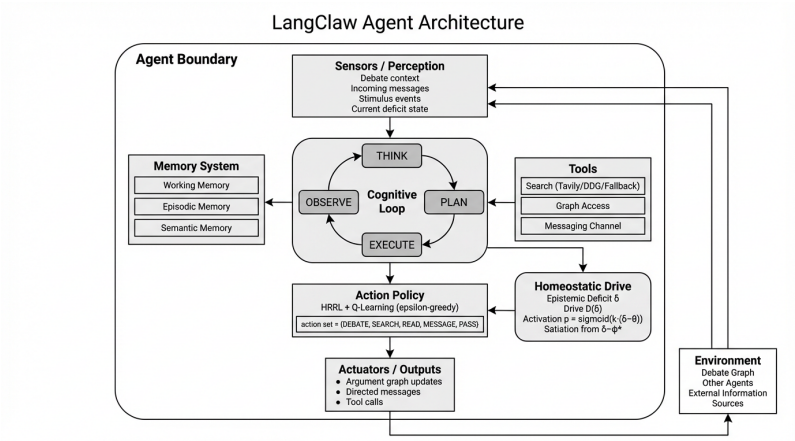

Fig. 1. Arquitectura del agente LangClaw: lazo cognitivo dirigido por eventos, memoria de tres capas, herramientas e impulso homeostático.

La arquitectura propuesta se sintetiza en la Figura 1. Dado el impulso y la señal de calidad, la propuesta requiere un espacio de acciones local y un sensor que vincule los eventos discursivos al estado interno. Cada agente selecciona entre cinco tipos de acción: **DEBATE** (producir un argumento), **SEARCH** (adquirir un hecho del dominio), **READ** (sintetizar el estado reciente del grafo), **MESSAGE** (enviar un acto comunicativo dirigido a un aliado específico), o **PASS** (descansar). Este conjunto de acciones es idéntico en HRRL y LangGraph; la diferencia radica en la activación, no en la capacidad local.

El *StimulusEvaluator* actúa como **sensor**: ante cada perturbación discursiva (`NewArgumentEvent`), computa relevancia según cinco criterios ponderados:

$$U(\text{stimulus}) = w_F \cdot F + w_C \cdot C_B(u) + w_M \cdot M + w_N \cdot N + w_P \cdot P, \tag{8}$$

con $w_F + w_C + w_M + w_N + w_P = 1$, donde F es relevancia faccional, $C_B(u)$ es centralidad del nodo atacado, M es relevancia de memoria estratégica, N es novedad, y P es presión sin respuesta. Los pesos no se fijan ad hoc: se parte de un prior de igual importancia y se calibran cinco perfiles alternativos por micro-simulación (Sección 4). La

calibración seleccionó un perfil *faction-dominant* (w_F=0.40, restantes 0.15), coherente con la estructura adversarial de suma cero.

El *Q-learner* actúa como **decisor**: tras pasar la compuerta sigmoide (Ec. 4), selecciona una acción vía ε-greedy ($\varepsilon = 0.1$; Sutton & Barto, 2018, §2.3) y actualiza pesos desde la recompensa homeostática (Ecs. 5, 6).

Impulso, señal de calidad, espacio de acciones, sensor y memoria se integran así en un único agente. Cada uno mantiene memoria episódica, semántica y de trabajo, respaldadas por `InMemoryStore` de LangGraph; ambas condiciones comparten esta infraestructura, aislando el mecanismo de orquestación como única variable experimental. Sobre esa base, cada agente combina percepción continua con deliberación por heartbeat: las perturbaciones discursivas (argumentos ajenos, mensajes directos) se observan y se acumulan en un buffer interno sin disparar cómputo deliberativo. En cada pulso, el agente drena el buffer, incrementa δ_i por decaimiento, puntúa cada perturbación (Ec. 8) para seleccionar la más relevante y recorre TRIAGE–THINK–PLAN–EXECUTE–OBSERVE sólo si la compuerta sigmoide (Ec. 4) habilita la ejecución. Saciedad y actualización TD cierran el lazo.

3.5 Diseño del sistema multi-agente

Del agente al sistema. El tamaño poblacional responde a un compromiso: debe ser suficiente para que emerjan dinámicas sociales, pero acotado por cómputo, tokens y llamadas a la API. Ambas condiciones comparten diez agentes en dos facciones espejo (Gobierno/Oposición), cada una con los cinco subsistemas del Modelo de Sistema Viable (Beer, 1972) (S1–S5; Fig. 2, Tabla 1): la *unidad mínima viable* para sostener regulación individual y observar regulación colectiva. La duplicación espejo introduce el antagonismo de suma cero.

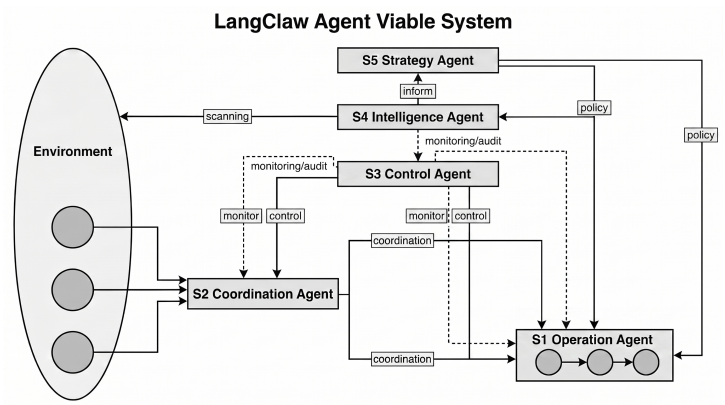

Fig. 2. Subsistemas VSM (S1–S5) que componen una facción; ambas facciones (Gobierno y Oposición) replican esta estructura espejada.

Table 1. Roles de los subsistemas VSM (espejados en ambas facciones).

VSM	Rol	Función principal
S1	Operaciones	Producir y defender argumentos; ejecutar tareas de debate.
S2	Coordinación	Sincronizar acciones aliadas; delegar tareas; enrutar información estratégica.
S3	Control	Auditar coherencia interna; detectar contradicciones; enviar mensajes correctivos.
S4	Inteligencia	Escanear al oponente; identificar amenazas; usar SEARCH para recursos externos.
S5	Estrategia	Fijar prioridades; resolver tensiones control–inteligencia; emitir directivas.

3.6 Estrategias de orquestación

Agente y sistema definidos, la variable experimental queda aislada: quién decide cuándo actúa un agente. Esto permite comparar dos estrategias de orquestación bajo capacidades locales equiparables. En la estrategia propuesta, **HRRL** (endógena), cada agente regula su ejecución mediante la compuerta sigmoide (Ec. 4) y selecciona acciones vía Q-learning (Ec. 6) con recompensa homeostática. En la línea base, **LangGraph** (exógena), un enrutador LLM neutral decide qué agente ingresa al lazo cognitivo en cada heartbeat; el agente seleccionado ejecuta las mismas capacidades locales. El prompt del enrutador recibe los últimos seis argumentos del grafo como texto plano y la lista de identificadores de agente —sin métricas estructurales— y devuelve el ID cuyo aporte *mejor avanza la discusión* (*round-robin* como fallback). Existe una **asimetría de información** de diseño: la sigmoide HRRL recibe δ_i modulado por StimulusEvaluator (cinco criterios estructurales), mientras el enrutador dispone sólo de texto. Esta asimetría corresponde al contraste endógeno/exógeno y se reconoce como parte del diseño, no como defecto del baseline.

4 Diseño experimental

4.1 Medidas de desempeño e hipótesis central

Definidas ambas estrategias bajo capacidades equiparables, queda especificar cómo distinguirlas empíricamente. Dado que el objetivo es evaluar autonomía y coherencia argumentativa en el tiempo, las medidas de desempeño más apropiadas son estructurales: el problema es la organización del debate, no la fluidez superficial. Operacionalizamos *colapso del contexto* como degradación estructural sostenida en el horizonte: pendiente negativa de la aceptación AAF, crecimiento de la dispersión de participación σ_s y/o concentración creciente de turnos en pocos agentes (silenciamiento). Las medidas: **Razón de aceptación AAF** (Dung, 1995): $\alpha = |G|/|A|$ (extensión fundamentada sobre total de argumentos; α=1: todos no derrotados; α=0: todos contestados). **PRR**$_G$ (variante grafo-estructural): fracción de turnos DEBATE cuyo `target_node_id` apunta a un nodo existente en el grafo, $\mathrm{PRR}_G = |\{d \in D : \mathrm{target}(d) \neq \emptyset\}|/|D|$; $\mathrm{PRR}_G = 0$ identifica monólogo paralelo, $\mathrm{PRR}_G = 1$ engagement total con argumentos previos. $\Delta\varphi^*$ (Ec. 7):

compromiso estructural por intervención; reportado de manera diagnóstica al ser también señal de entrenamiento (Sec. 3). **IR** (*validity check*, no comparación): razón de turnos homeostáticamente activados sobre turnos activos totales; IR=1.0 para HRRL, =0.0 para LangGraph por construcción. La medida primaria es la *degradación temporal*: pendiente de α a lo largo de los heartbeats; pendiente de $\Delta\varphi^*$ y σ_s como medidas secundarias.

Pregunta de investigación. Bajo capacidades locales equiparables y un horizonte extendido donde el enrutamiento exógeno (Snell et al., 2024) ha reportado degradación, ¿emergen diferencias sistemáticas en las trayectorias temporales de coherencia argumentativa, distribución de participación y calidad estructural entre un régimen de regulación endógena (HRRL) y uno de enrutamiento exógeno (LangGraph)? Formalmente, H_0: las trayectorias no difieren entre condiciones; H_1: existen diferencias atribuibles al mecanismo de activación. La métrica primaria es la degradación temporal; la foto final (Tabla 3) es diagnóstico secundario.

El contraste empírico se articula en tres dimensiones: distribución de participación (σ_s en ventanas temporales), calidad por intervención ($\Delta\varphi^*$ y su pendiente) y coherencia global del grafo (aceptación AAF y su pendiente), interpretadas a la luz de T1 (Sec. 3).

4.2 Configuración experimental

La Tabla 2 consolida los valores que gobiernan impulso, sigmoide y aprendizaje Q; sobre esa base distinguimos parámetros derivados matemáticamente, fijados por relevancia funcional o calibrados empíricamente.

Table 2. Hiperparámetros.

Parámetro	**Símbolo**	**Valor**
Tasa de decaimiento	λ	0.05
Pendiente sigmoide	k	10
Umbral de activación	θ	0.7
Tasa de saciedad	α	3.0 (calibrado de $\{1,2,3\}$)
Ganancia de estímulo	γ	0.1
Línea base / déficit inicial	ε, δ_0	0.1, 0.5
Exponente de impulso	m	2
Tasa de aprendizaje Q	η	0.01
Tasa de exploración	$\varepsilon_{\mathrm{RL}}$	0.1
Factor de descuento	γ_{RL}	0.95
Pesos de estímulo	$(w_F, w_C, w_M, w_N, w_P)$	$(0.40, 0.15, 0.15, 0.15, 0.15)$
Heartbeats máx / agentes	T, N	80, 10
LLM	—	GPT-5-nano (OpenAI, 2025)
Semillas	s	$\{7, 17, 42, 123, 256\}$

Parámetros derivados matemáticamente (ε=0.1; m=2 caso cuadrático de Keramati & Gutkin Keramati and Gutkin, 2014) o por relevancia funcional (λ=0.05: $\sim$14 heartbeats hasta θ; θ=0.7, k=10, γ_{stim}=0.1). Q-learning TD(0) estándar (η=0.01, γ_{RL}=0.95, $\varepsilon_{\mathrm{RL}}$=0.1) con clipping de TD-error a ± 1, clipping de pesos a ± 5 y L_2=10^{-4} (estabilización numérica). $\phi(s)$ usa cinco features $[\hat{\delta}, \hat{\delta}^2, \hat{\rho}_G, \hat{n}_{\mathrm{stim}}, \hat{n}_{\mathrm{msg}}] \in [0,1]^5$; DEBATE

se especializa en `DEBATE_STIMULUS/DEBATE_PROACTIVE` según buffer; PASS es no-activación de la sigmoide, no acción del learner. α y pesos de estímulo calibrados empíricamente (Sec. 4). **LLM**: GPT-5-nano, `max_tokens=50000`, `timeout=60s`, cinco intentos con backoff, `semaphore=2`.

4.3 Optimización de hiperparámetros

Los únicos parámetros sin prior teórico —tasa de saciedad α y pesos de estímulo $(w_F, w_C, w_M, w_N, w_P)$— se calibran por ablación de 15 micro-simulaciones (10 heartbeats HRRL, s=42) que cruza cinco perfiles de pesos (*equal*, *faction-dominant* w_F=0.40, *centrality-dominant*, *novelty-dominant*, *pressure-dominant*) con $\alpha \in \{1,2,3\}$. La configuración ganadora —ordenada por $\overline{\Delta\varphi^*}$ con consistencia como desempate— resultó *faction-dominant*, α=3.0 ($\overline{\Delta\varphi^*}$=0.136, consistencia 97.2% en 36 debates), seguida de *novelty-dominant* (α=1) y *faction-dominant* (α=2): duplicar el peso faccional alinea el sensor con la estructura adversarial y α alto amplifica la saciedad por unidad de $\Delta\varphi^*$. Las salidas imponen esquema JSON Pydantic con penalización de $+0.1$ tras dos reintentos; una fábrica deriva semillas primas vía SHA-256 para reproducibilidad y las pruebas usan Wilcoxon *signed-rank* bilateral con corrección de Bonferroni e intervalos *bootstrap* (1000 resamples). **Fuga parcial.** La calibración usó seed=42, que también integra el conjunto de evaluación; $\{7, 17, 123, 256\}$ son *held-out*. La fuga es parcial (1/5) y se reporta explícitamente; *leave-one-out* queda como trabajo futuro.

5 Resultados

5.1 Métricas de resultado

El heartbeat opera como discretización temporal uniforme: ambas condiciones disponen del mismo número de tics, mismo horizonte y mismo presupuesto de tokens y llamadas a la API. La diferencia en *densidad deliberativa* (debates por heartbeat) refleja, por construcción, capacidad endógena de auto-activación bajo presión epistémica, no un ajuste de presupuesto. La comparación de calidad se realiza, en consecuencia, sobre métricas estructurales normalizadas por intervención ($\overline{\Delta\varphi^*}$, aceptación AAF, PRR_G), de modo que diferencias en densidad no contaminen la comparación de coherencia agregada.

La primera verificación es estructural: IR $= 1.0$ para HRRL y 0.0 para LangGraph confirma que las condiciones son funcionalmente distintas. La Tabla 3 agrega los cuatro primeros pares de semillas $\{7, 17, 42, 123\}$; la quinta ($\{256\}$) está en ejecución. A continuación se interrogan los datos.

¿Quién habla? T1 predice activación sostenida en todo agente con $\delta_i > \varepsilon$; aplicada a una población con impulsos simétricos, implica distribución emergente de la participación: el impulso acumulado empuja a actuar a quien se silencia. Bajo HRRL los 10 agentes debaten en las cuatro semillas ($\sigma_s = 6.73 \pm 1.86$, ningún agente con cero turnos). Bajo LangGraph 3.25 ± 0.96 agentes no intervienen y el más activo concentra $36.1\% \pm 6.0\%$ de los debates (vs $12.4\% \pm 0.5\%$ en HRRL); los silenciados acumulan déficits de $\sim 10 \times \theta$ que el enrutador no corrige.

Table 3. Resultados preliminares (n=4 pares de semillas $\{7, 17, 42, 123\}$, $T = 80$ heartbeats; semilla 256 en curso). Valores: media $\pm$ desviación (muestral). Las métricas de calidad están normalizadas por intervención.

Métrica	**HRRL**	**LangGraph**
Total debates	383.8 ± 6.9	70.5 ± 5.9
Densidad deliberativa (deb./hb.)	4.80	0.88
Ratio de volumen HRRL/LG	5.48 ± 0.51	
σ_s por agente	6.73 ± 1.86	8.96 ± 1.53
Agentes silenciados (de 10)	0.00 ± 0.00	3.25 ± 0.96
Cuota máxima por agente	0.124 ± 0.005	0.361 ± 0.060
Razón de aceptación AAF	0.667 ± 0.029	0.543 ± 0.025
PRR_G	0.990 ± 0.001	0.986 ± 0.001
$\overline{\Delta\varphi^*}$ por debate	0.123 ± 0.025	0.103 ± 0.018
Pendiente $\Delta\varphi^*$ (por ventana)	$+0.009 \pm 0.011$	-0.019 ± 0.003
Pendiente aceptación	$+0.003 \pm 0.011$	-0.003 ± 0.003
IR (verificación)	1.0	0.0
Recompensa media	-2.03 ± 0.38	$+0.41 \pm 0.07$

¿La cantidad sacrifica calidad? Bajo el mismo presupuesto temporal HRRL exhibe 5.5$\times$ mayor densidad deliberativa. La pregunta relevante no es si genera más, sino si esa densidad degrada la calidad agregada por intervención. La respuesta es matizada: $\overline{\Delta\varphi^*}$ por debate es ligeramente superior agregado (0.123 vs 0.103), pero el **re-análisis post-hoc *volume-matched*** (Sec. siguiente) muestra que esa ventaja se debe parcialmente al mayor volumen. La trayectoria temporal sí favorece a HRRL: pendiente de $\Delta\varphi^*$ positiva en HRRL ($+0.009 \pm 0.011$) y persistentemente negativa en LangGraph (-0.019 ± 0.003). El enrutador se agota; la regulación endógena sostiene calidad mientras escala densidad.

¿Más argumentos implican más refutación? Intuitivamente, quintuplicar los debates debería reducir la aceptación. Ocurre lo contrario: HRRL agregada 0.667 ± 0.029 vs LangGraph 0.543 ± 0.025. La participación distribuida no degrada la estructura del grafo: la fortalece.

¿Opera el mecanismo en su régimen teórizado? Honest split. La activación *endógena* opera (sigmoide dispara, IR=1.0, los 10 agentes participan); el *lazo TD* no cierra como predice T1: la recompensa media en HRRL es -2.03 ± 0.38 (n=4), violando $r_t \geq 0$ esperado, mientras LangGraph se mantiene en $+0.41 \pm 0.07$. En HRRL los déficits finales muestran asimetría faccional (GOV: 13–20; OPP: 0.1–6.1, semilla 7). La calibración de α se hizo antes de activar la difusión completa de eventos y quedó sub-dimensionada (Sec. 4). Las métricas macro mejoran aún bajo este régimen subóptimo, sugiriendo robustez del efecto emergente con una política Q no convergida.

¿Se puede confiar en estos patrones? Con n=4 la potencia inferencial sigue limitada, pero la consistencia direccional es estricta: los cuatro pares favorecen a HRRL en aceptación AAF, distribución de participación y densidad. Wilcoxon signed-rank bilateral pareado arroja p=0.125 —límite teórico para n=4 con todos los signos alineados— por lo que el test no rechaza H_0 pero tampoco compite con la señal. Un **re-análisis post-hoc *volume-matched*** (truncando HRRL a $K{=}N_{\mathrm{LangGraph}} \approx 70$ debates por semilla) preserva la brecha en aceptación AAF ($\Delta\bar{\alpha} \approx +0.10$; 0.646 ± 0.037 vs 0.543 ± 0.025)

y *colapsa* la brecha en $\overline{\Delta\varphi^*}$ (0.096 ± 0.003 vs 0.103 ± 0.018), que oscila signo entre semillas: la ventaja estructural en aceptación no es artefacto de más turnos; la ventaja en $\Delta\varphi^*$ agregado depende parcialmente del volumen.

6 Discusión

6.1 Interpretación de los resultados

Mecánica y emergencia. El balance (σ_s: 6.73 ± 1.86 vs 8.96 ± 1.53) emerge de la simetría del impulso, no fue diseñado; la concentración bajo LangGraph (36% en un solo agente) evoca la oligarquía de Michels (Michels, 1915). Quintuplicar la actividad *fortalece* el grafo (α: 0.667 vs 0.543): la diversidad de atacantes estabiliza la extensión fundamentada, análogo a la variedad requerida (Ashby, 1956). El *mecanismo* fue diseñado exógenamente; lo endógeno es la *dinámica* que emerge una vez instanciada, aunque el régimen oscilatorio predicho requiere recalibración bajo el flujo real.

Limitaciones. n=5 semillas exploratorio (efectos grandes); calibración con una semilla y flujo de estímulos parcial, dejando α sub-dimensionado (recompensa negativa); Q adaptativo, no convergido; pesos de $\Delta\varphi^*$ prior principiado sin validar; resultados específicos a GPT-5-nano; mecanismo potencialmente explotable por argumentos estructuralmente ubicados pero semánticamente vacíos.

Trabajo futuro. (i) umbral de diversidad de atacantes que estabilice la extensión fundamentada; (ii) integrar DeLP (García & Simari, 2004) para garantías y derrotabilidad explícita; (iii) validación cruzada de calibración, sensibilidad de θ, α, λ y escalamiento poblacional (Snell et al., 2024); (iv) LLM-as-judge con rúbrica multi-criterio AHP (Lu, Li, et al., 2024; Saaty, 1980), dos jueces independientes bajo evaluación ciega y Krippendorff α ordinal.

7 Conclusiones

LangClaw pregunta si el colapso del contexto en debate multi-agente LLM se aborda mejor por planificación externa o regulación endógena. Bajo presupuesto temporal equiparable, los resultados preliminares muestran que HRRL exhibe mayor densidad deliberativa, distribuye la participación sin enrutador externo y sostiene mejor coherencia estructural agregada (la brecha en aceptación AAF persiste tras emparejar volumen). El hallazgo más inesperado —el aumento monotónico de aceptación pese a mayor densidad— sugiere que la diversidad de participación puede estabilizar la estructura argumentativa aún bajo calibración subóptima. El aporte es también metodológico: una forma testeable de preguntar si la coherencia en MAS puede ser propiedad autoorganizada.

Reproducibilidad

Código e instrucciones de reproducibilidad: https://github.com/pgerpe/langclaw_experiment

References

Anonymous. (2024). Enhancing conflict resolution in language models via abstract argumentation [arXiv:2412.16725]. *arXiv preprint*. https://arxiv.org/abs/2412.16725

Anonymous. (2026). A control-theoretic foundation for agentic systems [arXiv:2603.10779]. *arXiv preprint*. https://arxiv.org/abs/2603.10779

Ashby, W. R. (1956). *An introduction to cybernetics*. Chapman & Hall.

Becker, J., Kaesberg, L. B., et al. (2025). Stay focused: Problem drift in multi-agent debate [arXiv:2502.19559; Accepted at EACL 2026 Findings]. *arXiv preprint*. https://arxiv.org/abs/2502.19559

Beer, S. (1972). *Brain of the firm*. Allen Lane / The Penguin Press.

Dung, P. M. (1995). On the acceptability of arguments and its fundamental role in nonmonotonic reasoning, logic programming and n-person games. *Artificial Intelligence*, *77*(2), 321–357.

García, A. J., & Simari, G. R. (2004). Defeasible logic programming: An argumentative approach. *Theory and Practice of Logic Programming*, *4*(1–2), 95–138. https://doi.org/10.1017/S1471068403001674

Hong, S., Zhuge, M., Chen, J., Zheng, X., Cheng, Y., Zhang, C., Wang, J., Wang, Z., Yau, S. K. S., Lin, Z., et al. (2023). MetaGPT: Meta programming for a multi-agent collaborative framework [arXiv:2308.00352]. *arXiv preprint*.

Huang, H., Zhao, Q., et al. (2025). On the resilience of LLM-based multi-agent collaboration with faulty agents [arXiv:2408.00989]. *Proceedings of the International Conference on Machine Learning (ICML)*.

Huta, V., & Waterman, A. S. (2014). Eudaimonia and its distinction from hedonia: Developing a classification and terminology for understanding conceptual and operational definitions. *Journal of Happiness Studies*, *15*(6), 1425–1456.

Keramati, M., & Gutkin, B. (2014). Homeostatic reinforcement learning for integrating reward collection and physiological stability. *eLife*, *3*, e04811. https://doi.org/10.7554/eLife.04811

Laurençon, H., et al. (2024). Continuous time continuous space homeostatic reinforcement learning: Towards biological self-autonomous agents [arXiv:2401.08999]. *arXiv preprint*.

Li, G., Hammoud, H., Itani, H., Khizbullin, D., & Ghanem, B. (2023). CAMEL: Communicative agents for "mind" exploration of large language model society. *Advances in Neural Information Processing Systems (NeurIPS)*.

Lu, X., Li, J., et al. (2024). AHP-powered LLM reasoning for multi-criteria evaluation of open-ended responses [arXiv:2410.01246]. *Findings of the Association for Computational Linguistics: EMNLP 2024*. https://arxiv.org/abs/2410.01246

Michels, R. (1915). *Political parties: A sociological study of the oligarchical tendencies of modern democracy* [Trans. E. Paul and C. Paul; original German edition 1911]. Hearst's International Library.

OpenAI. (2025). GPT-5 nano [Model: gpt-5-nano-2025-08-07. Released August 7, 2025]. https://platform.openai.com/docs/models/gpt-5-nano

OpenClaw Contributors. (2025). OpenClaw gateway: Heartbeat [Accessed: April 2026]. https://openclawlab.com/en/docs/gateway/heartbeat/

Park, J. S., O'Brien, J. C., Cai, C. J., Morris, M. R., Liang, P., & Bernstein, M. S. (2023). Generative agents: Interactive simulacra of human behavior. *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology (UIST)*. https://doi.org/10.1145/3586183.3606763

Ryan, R. M., & Deci, E. L. (2001). On happiness and human potentials: A review of research on hedonic and eudaimonic well-being. *Annual Review of Psychology*, *52*, 141–166.

Saaty, T. L. (1980). *The analytic hierarchy process: Planning, priority setting, resource allocation*. McGraw-Hill.

Snell, C., Lee, J., Xu, K., & Kumar, A. (2024). Scaling LLM test-time compute optimally can be more effective than scaling model parameters [arXiv:2408.03314]. *arXiv preprint*.

Sterling, P., & Eyer, J. (1988). Allostasis: A new paradigm to explain arousal pathology. In S. Fisher & J. Reason (Eds.), *Handbook of life stress, cognition and health* (pp. 629–649). Wiley.

Wang, Z., et al. (2025). Simulating human-like daily activities with desire-driven autonomy [arXiv:2412.06435]. *Proceedings of the International Conference on Learning Representations (ICLR)*.

Wu, Q., Bansal, G., Zhang, J., Wu, Y., Li, B., Zhu, E., Jiang, L., Zhang, X., Zhang, S., Liu, J., Awadallah, A. H., White, R. W., Burger, D., & Wang, C. (2023). AutoGen: Enabling next-gen LLM applications via multi-agent conversation [arXiv:2308.08155]. *arXiv preprint*.

Zhou, X., Zhu, H., Mathur, L., Zhang, R., Yu, H., Qi, Z., Morency, L.-P., Bisk, Y., Fried, D., Neubig, G., & Sap, M. (2024). SOTOPIA: Interactive evaluation for social intelligence in language agents. *Proceedings of the International Conference on Learning Representations (ICLR)*.