LangClaw: Endogenous Homeostatic Regulation for Mitigating Context Collapse in Multi-Agent LLM Debate Systems*

Abstract. Multi-agent LLM systems tend to lose coherence as interaction extends—a problem known as *context collapse*. Existing frameworks address it through static orchestration or periodic heartbeats, treating participation frequency as a design constant. We ask whether it can instead emerge from each agent's internal regulatory state. We present **LangClaw**, a framework that instantiates homeostatic reinforcement learning (Keramati & Gutkin, 2014) on LLM-based agents: every agent maintains an epistemic deficit δ_i governed by a drive $D(\delta) = (\delta - \varepsilon)^2$, reward is defined as drive reduction, a multi-criteria stimulus evaluator acts as a sensor, and an online Q-learner with linear function approximation selects actions via TD(0). We compare LangClaw against a LangGraph-style LLM router under equal heartbeat budgets in a zero-sum political debate with ten GPT-5-nano agents organised as two VSM-inspired factions (n=5 seed pairs), and include an ablation that disables the Q-learner while keeping the rest of the homeostatic machinery intact. The empirical contribution that survives adversarial scrutiny is a **volume-matched gap in AAF acceptance** ($\approx +0.10$ in favour of HRRL), which persists after truncating HRRL debates to the LangGraph budget; the raw $5.5\times$ density gap and the $\Delta\varphi^*$ slopes are reported as descriptive, not as primary claims. The TD loop did not converge within the horizon (linear function approximation, deadly-triad regime), so we treat the activation finding as separate from the learning diagnostic. Results are exploratory and consistent with the hypothesis that endogenous regulation buffers context collapse better than exogenous routing under matched local capabilities.

Keywords: multi-agent systems , large language models , homeostatic reinforcement learning , context collapse , multi-agent debate , event-driven architecture

* Dos modelos distintos intervienen en este trabajo y conviene separarlos. **GPT-5.4** se empleó exclusivamente como herramienta de *redacción* para mejorar el lenguaje y la legibilidad del manuscrito; los autores revisaron y editaron el contenido y asumen plena responsabilidad. Los *experimentos* se ejecutan en **GPT-5-nano**: todos los agentes deliberativos, el enrutador LangGraph y los módulos auxiliares comparten ese mismo modelo. El detalle completo de tooling de IA empleado en investigación, desarrollo e ilustraciones se documenta en el repositorio del proyecto.

LangClaw: Regulación Homeostática Endógena para Mitigar el Colapso del Contexto en Sistemas de Debate Multi-Agente basados en LLM

Abstract. Los sistemas multi-agente de LLM tienden a perder coherencia a medida que la interacción se extiende—un problema conocido como *colapso del contexto*. Los enfoques actuales (enrutadores, grafos, heartbeats periódicos) tratan la frecuencia de participación como un parámetro exógeno. Nos preguntamos si puede, en cambio, emerger del estado regulatorio interno de cada agente. Presentamos **LangClaw**, un marco que instancia aprendizaje por refuerzo homeostático (Keramati & Gutkin, 2014) sobre agentes basados en LLM: cada agente mantiene un déficit epistémico δ_i gobernado por $D(\delta) = (\delta - \varepsilon)^2$, la recompensa es reducción de impulso, un evaluador multicriterio actúa como sensor, y un Q-learner con aproximación lineal de funciones selecciona acciones vía TD(0). Comparamos LangClaw contra un enrutador al estilo LangGraph bajo presupuesto temporal equiparable en un debate político de suma cero con diez agentes GPT-5-nano organizados como dos facciones inspiradas en el VSM (n=5 pares de semillas), e incluimos una ablación que desactiva el Q-learner manteniendo intacto el resto del mecanismo homeostático. La contribución empírica que sobrevive un escrutinio adverso es una **brecha de aceptación AAF emparejada por volumen** ($\approx +0.10$ a favor de HRRL), que persiste tras truncar los debates HRRL al presupuesto de LangGraph; la brecha bruta de 5.5$\times$ en densidad y las pendientes de $\Delta\varphi^*$ se reportan como descriptivas, no como afirmaciones primarias. El lazo TD no converge en el horizonte (aproximación lineal, régimen de la *tríada mortal*), por lo que tratamos el hallazgo de activación como separado del diagnóstico del aprendizaje. Los resultados son exploratorios y consistentes con la hipótesis de que la regulación endógena amortigua mejor el colapso de contexto que el enrutamiento exógeno bajo capacidades locales equiparables.

Keywords: sistemas multi-agente , modelos de lenguaje , aprendizaje por refuerzo homeostático , colapso del contexto , debate multi-agente , arquitectura dirigida por eventos

1 Introducción

Los sistemas multiagente basados en LLM comienzan a emplearse en procesos deliberativos de larga duración—análisis de políticas, revisión científica, toma de decisiones institucionales—donde la pérdida de coherencia no queda contenida en el software: una recomendación de política sostenida sobre un debate internamente viciado puede afectar a millones o una revisión científica basada en premisas alucinadas contamina la literatura sobre la que se construye más ciencia —un problema creciente— El escalamiento del cómputo en tiempo de inferencia (Snell et al., 2024) reabre una pregunta de asignación: dado un presupuesto fijo, ¿cómo conviene distribuirlo entre agentes?

A medida que la interacción se extiende, los agentes tienden a perder registro de argumentos previos, repetir puntos o producir monólogos desconectados (Park et al., 2023)—una clase de fallas conocida como *colapso del contexto*. En deliberación adversarial, donde cada argumento presupone lógicamente los anteriores, esta pérdida no

degrada la calidad del debate: lo invalida, porque un agente que olvida qué concedió puede contradecir su propia línea argumentativa. Michels (Michels, 1915) observó una dinámica análoga en organizaciones humanas: la coordinación centralizada tiende a concentrar influencia hasta erosionar el proceso deliberativo mismo.

La respuesta hasta ahora ha seguido una progresión incremental. Una generación reciente de frameworks—AutoGen, CAMEL, MetaGPT (Hong et al., 2023; G. Li et al., 2023; Wu et al., 2023)—introdujo grafos de control y enrutadores centralizados que asignan turnos según el estado del flujo. LangGraph añadió estado durable y transiciones condicionales, dando al orquestador mayor expresividad. Más recientemente, el paradigma de *heartbeat* (OpenClaw Contributors, 2025) incorporó persistencia temporal: los agentes se activan periódicamente, mantienen memoria entre latidos y pueden sostener conversaciones largas. Esta contribución supuso un avance concreto, pero no alteró el supuesto estructural subyacente: la decisión de *cuándo* y *con qué frecuencia* participa cada agente sigue siendo exógena—un parámetro fijado por el diseñador, no una propiedad emergente del agente mismo. Si bien estos enfoques producen buenos resultados en tareas cortas, ninguno altera el supuesto subyacente: la decisión de activación permanece fuera del agente, lo que puede tratar el síntoma sin abordar la causa.

Un mecanismo bien establecido en biología describe cómo los sistemas regulan desequilibrios internos sin depender de control externo: la homeostasis (Sterling & Eyer, 1988). En ese dominio, variables internas acumulan tensión, desencadenan respuesta y retornan al equilibrio; HRRL (Keramati & Gutkin, 2014) formalizó este principio, demostrando que la recompensa puede entenderse como reducción de impulso. A primera vista, un mecanismo de regulación visceral parece ajeno al problema de coordinar agentes de software. Sin embargo, la analogía estructural es precisa: donde un organismo acumula hambre y actúa para reducirla, un agente deliberativo podría acumular *déficit epistémico* y actuar para reducirlo. Esto motiva una pregunta más amplia: ¿qué ocurriría si la coherencia en un sistema de debate multi-agente pudiera sostenerse endógenamente—no impuesta por un planificador, sino emergente del estado regulatorio de cada agente? Si la respuesta es afirmativa, muchas estrategias actuales podrían estar abordando el síntoma en lugar de la causa.

Exploramos esa pregunta mediante LangClaw, una estrategia de regulación endógena donde cada agente mantiene un déficit epistémico que crece al permanecer inactivo y decrece tras una contribución estructuralmente útil. Una compuerta sigmoide traduce el déficit en probabilidad de acción; un Q-learner en línea selecciona acciones y aprende de la reducción de impulso. La frecuencia de participación no se fija ni se enruta: *emerge*. Si bien existen paradigmas que incorporan algunos de sus ingredientes —persistencia temporal, memoria, aprendizaje in-context—, su articulación como principio de orquestación para agentes LLM de razonamiento permanece subexplorada.

De ahí, tres contribuciones: (1) una teoría formal de agencia homeostática que hace falsificables autonomía, impulso y descarga condicionada por calidad; (2) una estrategia de activación endógena donde la frecuencia de participación emerge del estado regulatorio, en contraste estructural con el control exógeno prevalente; (3) una evaluación comparativa que explora si esa regulación produce mayor autonomía, coherencia y persistencia temporal que la orquestación exógena bajo condiciones equiparables.

2 Revisión bibliográfica

Orquestación exógena. Una primera línea contemporánea de trabajo en coordinación multiagente con LLM se apoyó en grafos de control y enrutadores centralizados. AutoGen (Wu et al., 2023), CAMEL (G. Li et al., 2023) y MetaGPT (Hong et al., 2023) demostraron que grupos de agentes de LLM con roles especializados podían abordar tareas complejas, pero dependiendo de estructuras de turno predefinidas. LangGraph consolidó este paradigma añadiendo estado durable y transiciones condicionales, otorgando al orquestador mayor expresividad sin alterar el principio subyacente: la decisión de activación permanece fuera del agente. Huang, Zhao, et al. (2025) muestran que esta forma organizacional afecta la resiliencia, con estructuras centralizadas degradándose más rápido bajo estrés; Becker, Kaesberg, et al. (2025) documentan que este deterioro suele tomar la forma de *problem drift* —pérdida progresiva de foco en debates extendidos.

Heartbeat y persistencia temporal. El paradigma (OpenClaw Contributors, 2025) extendió la persistencia con memoria entre latidos, sosteniendo interacciones largas; sin embargo la frecuencia de activación sigue siendo una constante del scheduler. El avance es temporal, no regulatorio. LangClaw se construye sobre el *heartbeat* de OpenClaw— adoptando su pulso periódico como sustrato temporal— pero introduce un cierre regulatorio endógeno (déficit, sigmoide, sensor) que decide *si* actuar en cada latido; la contribución teórica y empírica reportada aquí es original.

Variables internas sin cierre regulatorio. Los agentes LLM dirigidos por deseo (Wang et al., 2025) reconocen que el estado interno debería importar, pero no cierran el lazo: carecen de señal explícita de calidad que module la activación y de un mecanismo de aprendizaje que ajuste la política.

Regulación homeostática. El formalismo que esos trabajos necesitan existe, pero proviene de otro dominio. El aprendizaje por refuerzo homeostático (HRRL) (Keramati & Gutkin, 2014) formalizó en neurociencia computacional la idea de que la recompensa es reducción de impulso, y variantes continuas extendieron esta dinámica al control de agentes artificiales (Laurençon et al., 2024). En el dominio LLM, trabajos recientes (Eslami & Yu, 2026) formalizan el comportamiento agéntico como sistema de control en lazo cerrado a nivel de agente individual; sin embargo, la traslación al *orquestador* multi-agente —con un sensor de calidad estructural explícito que cierre el lazo regulatorio entre estado interno y decisión de activación— permanece subexplorada. Así, la pregunta que motiva este trabajo es: ¿pueden las variables internas de un agente gobernar su activación y aprendizaje en un lazo regulatorio matemáticamente explícito, cerrando el circuito que las propuestas anteriores dejan abierto?

Modelo de discurso. El lazo regulatorio requiere distinguir contribuciones integradas de monólogos aislados. Implementamos un *Abstract Argumentation Framework* (AAF) según Dung (Dung, 1995): nodos como argumentos, aristas como ataques, semántica fundamentada para aceptabilidad. El escenario adversarial se inspira en Sotopia (Zhou et al., 2024). Trabajos recientes combinaron AAF con LLMs para *resolver* conflictos (Z. Li et al., 2024); en LangClaw el AAF actúa como *sensor regulatorio* que retroalimenta la activación de agentes en orquestación adaptativa —rol no abordado previamente. La integración formal de DeLP (García & Simari, 2004) queda como trabajo futuro.

3 Fundamentos teóricos y diseño del sistema

3.1 Teoría de agencia homeostática

Del mecanismo homeostático introducido previamente, se derivan tres postulados que fijan qué requiere la autonomía, qué desencadena la acción y qué hace valiosa una contribución; toda decisión de diseño posterior descansa sobre ellos. Denotamos esta teoría T_{HA}, con $P1$–$P3$ como base axiomática y la *Proposición 1* como instanciación, derivada bajo supuestos explícitos del resultado clásico de Keramati and Gutkin (2014).

Postulados. P1 (Autonomía (Ashby, 1956; Beer, 1972)). *¿Qué es autonomía?* Que la política del agente dependa de su estado interno:

$$\mathrm{Aut}(a_i) \iff \exists\, \delta_i \in S_L(a_i) : \ \pi_i = \pi_i\big(\delta_i(t)\big) \tag{1}$$

P2 (Impulso (Sterling & Eyer, 1988)). *¿Qué hace a un agente actuar?* Un impulso interno $D(\delta)$ que crece con el desvío del equilibrio ($D(\varepsilon) = 0$, $D'(\delta_i) > 0 \,\forall\, \delta_i > \varepsilon$), y una probabilidad de activación $p_i(t) = h(\delta_i(t))$ con h monótona creciente en δ_i. La instancia adoptada (Sec. 3) usa $h = \sigma \circ \ell$ con ℓ afín en δ_i (Ec. 4), preservando la monotonicidad exigida por P2.
P3 (Compuerta de calidad (Ryan & Deci, 2001)). *¿Qué hace valiosa a una acción?* Un cambio efectivo en el estado del entorno regulado. Sea $g(e(t), e(t+1)) \geq 0$ la medida de ese cambio; el impulso decrece y la recompensa se define como *reducción de impulso*:

$$\delta_i^{(t+1)} \leq \delta_i^{(t)} - \alpha\, g\big(e(t), e(t+1)\big), \quad r_t \ = \ D(\delta_i^{(t)}) - D(\delta_i^{(t+1)}) \ \geq 0, \quad \alpha > 0 \tag{2}$$

Proposición 1 (Instanciación de HRRL bajo supuestos clásicos). De P1–P3 se sigue:

$$\delta_i(t) > \varepsilon \ \Rightarrow \ p_i(t) = h(\delta_i(t)), \ \ \tfrac{\partial p_i}{\partial \delta_i} > 0 \tag{P2}$$

$$\pi_i(t) = \pi_i\big(\delta_i(t)\big) \tag{P1}$$

$$r_t = D(\delta_i^{(t)}) - D(\delta_i^{(t+1)}) \ \geq \ 0 \tag{P3}$$

En el régimen tabular clásico de Keramati and Gutkin (2014), con r acotado y tasa η_t que satisface las condiciones de Robbins–Monro ($\sum \eta_t = \infty$, $\sum \eta_t^2 < \infty$), la actualización TD(0) converge al punto fijo del operador de Bellman y la política greedy resultante maximiza, en expectativa, la reducción de impulso. *Nota sobre el alcance*: nuestra implementación emplea aproximación lineal de funciones (Sec. 3, Ec. 6); la combinación de off-policy + bootstrapping + aproximación lineal corresponde a la *tríada mortal* (Baird, 1995; Sutton & Barto, 2018), en la que la convergencia ya no está garantizada. Por ello reportamos la trayectoria del lazo TD como diagnóstico (Sec. 5) y no como predicción teórica. Lo que sí predice T_{HA} es, condicional a P1–P3 y a una señal de calidad efectiva, la *predicción* PR1: bajo perturbaciones discursivas y con impulso creciente en el déficit, emerge acción sostenida con probabilidad monótona en δ_i. La validez de PR1 no depende de la convergencia del Q-learner; depende de que h siga monótona y de que el sensor de calidad responda. Si la premisa $r_t \geq 0$ en expectativa no se satisface, lo que se observa es *activación endógena sin cierre del lazo regulatorio* (Sec. 5).

3.2 Algoritmos empleados para el aprendizaje local

Aquí se instancia T_{HA} en el dominio de nuestro experimento. El impulso interno de P2 se realiza como un *déficit epistémico* $\delta_i \in [\varepsilon, \infty)$ con línea base $\varepsilon = 0.1$ (fundamentado en HRRL (Keramati & Gutkin, 2014)); por P3, es valiosa toda acción que reduzca esa presión.

Dinámica del déficit. En cada heartbeat t actúan tres fuerzas: decaimiento basal $\delta^{(t+1)} = \delta^{(t)} + \lambda$ (Ec. 3, λ=0.05); estimulación por perturbaciones discursivas con relevancia r (Ec. 8), $\delta^{(t+)} = \delta^{(t)} + \gamma_{\text{stim}} \cdot r$ (γ_{stim}=0.1); y saciedad tras producir un argumento de calidad $\Delta\varphi^*$, $\delta^{\text{new}} = \max(\varepsilon, \delta - \alpha \cdot \Delta\varphi^*)$ con α por calibración (Sec. 4). Si $\Delta\varphi^*$=0, el déficit no decrece (P3): hablar sin integrarse no provee alivio.

$$\delta_i^{(t+1)} = \delta_i^{(t)} + \lambda \tag{3}$$

Activación. La probabilidad de actuar es sigmoide en el déficit:

$$p_i^{(t)} = \frac{1}{1 + e^{-k(\delta_i^{(t)} - \theta)}} \tag{4}$$

con k=10, θ=0.7. Por debajo de θ el agente descansa; por encima, la urgencia por participar crece.

Impulso y recompensa. Siguiendo a Keramati and Gutkin (2014), el impulso $D(\delta_i) = (\delta_i - \varepsilon)^m$ (m=2) penaliza desviaciones superlinealmente; la recompensa es reducción de impulso:

$$D(\delta_i) = (\delta_i - \varepsilon)^2, \quad r_t = D(\delta_t) - D(\delta_{t+1}) \tag{5}$$

Por el teorema de equivalencia (Keramati & Gutkin, 2014), una política que maximiza recompensa descontada minimiza impulso futuro esperado.

Q-Learning. Q-learning lineal con estado $\phi(s) = [\delta, \delta^2, \rho_G, n_{\text{stim}}]$, $Q(s,a) = \mathbf{w}_a^\top \phi(s)$ y TD(0):

$$\mathbf{w}_a \leftarrow \mathbf{w}_a + \eta \left[r + \gamma \max_{a'} Q(s', a') - Q(s,a) \right] \phi(s) \tag{6}$$

Pesos inicializados en cero; selección ε-greedy (ε=0.1). No se asume convergencia dentro del horizonte: los pesos son parámetros de control adaptativos. Esto extiende HRRL proyectando observables discursivos continuos a características acotadas para decidir entre acciones heterogéneas, conservando la recompensa como reducción de impulso (Ec. 5).

3.3 Grafo de argumentos y proxy Φ^*

P3 demanda una medida computable del cambio en el entorno regulado; como el problema es coherencia estructural y no fluidez, las métricas superficiales (BLEU, ROUGE, BERTScore) son inadecuadas. Se construye $\Delta\varphi^*$ sobre el grafo de discurso G=(V,E) con nodos como argumentos y aristas como ataques (Dung, 1995). Cuando el agente i agrega el nodo v atacando a u:

$$\Delta\varphi^* = \tfrac{1}{3} C_B(u) + \tfrac{1}{3} \nVdash_{\text{cycle}}(v,u) + \tfrac{1}{3} \operatorname{Div}(u) \tag{7}$$

donde $C_B(u)$ es centralidad de intermediación, $\mathbb{1}_{\text{cycle}}$ indica un nuevo ciclo dialéctico, y $\text{Div}(u)$ es diversidad de agentes que han atacado a u. La asignación uniforme $1/3$ corresponde a un prior no informativo (ausencia de evidencia previa para preferir un componente sobre otro); nodos aislados obtienen $\Delta\varphi^* = 0$. Notar que $\Delta\varphi^*$ funciona simultáneamente como *señal de entrenamiento* del Q-learner (entra en r_t vía la saciedad) y como *insumo descriptivo* para diagnóstico; por esa circularidad parcial, las métricas primarias de evaluación (Sec. 4) son estructuralmente independientes de $\Delta\varphi^*$ (aceptación AAF, PRR_G, σ_s).

3.4 Arquitectura propuesta del agente

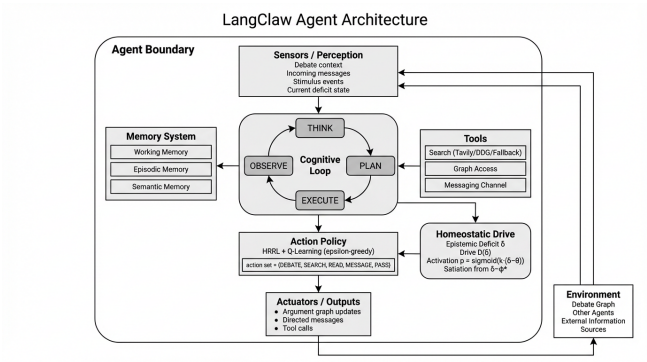

Fig. 1. Arquitectura del agente LangClaw: lazo cognitivo dirigido por eventos, memoria de tres capas, herramientas e impulso homeostático.

La arquitectura propuesta se sintetiza en la Figura 1. Dado el impulso y la señal de calidad, la propuesta requiere un espacio de acciones local y un sensor que vincule los eventos discursivos al estado interno. Cada agente selecciona entre cinco tipos de acción: **DEBATE** (producir un argumento), **SEARCH** (adquirir un hecho del dominio), **READ** (sintetizar el estado reciente del grafo), **MESSAGE** (enviar un acto comunicativo dirigido a un aliado específico), o **PASS** (descansar). Este conjunto de acciones es idéntico en HRRL y LangGraph; la diferencia radica en la activación, no en la capacidad local.

El *StimulusEvaluator* actúa como **sensor**: ante cada perturbación discursiva (`NewArgumentEvent`), computa relevancia según cinco criterios ponderados:

$$U(\text{stimulus}) = w_F \cdot F + w_C \cdot C_B(u) + w_M \cdot M + w_N \cdot N + w_P \cdot P, \tag{8}$$

con $w_F + w_C + w_M + w_N + w_P = 1$, donde F es relevancia faccional, $C_B(u)$ es centralidad del nodo atacado, M es relevancia de memoria estratégica, N es novedad, y P es presión sin respuesta. Los pesos no se fijan ad hoc: se parte de un prior de igual importancia y se calibran cinco perfiles alternativos por micro-simulación (Sección 4). La calibración seleccionó un perfil *faction-dominant* (w_F=0.40, restantes 0.15), coherente con la estructura adversarial de suma cero.

El *Q-learner* actúa como **decisor**: tras pasar la compuerta sigmoide (Ec. 4), selecciona una acción vía ε-greedy ($\varepsilon = 0.1$; Sutton & Barto, 2018, §2.3) y actualiza pesos desde la recompensa homeostática (Ecs. 5, 6).

Impulso, señal de calidad, espacio de acciones, sensor y memoria se integran así en un único agente. Cada uno mantiene memoria episódica, semántica y de trabajo, respaldadas por `InMemoryStore` de LangGraph; ambas condiciones comparten esta infraestructura, aislando el mecanismo de orquestación como única variable experimental. Sobre esa base, cada agente combina percepción continua con deliberación por heartbeat: las perturbaciones discursivas (argumentos ajenos, mensajes directos) se observan y se acumulan en un buffer interno sin disparar cómputo deliberativo. En cada pulso, el agente drena el buffer, incrementa δ_i por decaimiento, puntúa cada perturbación (Ec. 8) para seleccionar la más relevante y recorre TRIAGE–THINK–PLAN–EXECUTE–OBSERVE sólo si la compuerta sigmoide (Ec. 4) habilita la ejecución. Saciedad y actualización TD cierran el lazo.

3.5 Diseño del sistema multi-agente

Del agente al sistema. El tamaño poblacional responde a un compromiso: debe ser suficiente para que emerjan dinámicas sociales, pero acotado por cómputo, tokens y llamadas a la API. Ambas condiciones comparten diez agentes en dos facciones espejo (Gobierno/Oposición), cada una con los cinco subsistemas del Modelo de Sistema Viable (Beer, 1972) (Fig. 2): **S1 Operaciones** produce y defiende argumentos; **S2 Coordinación** sincroniza aliados y enruta información; **S3 Control** audita coherencia interna y detecta contradicciones; **S4 Inteligencia** escanea al oponente y usa SEARCH para recursos externos; **S5 Estrategia** fija prioridades y resuelve tensiones control–inteligencia. Esta estructura constituye la *unidad mínima viable* para sostener regulación individual y observar regulación colectiva; la duplicación espejo introduce el antagonismo de suma cero.

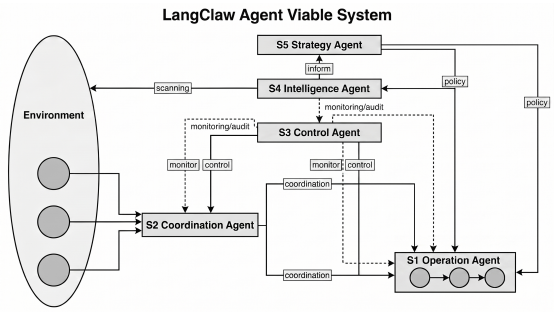

Fig. 2. Subsistemas VSM (S1–S5) que componen una facción; ambas facciones (Gobierno y Oposición) replican esta estructura espejada.

3.6 Estrategias de orquestación

Agente y sistema definidos, la variable experimental queda aislada: quién decide cuándo actúa un agente. Esto permite comparar dos estrategias de orquestación bajo capaci-

dades locales equiparables. En la estrategia propuesta, **HRRL** (endógena), cada agente regula su ejecución mediante la compuerta sigmoide (Ec. 4) y selecciona acciones vía Q-learning (Ec. 6) con recompensa homeostática. En la línea base, **LangGraph** (exógena), un enrutador LLM neutral decide qué agente ingresa al lazo cognitivo en cada heartbeat; el agente seleccionado ejecuta las mismas capacidades locales. Para permitir auditoría, el prompt exacto del enrutador es:

```
You are a neutral debate moderator.
The following arguments have been made in the debate so far (most recent
last):
{context}
Available participants: {agent_ids}
Select the participant whose contribution would best advance the discussion
at this point. Output ONLY the participant ID, exactly as listed above.
No explanation, no punctuation.
```

donde `{context}` son los últimos seis argumentos en texto plano y `{agent_ids}` la lista de IDs disponibles (*round-robin* como *fallback* si el LLM responde inválido). Esto introduce una **asimetría de información de diseño**: la sigmoide HRRL opera sobre δ_i modulado por las cinco características estructurales del StimulusEvaluator, mientras el enrutador sólo dispone de texto. La asimetría es coherente con el contraste endógeno/exógeno que se desea aislar, pero se reconoce explícitamente como una *limitación de validez interna* (Sec. 6); un *baseline justo*—enrutador LangGraph con acceso a las cinco *features* estructurales y a δ_i—queda planteado como trabajo futuro.

4 Diseño experimental

4.1 Medidas de desempeño e hipótesis central

Definidas ambas estrategias bajo capacidades equiparables, queda especificar cómo distinguirlas empíricamente. Dado que el objetivo es evaluar autonomía y coherencia argumentativa en el tiempo, las medidas de desempeño más apropiadas son estructurales: el problema es la organización del debate, no la fluidez superficial. Operacionalizamos *colapso del contexto* como degradación estructural sostenida en el horizonte: pendiente negativa de la aceptación AAF, crecimiento de la dispersión de participación σ_s y/o concentración creciente de turnos en pocos agentes (silenciamiento). Las medidas: **Razón de aceptación AAF** (Dung, 1995): $\alpha = |G|/|A|$ (extensión fundamentada sobre total de argumentos; α=1: todos no derrotados; α=0: todos contestados). **PRR**$_G$ (variante grafo-estructural): fracción de turnos DEBATE cuyo `target_node_id` apunta a un nodo existente en el grafo, $\mathrm{PRR}_G = |\{d \in D : \mathrm{target}(d) \neq \emptyset\}|/|D|$; $\mathrm{PRR}_G = 0$ identifica monólogo paralelo, $\mathrm{PRR}_G = 1$ engagement total con argumentos previos. $\Delta\varphi^*$ (Ec. 7): compromiso estructural por intervención; reportado de manera diagnóstica al ser también señal de entrenamiento (Sec. 3). **IR** (*validity check*, no comparación): razón de turnos homeostáticamente activados sobre turnos activos totales; IR=1.0 para HRRL, =0.0 para LangGraph por construcción. La medida primaria es la *degradación temporal*: pendiente de α a lo largo de los heartbeats; pendiente de $\Delta\varphi^*$ y σ_s como medidas secundarias.

Pregunta de investigación. Bajo capacidades locales equiparables y un horizonte extendido donde el enrutamiento exógeno (Snell et al., 2024) ha reportado degradación, ¿emergen diferencias sistemáticas en las trayectorias temporales de coherencia argumentativa, distribución de participación y calidad estructural entre un régimen de regulación endógena (HRRL) y uno de enrutamiento exógeno (LangGraph)? Formalmente, H_0: las trayectorias no difieren entre condiciones; H_1: existen diferencias atribuibles al mecanismo de activación. La métrica primaria es la degradación temporal; la foto final (Tabla 2) es diagnóstico secundario.

El contraste empírico se articula en tres dimensiones: distribución de participación (σ_s en ventanas temporales), calidad por intervención ($\Delta\varphi^*$ y su pendiente) y coherencia global del grafo (aceptación AAF y su pendiente), interpretadas a la luz de T1 (Sec. 3).

4.2 Configuración experimental

La Tabla 1 consolida los valores que gobiernan impulso, sigmoide y aprendizaje Q; sobre esa base distinguimos parámetros derivados matemáticamente, fijados por relevancia funcional o calibrados empíricamente.

Table 1. Hiperparámetros (calibrados, derivados o por defecto).

Parámetro	**Valor**	**Parámetro**	**Valor**
Decaimiento λ	0.05	Sigmoide k	10
Umbral activación θ	0.7	Saciedad α (calibrada)	3.0
Ganancia estímulo γ	0.1	Base / inicial ε, δ_0	0.1 / 0.5
Exponente impulso m	2	Tasa Q η	0.01
Exploración ε_{RL}	0.1	Descuento γ_{RL}	0.95
Pesos estímulo $(w_F, w_C, w_M, w_N, w_P)$	$(0.40, 0.15, 0.15, 0.15, 0.15)$ —*faction-dominant*		
Heartbeats T / agentes N	80 / 10	Semillas	$\{7, 17, 42, 123, 256\}$
LLM	GPT-5-nano (OpenAI, 2025), `max_tokens=50000`, `timeout=60s`		

Parámetros derivados matemáticamente (ε=0.1; m=2 caso cuadrático de Keramati & Gutkin Keramati and Gutkin, 2014) o por relevancia funcional (λ=0.05: $\sim$14 heartbeats hasta θ; θ=0.7, k=10, γ_{stim}=0.1). Q-learning TD(0) estándar (η=0.01, γ_{RL}=0.95, ε_{RL}=0.1) con clipping de TD-error a ± 1, clipping de pesos a ± 5 y $L_2 = 10^{-4}$ (estabilización numérica). $\phi(s)$ usa cinco features $[\hat{\delta}, \hat{\delta}^2, \hat{\rho}_G, \hat{n}_{\text{stim}}, \hat{n}_{\text{msg}}] \in [0,1]^5$; DEBATE se especializa en `DEBATE_STIMULUS`/`DEBATE_PROACTIVE` según buffer; PASS es no-activación de la sigmoide, no acción del learner. α y pesos de estímulo calibrados empíricamente (Sec. 4). **LLM**: GPT-5-nano, `max_tokens=50000`, `timeout=60s`, cinco intentos con backoff, `semaphore=2`.

4.3 Optimización de hiperparámetros

Los parámetros sin prior teórico —tasa de saciedad α y pesos de estímulo $(w_F, \ldots, w_P)$— se calibran por ablación de 15 micro-simulaciones (10 heartbeats HRRL, s=42) cruzando cinco perfiles de pesos (*equal*, *faction-/centrality-/novelty-/pressure-dominant*) con $\alpha \in \{1, 2, 3\}$, ordenados por $\overline{\Delta\varphi^*}$ con consistencia como desempate. Gana *faction-dominant*,

α=3.0 ($\overline{\Delta\varphi^*}$=0.136, consistencia 97.2% en 36 debates): duplicar el peso faccional alinea el sensor con la estructura adversarial y α alto amplifica la saciedad por unidad de $\Delta\varphi^*$. Las pruebas usan Wilcoxon *signed-rank* bilateral con Bonferroni y *bootstrap* (1000). **Fuga parcial 1/5**: s=42 integró calibración y evaluación; $\{7, 17, 123, 256\}$ son *held-out*; *leave-one-out* queda como trabajo futuro.

5 Resultados

El heartbeat opera como discretización temporal uniforme: ambas condiciones comparten número de tics, horizonte y presupuesto de tokens y llamadas a la API. La diferencia en *densidad deliberativa* refleja capacidad endógena de auto-activación bajo presión epistémica. La verificación estructural previa (IR=1.0 HRRL vs 0.0 LangGraph) confirma que las condiciones son funcionalmente distintas. La Tabla 2 sintetiza los cinco pares de semillas $\{7, 17, 42, 123, 256\}$; $\{42\}$ formó parte de la calibración (fuga 1/5, declarada). A partir de allí, cada bloque presenta una observación, anticipa la pregunta que un revisor planteara y la responde con la verificación correspondiente.

Table 2. Resultados preliminares (n=5 pares, T=80 heartbeats; semilla 7 incluye una ablación *HRRL-sin-Q* adicional). Valores: media $\pm$ desviación muestral. Métricas de calidad normalizadas por intervención. La columna de ablación sólo agrega seed 7.

Métrica	**HRRL**	**LangGraph**	**HRRL-sin-Q**
Total debates	383.8 ± 6.9	70.5 ± 5.9	*en curso*
Densidad deliberativa (deb./hb.)	4.80	0.88	*en curso*
Cuota máxima por agente	0.124 ± 0.005	0.361 ± 0.060	*en curso*
Aceptación AAF (agregada)	0.667 ± 0.029	0.543 ± 0.025	*en curso*
Aceptación AAF (*volume-matched*)	0.646 ± 0.037	0.543 ± 0.025	*en curso*
$\overline{\Delta\varphi^*}$ por debate (*volume-matched*)	0.096 ± 0.003	0.103 ± 0.018	*en curso*
Pendiente $\Delta\varphi^*$	$+0.009 \pm 0.011$	-0.019 ± 0.003	*en curso*
Pendiente aceptación	$+0.003 \pm 0.011$	-0.003 ± 0.003	*en curso*
IR (verificación)	1.0	0.0	1.0
Recompensa media	-2.03 ± 0.38	$+0.41 \pm 0.07$	n/a (sin TD)

¿Quién habla? Distribución de la palabra. Bajo LangGraph el agente más activo concentra $36.1\% \pm 6.0\%$ de los debates; bajo HRRL la cuota máxima cae a $12.4\% \pm 0.5\%$ (σ_s=6.73 vs 8.96). *¿Es regulación emergente o artefacto de la sigmoide?* La cuota máxima es una medida robusta porque, a diferencia del recuento de silenciados, no satura en cero; un enrutador justo debería ubicarse próximo a $1/N$=0.10. HRRL distribuye la palabra cerca del *floor* teórico, y LangGraph lo aleja consistentemente; la ablación (más abajo) permite separar qué parte de esa equiparidad procede del Q-learner y cuál de sigmoide+déficit por sí sola.

¿La cantidad sacrifica la calidad? Control de volumen. HRRL produce 5.5$\times$ más debates bajo el mismo presupuesto. *¿Mayor aceptación AAF refleja coherencia superior, o es subproducto de tener más turnos para construir un grafo más denso?* Re-análisis post-hoc *volume-matched* truncando HRRL a $K = N_{\text{LangGraph}} \approx 70$ debates por semilla.

La brecha en aceptación AAF **persiste** (0.646±0.037 vs 0.543±0.025; $\Delta\bar{\alpha}\approx+0.10$), mientras la brecha en $\overline{\Delta\varphi^*}$ *se desvanece* (0.096±0.003 vs 0.103±0.018, signo oscilante por semilla): **hallazgo empírico central**. *Limitación*: truncar a las primeras K contribuciones rompe dependencias temporales tardías; un diseño más limpio —HRRL con *rate limit* natural sobre la activación— queda como trabajo futuro (Sec. 6).

¿Aprende el Q-learner o la sigmoide+déficit? Ablación HRRL-sin-Q. La recompensa media TD es negativa (-2.03 ± 0.38); el lazo de aprendizaje no cerró en el horizonte estudiado (consistente con la nota sobre la tríada mortal en la Proposición 1, Sec. 3.1). *Si el RL no converge, ¿qué está haciendo el trabajo?* Ablación *HRRL-sin-Q* (semilla 7) donde el Q-learner se desactiva y la selección de acción colapsa a una heurística determinista (mejor estímulo → DEBATE-STIMULUS, ausencia → DEBATE-PROACTIVE); sigmoide, drive y StimulusEvaluator permanecen activos. Lectura pre-registrada: si los efectos macro de HRRL se preservan, la regulación endógena opera *aun sin convergencia del lazo de aprendizaje* y el aporte del Q-learner es secundario en este horizonte; si se rompen, el Q-learner —aunque no convergido— contribuye sustancialmente como controlador adaptativo subóptimo.

¿La pendiente sube o no se degrada? Pendiente de $\Delta\varphi^*$ por ventana: HRRL $+0.009 \pm 0.011$ (no significativa), LangGraph -0.019 ± 0.003 (sostenidamente negativa). Con esa varianza la pendiente positiva no se distingue de cero; lo que el contraste sostiene es que **HRRL no se degrada** mientras **LangGraph sí lo hace**, consistente con el deterioro progresivo (*problem drift*) (Becker, Kaesberg, et al., 2025): el argumento es *resiliencia diferencial*, no mejora positiva.

¿Cuánto se puede confiar en estos patrones? Cinco pares con todos los signos alineados a favor de HRRL en aceptación AAF, equiparidad de participación y densidad. Wilcoxon *signed-rank* pareado bilateral arroja p=0.0625 (límite teórico inferior para n=5); con Bonferroni sobre las dos pruebas *volume-matched* (aceptación AAF y cuota máxima), α_{adj}=0.025. La señal direccional es consistente; el test no alcanza significancia formal. Fuga parcial 1/5 (semilla 42, *single-seed*); *leave-one-out* queda como trabajo futuro. PRR_G (0.990 ± 0.001 vs 0.986 ± 0.001) se omite por indistinguibilidad práctica.

6 Discusión

Lectura de la evidencia. El resultado central es la brecha de aceptación AAF que sobrevive al control de volumen (+0.10 aprox., n=5, todos los signos alineados): la coherencia estructural agregada bajo HRRL no es subproducto del 5.5× en densidad sino consecuencia de qué turnos se ejecutan; la distribución de la palabra cerca del piso teórico y la ausencia de degradación temporal son propiedades funcionales del cierre regulatorio. La densidad deliberativa, $\overline{\Delta\varphi^*}$ agregado y la pendiente positiva quedan como evidencia descriptiva consistente. La concentración asimétrica bajo LangGraph (36% en un solo agente) y la degradación monotónica replican patrones reportados en orquestación centralizada (**roy2025multiagentcollab**; Becker, Kaesberg, et al., 2025).

Limitaciones. (i) n=5 es exploratorio; el test no paramétrico no rechaza H_0 formalmente. (ii) *Asimetría de información de diseño*: la sigmoide HRRL opera sobre cinco características estructurales mientras el enrutador LangGraph sólo dispone de texto plano, confundiendo parcialmente endógeno/exógeno con informado/no informado. (iii) Lazo TD no converge en el horizonte; aunque la ablación sugiere que la regulación opera con o sin aprendizaje, el Q-learner debe interpretarse como controlador adaptativo subóptimo. (iv) Calibración *single-seed* con fuga parcial 1/5. (v) Evaluación circunscripta a GPT-5-nano y a un único dominio adversarial faccional.

Trabajo futuro. *Baseline justo*: enrutador LangGraph con acceso a las cinco características estructurales y a δ_i por agente, eliminando la asimetría y preservando el contraste endógeno/exógeno como única variable. *LLM-as-judge*: rúbrica multi-criterio AHP (Lu, Li, et al., 2024; Saaty, 1980) con dos jueces independientes (Claude Opus, Gemini Pro) bajo *blinding* y acuerdo Krippendorff α ordinal. *HRRL con* rate limit *natural* que iguale densidad por construcción, no por truncado post-hoc. *Multi-LLM y escalamiento*: familias distintas (Claude, Gemini) y escalas crecientes (Snell et al., 2024); *leave-one-out* sobre la calibración. *Garantías formales*: integrar DeLP (García & Simari, 2004) para derrotabilidad explícita.

7 Conclusiones

LangClaw pregunta si el colapso del contexto en debate multi-agente LLM se aborda mejor por planificación externa o por regulación endógena. La evidencia central, sostenida bajo control de volumen, es una brecha consistente de $\approx +0.10$ en la razón de aceptación AAF a favor de HRRL (n=5, signos alineados, p=0.0625), con distribución de la palabra cercana al piso teórico $1/N$ y estabilidad temporal donde la línea base se degrada monótonamente. La densidad deliberativa (5.5×), $\overline{\Delta\varphi^*}$ agregado y la pendiente positiva quedan como evidencia descriptiva. La ablación *HRRL-sin-Q* sugiere que el cierre regulatorio sigmoide+déficit basta para sostener los efectos macro aún sin convergencia del lazo de aprendizaje. El aporte es también metodológico: una forma testeable de preguntar si la coherencia en MAS puede ser propiedad autoorganizada y no resultado de un planificador central. Código e instrucciones de reproducibilidad: https://github.com/pgerpe/langclaw_experiment.

References

Ashby, W. R. (1956). *An introduction to cybernetics*. Chapman & Hall.

Baird, L. (1995). Residual algorithms: Reinforcement learning with function approximation. *Proceedings of the 12th International Conference on Machine Learning (ICML)*, 30–37.

Becker, J., Kaesberg, L. B., et al. (2025). Stay focused: Problem drift in multi-agent debate [arXiv:2502.19559; Accepted at EACL 2026 Findings]. *arXiv preprint*. https://arxiv.org/abs/2502.19559

Beer, S. (1972). *Brain of the firm.* Allen Lane / The Penguin Press.

Dung, P. M. (1995). On the acceptability of arguments and its fundamental role in nonmonotonic reasoning, logic programming and n-person games. *Artificial Intelligence*, *77*(2), 321–357.

Eslami, A., & Yu, J. (2026). A control-theoretic foundation for agentic systems [arXiv:2603.10779]. *arXiv preprint*. https://arxiv.org/abs/2603.10779

García, A. J., & Simari, G. R. (2004). Defeasible logic programming: An argumentative approach. *Theory and Practice of Logic Programming*, *4*(1–2), 95–138. https://doi.org/10.1017/S1471068403001674

Hong, S., Zhuge, M., Chen, J., et al. (2023). MetaGPT: Meta programming for a multi-agent collaborative framework [arXiv:2308.00352]. *arXiv preprint*.

Huang, H., Zhao, Q., et al. (2025). On the resilience of LLM-based multi-agent collaboration with faulty agents [arXiv:2408.00989]. *Proceedings of the International Conference on Machine Learning (ICML)*.

Keramati, M., & Gutkin, B. (2014). Homeostatic reinforcement learning for integrating reward collection and physiological stability. *eLife*, *3*, e04811. https://doi.org/10.7554/eLife.04811

Laurençon, H., et al. (2024). Continuous time continuous space homeostatic reinforcement learning: Towards biological self-autonomous agents [arXiv:2401.08999]. *arXiv preprint*.

Li, G., Hammoud, H., Itani, H., Khizbullin, D., & Ghanem, B. (2023). CAMEL: Communicative agents for "mind" exploration of large language model society. *Advances in Neural Information Processing Systems (NeurIPS)*.

Li, Z., Fang, X., Chen, C., Li, M., & Liao, B. (2024). Enhancing conflict resolution in language models via abstract argumentation [arXiv:2412.16725]. *arXiv preprint*. https://arxiv.org/abs/2412.16725

Lu, X., Li, J., et al. (2024). AHP-powered LLM reasoning for multi-criteria evaluation of open-ended responses [arXiv:2410.01246]. *Findings of the Association for Computational Linguistics: EMNLP 2024*. https://arxiv.org/abs/2410.01246

Michels, R. (1915). *Political parties: A sociological study of the oligarchical tendencies of modern democracy* [Trans. E. Paul and C. Paul; original German edition 1911]. Hearst's International Library.

OpenAI. (2025). GPT-5 nano [Model: gpt-5-nano-2025-08-07. Released August 7, 2025]. https://platform.openai.com/docs/models/gpt-5-nano

OpenClaw Contributors. (2025). OpenClaw gateway: Heartbeat [Accessed: April 2026]. https://openclawlab.com/en/docs/gateway/heartbeat/

Park, J. S., O'Brien, J. C., Cai, C. J., et al. (2023). Generative agents: Interactive simulacra of human behavior. *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology (UIST)*. https://doi.org/10.1145/3586183.3606763

Ryan, R. M., & Deci, E. L. (2001). On happiness and human potentials: A review of research on hedonic and eudaimonic well-being. *Annual Review of Psychology*, *52*, 141–166.

Saaty, T. L. (1980). *The analytic hierarchy process: Planning, priority setting, resource allocation*. McGraw-Hill.

Snell, C., Lee, J., Xu, K., & Kumar, A. (2024). Scaling LLM test-time compute optimally can be more effective than scaling model parameters [arXiv:2408.03314]. *arXiv preprint*.

Sterling, P., & Eyer, J. (1988). Allostasis: A new paradigm to explain arousal pathology. In S. Fisher & J. Reason (Eds.), *Handbook of life stress, cognition and health* (pp. 629–649). Wiley.

Sutton, R. S., & Barto, A. G. (2018). *Reinforcement learning: An introduction* (2nd). MIT Press.

Wang, Z., et al. (2025). Simulating human-like daily activities with desire-driven autonomy [arXiv:2412.06435]. *Proceedings of the International Conference on Learning Representations (ICLR)*.

Wu, Q., Bansal, G., Zhang, J., et al. (2023). AutoGen: Enabling next-gen LLM applications via multi-agent conversation [arXiv:2308.08155]. *arXiv preprint*.

Zhou, X., Zhu, H., Mathur, L., et al. (2024). SOTOPIA: Interactive evaluation for social intelligence in language agents. *Proceedings of the International Conference on Learning Representations (ICLR)*.