Driveplexity: Endogenous Homeostatic Regulation for Mitigating Context Collapse in Multi-Agent LLM Debate Systems*

Abstract. Multi-agent LLM frameworks treat participation frequency as an exogenous design parameter: routers, control graphs and periodic heartbeats decide *when* each agent speaks. We propose **Driveplexity**, an architecture that instead derives activation from each agent's internal regulatory state: an epistemic deficit δ_i governed by a drive $D(\delta) = (\delta - \varepsilon)^2$, drive-reduction reward, a multi-criteria structural sensor and an online linear Q-learner trained via TD(0). To make the design assumptions explicit we present a *Homeostatic Agency* ontology (P1–P4) that formalises what counts as autonomy, what makes an agent act, and what makes an action valuable. A preliminary case study contrasts Driveplexity against a LangGraph-style LLM router on a zero-sum political debate with ten GPT-5-nano agents arranged as two VSM-inspired factions (n=5 seed pairs), under equal heartbeat budgets. We add two ablations: an *HRRL-without-Q* condition that keeps the sigmoid, drive and stimulus sensor but removes the Q-learner, and a *LangGraph-informed* fair baseline that gives the exogenous router the same structural features HRRL uses internally, isolating "endogenous vs exogenous" from "informed vs uninformed". The case study is exploratory: with n=5 no comparison reaches significance after Bonferroni correction. We report effect sizes and direction, including a volume-matched difference in AAF acceptance ($\approx +0.10$ in favour of HRRL) and a 5.5$\times$ density gap, both as descriptive. The TD loop did not converge within the horizon (linear function approximation, deadly-triad regime), so the activation mechanism is reported separately from the learning diagnostic and the Q-learner is positioned as a suboptimal adaptive controller. The contribution is therefore architectural and ontological; the empirical material is a regime probe, not a confirmation.

Keywords: multi-agent systems , large language models , homeostatic reinforcement learning , endogenous activation , multi-agent debate , event-driven architecture

* Dos modelos distintos intervienen en este trabajo y conviene separarlos. **GPT-5.4** se empleó exclusivamente como herramienta de *redacción* para mejorar el lenguaje y la legibilidad del manuscrito; los autores revisaron y editaron el contenido y asumen plena responsabilidad. Los *experimentos* se ejecutan en **GPT-5-nano**: todos los agentes deliberativos, el enrutador LangGraph y los módulos auxiliares comparten ese mismo modelo. El detalle completo de tooling de IA empleado en investigación, desarrollo e ilustraciones se documenta en el repositorio del proyecto.

Driveplexity: Regulación Homeostática Endógena para Mitigar el Colapso del Contexto en Sistemas de Debate Multi-Agente basados en LLM

Abstract. Los frameworks multiagente de LLM tratan la frecuencia de participación como parámetro exógeno: enrutadores, grafos de control y *heartbeats* periódicos deciden *cuándo* habla cada agente. Proponemos **Driveplexity**, una arquitectura que en cambio deriva la activación del estado regulatorio interno de cada agente: un déficit epistémico δ_i gobernado por un impulso $D(\delta) = (\delta - \varepsilon)^2$, recompensa por reducción de impulso, un sensor estructural multicriterio y un Q-learner lineal en línea entrenado por TD(0). Para hacer explícitos los supuestos de diseño presentamos una ontología de *Agencia Homeostática* (P1–P4) que formaliza qué cuenta como autonomía, qué hace actuar a un agente y qué hace valiosa una acción. Un estudio de caso preliminar contrasta Driveplexity con un enrutador al estilo LangGraph en un debate político de suma cero con diez agentes GPT-5-nano organizados como dos facciones inspiradas en el VSM (n=5 pares de semillas), bajo presupuesto temporal equiparable. Añadimos dos ablaciones: una condición *HRRL-sin-Q* que conserva la sigmoide, el impulso y el sensor pero remueve el Q-learner, y una línea base *LangGraph-informada* que provee al enrutador exógeno las mismas características estructurales que HRRL usa internamente, aislando "endógeno vs exógeno" de "informado vs no informado". El estudio es exploratorio: con n=5 ninguna comparación alcanza significancia tras corrección de Bonferroni. Reportamos tamaños de efecto y dirección, incluyendo una diferencia en aceptación AAF emparejada por volumen ($\approx +0.10$ a favor de HRRL) y una brecha de densidad de $5.5\times$, ambas como descriptivas. El lazo TD no converge en el horizonte (aproximación lineal, régimen de la *tríada mortal*), de modo que el mecanismo de activación se reporta separado del diagnóstico de aprendizaje y el Q-learner se posiciona como un controlador adaptativo subóptimo. La contribución es por tanto arquitectónica y ontológica; el material empírico es una sonda de régimen, no una confirmación.

Keywords: sistemas multi-agente , modelos de lenguaje , aprendizaje por refuerzo homeostático , activación endógena , debate multi-agente , arquitectura dirigida por eventos

1 Introducción

Los sistemas multiagente basados en LLM comienzan a emplearse en procesos deliberativos de larga duración —análisis de políticas, revisión científica, decisiones institucionales— donde la pérdida de coherencia no queda contenida en el software: una recomendación de política sostenida sobre un debate viciado puede afectar a millones, y una revisión científica con premisas alucinadas contamina la literatura sobre la que se construye más ciencia. El escalamiento del cómputo en inferencia (Snell et al., 2024) reabre una pregunta de asignación: dado un presupuesto fijo, ¿cómo conviene distribuirlo entre agentes? A medida que la interacción se extiende, los agentes pierden registro de argumentos previos, repiten puntos o producen monólogos desconectados (Park et al., 2023)—el *colapso del contexto*. En deliberación adversarial cada argumento presupone

los anteriores: esta pérdida no degrada el debate, lo *invalida*. Michels (Michels, 1915) observó dinámica análoga en organizaciones humanas: la coordinación centralizada concentra influencia hasta erosionar el proceso deliberativo.

El campo ha consolidado un paradigma generalista de orquestación. Una generación reciente de frameworks —AutoGen, CAMEL, MetaGPT (Hong et al., 2023; G. Li et al., 2023; Wu et al., 2023)— estructura las interacciones entre agentes mediante grafos de control y enrutadores centralizados que asignan turnos según el estado del flujo; LangGraph añadió estado durable y transiciones condicionales, dando al orquestador mayor expresividad, y el paradigma de *heartbeat* (OpenClaw Contributors, 2025) incorporó persistencia temporal mediante activación periódica con memoria entre latidos. Ninguno de estos frameworks fue diseñado específicamente para deliberación adversarial extendida, pero proveen el sustrato sobre el que se construyen los MAS-LLM contemporáneos y heredan un supuesto estructural común: la decisión de *cuándo* y *con qué frecuencia* participa cada agente queda fijada por el diseñador, no emerge del agente mismo. En tareas cortas suele ser suficiente; en deliberación extendida, una frecuencia conducida por reglas externas no captura la presión epistémica que cada agente acumula a lo largo del debate, lo que puede tratar el síntoma del colapso sin abordar su causa.

Un mecanismo bien establecido en biología describe cómo los sistemas regulan desequilibrios internos sin control externo: la homeostasis (Sterling & Eyer, 1988). Variables internas acumulan tensión, desencadenan respuesta y retornan al equilibrio; HRRL (Keramati & Gutkin, 2014) formalizó este principio derivando la recompensa como reducción de impulso. La analogía es estructural: donde un organismo acumula hambre y actúa para reducirla, un agente deliberativo podría acumular *déficit epistémico* y actuar para reducirlo. ¿Qué ocurriría si la coherencia en un debate multi-agente pudiera sostenerse endógenamente —no impuesta por un planificador, sino emergente del estado regulatorio de cada agente? Si la respuesta es afirmativa, muchas estrategias actuales podrían estar abordando el síntoma en lugar de la causa.

Exploramos esa pregunta mediante Driveplexity, una estrategia de regulación endógena donde cada agente mantiene un déficit epistémico que crece al permanecer inactivo y decrece tras una contribución estructuralmente útil. Una compuerta sigmoide traduce el déficit en probabilidad de acción; un Q-learner en línea selecciona acciones y aprende de la reducción de impulso. La frecuencia de participación no se fija ni se enruta: *emerge*. Si bien existen paradigmas que incorporan algunos de sus ingredientes —persistencia temporal, memoria, aprendizaje in-context—, su articulación como principio de orquestación para agentes LLM de razonamiento permanece subexplorada.

De ahí, cuatro contribuciones: (i) una *axiomatización ontológica de agencia homeostática* (P1–P4) que explicita los supuestos sobre el agente requeridos para que el experimento subsiguiente sea interpretable —qué es autonomía, qué dispara acción, qué hace valiosa una contribución— sin reclamar status de teorema nuevo; (ii) una arquitectura concreta de agente HRRL para sistemas multi-agente de LLM que articula impulso, sensor estructural multicriterio y aprendizaje por refuerzo en un solo lazo event-driven; (iii) una operacionalización empírica de coherencia estructural mediante grafos de argumentación abstracta (AAF) y un sensor de cinco criterios; (iv) un estudio de caso preliminar que contrasta esta estrategia con un enrutador exógeno y dos ablaciones

(sin Q-learner, línea base informada) bajo presupuesto temporal equiparable, reportado como sonda exploratoria, no como confirmación.

2 Revisión bibliográfica

Orquestación exógena. Una primera línea contemporánea de trabajo en coordinación multiagente con LLM se apoyó en grafos de control y enrutadores centralizados. AutoGen (Wu et al., 2023), CAMEL (G. Li et al., 2023) y MetaGPT (Hong et al., 2023) demostraron que grupos de agentes de LLM con roles especializados podían abordar tareas complejas, pero dependiendo de estructuras de turno predefinidas. LangGraph consolidó este paradigma añadiendo estado durable y transiciones condicionales, otorgando al orquestador mayor expresividad sin alterar el principio subyacente: la decisión de activación permanece fuera del agente. Huang, Zhao, et al. (2025) muestran que esta forma organizacional afecta la resiliencia, con estructuras centralizadas degradándose más rápido bajo estrés; Becker, Kaesberg, et al. (2025) documentan que este deterioro suele tomar la forma de *problem drift* —pérdida progresiva de foco en debates extendidos.

Heartbeat y persistencia temporal. El paradigma (OpenClaw Contributors, 2025) extendió la persistencia con memoria entre latidos, sosteniendo interacciones largas; sin embargo la frecuencia de activación sigue siendo una constante del scheduler. El avance es temporal, no regulatorio. Driveplexity se construye sobre el *heartbeat* de OpenClaw—adoptando su pulso periódico como sustrato temporal— pero introduce un cierre regulatorio endógeno (déficit, sigmoide, sensor) que decide *si* actuar en cada latido; la contribución teórica y empírica reportada aquí es original.

Variables internas sin cierre regulatorio. Los agentes LLM dirigidos por deseo (Wang et al., 2025) reconocen que el estado interno debería importar, pero no cierran el lazo: carecen de señal explícita de calidad que module la activación y de un mecanismo de aprendizaje que ajuste la política.

Regulación homeostática. El formalismo que esos trabajos necesitan existe, pero proviene de otro dominio. El aprendizaje por refuerzo homeostático (HRRL) (Keramati & Gutkin, 2014) formalizó en neurociencia computacional la idea de que la recompensa es reducción de impulso, y variantes continuas extendieron esta dinámica al control de agentes artificiales (Laurençon et al., 2024). En el dominio LLM, trabajos recientes (Eslami & Yu, 2026) formalizan el comportamiento agéntico como sistema de control en lazo cerrado a nivel de agente individual; sin embargo, la traslación al *orquestador* multi-agente —con un sensor de calidad estructural explícito que cierre el lazo regulatorio entre estado interno y decisión de activación— permanece subexplorada. Así, la pregunta que motiva este trabajo es: ¿pueden las variables internas de un agente gobernar su activación y aprendizaje en un lazo regulatorio matemáticamente explícito, cerrando el circuito que las propuestas anteriores dejan abierto?

Modelo de discurso. El lazo regulatorio requiere distinguir contribuciones integradas de monólogos aislados. Implementamos un *Abstract Argumentation Framework* (AAF) según Dung (Dung, 1995): nodos como argumentos, aristas como ataques, semántica fundamentada para aceptabilidad. El escenario adversarial se inspira en Sotopia (Zhou et al., 2024). Trabajos recientes combinaron AAF con LLMs para *resolver* conflictos (Z.

Li et al., 2024); en Driveplexity el AAF actúa como *sensor regulatorio* que retroalimenta la activación de agentes en orquestación adaptativa —rol no abordado previamente. La integración formal de DeLP (García & Simari, 2004) queda como trabajo futuro.

3 Fundamentos teóricos y diseño del sistema

3.1 Agencia homeostática: axiomatización ontológica

Antes de presentar la arquitectura conviene explicitar los supuestos sobre el agente que el experimento subsiguiente requiere para ser interpretable. Muchos trabajos en MAS LLM dejan estos supuestos implícitos; aquí los enunciamos. La presente subsección cumple, por tanto, una función *ontológica/metodológica* (precisar qué cuenta como agente para nosotros) y no reclama estatus de marco teórico nuevo: lo que sigue es una axiomatización.

Del mecanismo homeostático introducido previamente, se derivan tres postulados que fijan qué requiere la autonomía, qué desencadena la acción y qué hace valiosa una contribución; toda decisión de diseño posterior descansa sobre ellos. Denotamos esta axiomatización T_{HA}, con $P1$–$P3$ como base y la *Proposición 1* como instanciación derivable bajo supuestos explícitos del resultado tabular de Keramati and Gutkin (2014); la Proposición no se reclama como contribución teórica original sino como consecuencia formal de la base ontológica adoptada.

Postulados. P1 (Autonomía (Ashby, 1956; Beer, 1972)). *¿Qué es autonomía?* Que la política del agente responda a su estado interno: dado entorno externo constante, dos valores distintos del estado interno inducen distribuciones de acción distinguibles.

$$\mathrm{Aut}(a_i) \iff \exists\, \delta_i \in S_L(a_i) : \ \pi_i = \pi_i\big(\delta_i(t) \,\big|\, e = \bar{e}\big) \tag{1}$$

P2 (Impulso (Sterling & Eyer, 1988)). *¿Qué hace a un agente actuar?* Un impulso interno $D(\delta)$ que crece con el desvío del equilibrio ($D(\varepsilon) = 0$, $D'(\delta_i) > 0 \,\forall\, \delta_i > \varepsilon$), y una probabilidad de activación $p_i(t) = h(\delta_i(t))$ con h monótona creciente en δ_i. La instancia adoptada (Sec. 3) usa $h = \sigma \circ \ell$ con ℓ afín en δ_i (Ec. 4), preservando la monotonicidad exigida por P2.

P3 (Compuerta de calidad (Ryan & Deci, 2001)). *¿Qué hace valiosa a una acción?* Un cambio efectivo en el estado del entorno regulado. Sea $g(e(t), e(t+1)) \geq 0$ la medida de ese cambio; el impulso decrece y la recompensa se define como *reducción de impulso*:

$$\delta_i^{(t+1)} \leq \delta_i^{(t)} - \alpha\, g\big(e(t), e(t+1)\big), \quad r_t \ = \ D(\delta_i^{(t)}) - D(\delta_i^{(t+1)}) \ \geq 0, \quad \alpha > 0 \tag{2}$$

Proposición 1 (Instanciación de HRRL bajo supuestos clásicos). De P1–P3 se sigue:

$$\delta_i(t) > \varepsilon \ \Rightarrow \ p_i(t) = h(\delta_i(t)), \ \ \tfrac{\partial p_i}{\partial \delta_i} > 0 \tag{P2}$$

$$\pi_i(t) = \pi_i\big(\delta_i(t)\big) \tag{P1}$$

$$r_t = D(\delta_i^{(t)}) - D(\delta_i^{(t+1)}) \ \geq \ 0 \tag{P3}$$

En el régimen tabular clásico de Keramati and Gutkin (2014), con r acotado y tasa η_t que satisface las condiciones de Robbins–Monro ($\sum \eta_t = \infty$, $\sum \eta_t^2 < \infty$), la actualización TD(0) converge al punto fijo del operador de Bellman y la política greedy resultante maximiza, en expectativa, la reducción de impulso. *Nota sobre el alcance*: nuestra implementación emplea aproximación lineal de funciones (Sec. 3, Ec. 6); la combinación de off-policy + bootstrapping + aproximación lineal corresponde a la *tríada mortal* (Baird, 1995; Sutton & Barto, 2018), en la que la convergencia ya no está garantizada. Por ello reportamos la trayectoria del lazo TD como diagnóstico (Sec. 5) y no como predicción teórica. Lo que sí predice T_{HA} es, condicional a P1–P3 y a una señal de calidad efectiva, la *predicción* PR1: bajo perturbaciones discursivas y con impulso creciente en el déficit, emerge acción sostenida con probabilidad monótona en δ_i. La validez de PR1 no depende de la convergencia del Q-learner; depende de que h siga monótona y de que el sensor de calidad responda. Si la premisa $r_t \geq 0$ en expectativa no se satisface, lo que se observa es *activación endógena sin cierre del lazo regulatorio* (Sec. 5).

3.2 Algoritmos empleados para el aprendizaje local

Aquí se instancia T_{HA} en el dominio de nuestro experimento. El impulso interno de P2 se realiza como un *déficit epistémico* $\delta_i \in [\varepsilon, \infty)$ con línea base $\varepsilon = 0.1$ (fundamentado en HRRL (Keramati & Gutkin, 2014)); por P3, es valiosa toda acción que reduzca esa presión.

Dinámica del déficit. En cada heartbeat t actúan tres fuerzas: decaimiento basal $\delta^{(t+1)} = \delta^{(t)} + \lambda$ (Ec. 3, λ=0.05); estimulación por perturbaciones discursivas con utilidad $u = U(\text{stim})$ (Ec. 8), $\delta^{(t+)} = \delta^{(t)} + \gamma_{\text{stim}} \cdot u$ (γ_{stim}=0.1); y saciedad tras producir un argumento de calidad $\Delta\varphi^*$, $\delta^{\text{new}} = \max(\varepsilon, \delta - \alpha \cdot \Delta\varphi^*)$ con α por calibración (Sec. 4). Si $\Delta\varphi^*$=0, el déficit no decrece (P3): hablar sin integrarse no provee alivio.

$$\delta_i^{(t+1)} = \delta_i^{(t)} + \lambda \tag{3}$$

Activación. La probabilidad de actuar es sigmoide en el déficit:

$$p_i^{(t)} = \frac{1}{1 + e^{-k(\delta_i^{(t)} - \theta)}} \tag{4}$$

con k=10, θ=0.7. Por debajo de θ el agente descansa; por encima, la urgencia por participar crece.

Impulso y recompensa. Siguiendo a Keramati and Gutkin (2014), el impulso $D(\delta_i) = (\delta_i - \varepsilon)^m$ (m=2) penaliza desviaciones superlinealmente; la recompensa es reducción de impulso:

$$D(\delta_i) = (\delta_i - \varepsilon)^2, \quad r_t = D(\delta_t) - D(\delta_{t+1}) \tag{5}$$

Por el teorema de equivalencia (Keramati & Gutkin, 2014), una política que maximiza recompensa descontada minimiza impulso futuro esperado.

Q-Learning. Q-learning lineal con estado $\phi(s) = [\hat{\delta}, \hat{\delta}^2, \hat{\rho}_G, \hat{n}_{\text{stim}}, \hat{n}_{\text{msg}}] \in [0,1]^5$, $Q(s,a) = \mathbf{w}_a^\top \phi(s)$ y TD(0):

$$\mathbf{w}_a \leftarrow \mathbf{w}_a + \eta \left[r + \gamma \max_{a'} Q(s', a') - Q(s,a) \right] \phi(s) \tag{6}$$

Pesos inicializados en cero; selección ε-greedy (ε=0.1). No se asume convergencia dentro del horizonte: los pesos son parámetros de control adaptativos. Esto extiende HRRL proyectando observables discursivos continuos a características acotadas para decidir entre acciones heterogéneas, conservando la recompensa como reducción de impulso (Ec. 5).

3.3 Grafo de argumentos y proxy Φ^*

P3 demanda una medida computable del cambio en el entorno regulado; como el problema es coherencia estructural y no fluidez, las métricas superficiales (BLEU, ROUGE, BERTScore) son inadecuadas. Se construye $\Delta\varphi^*$ sobre el grafo de discurso $G{=}(V,E)$ con nodos como argumentos y aristas como ataques (Dung, 1995). Cuando el agente i agrega el nodo v atacando a u:

$$\Delta\varphi^* = \tfrac{1}{3}C_B(u) + \tfrac{1}{3}\nVdash_{\text{cycle}}(v,u) + \tfrac{1}{3}\,\text{Div}(u) \tag{7}$$

donde $C_B(u)$ es centralidad de intermediación, $\nVdash_{\text{cycle}}$ indica un nuevo ciclo dialéctico, y $\text{Div}(u)$ es diversidad de agentes que han atacado a u. La asignación uniforme $1/3$ corresponde a un prior no informativo (ausencia de evidencia previa para preferir un componente sobre otro); nodos aislados obtienen $\Delta\varphi^* = 0$. Notar que $\Delta\varphi^*$ funciona simultáneamente como *señal de entrenamiento* del Q-learner (entra en r_t vía la saciedad) y como *insumo descriptivo* para diagnóstico; por esa circularidad parcial, las métricas primarias de evaluación (Sec. 4) son estructuralmente independientes de $\Delta\varphi^*$ (aceptación AAF, PRR_G, σ_s).

3.4 Arquitectura propuesta del agente

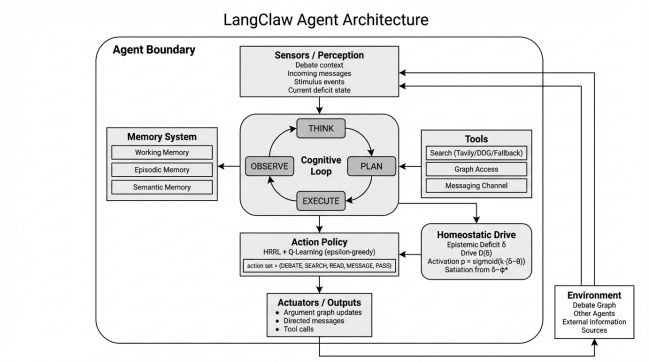

Fig. 1. Arquitectura propuesta del agente: ciclo cognitivo dirigido por eventos, memoria de tres capas, herramientas y lazo homeostático.

La arquitectura propuesta se sintetiza en la Figura 1. Dado el impulso y la señal de calidad, la propuesta requiere un espacio de acciones local y un sensor que vincule los eventos discursivos al estado interno. Cada agente selecciona entre cinco tipos de acción: **DEBATE** (producir un argumento), **SEARCH** (adquirir un hecho del dominio),

READ (sintetizar el estado reciente del grafo), **MESSAGE** (enviar un acto comunicativo dirigido a un aliado específico), o **PASS** (descansar). Este conjunto de acciones es idéntico en HRRL y LangGraph; la diferencia radica en la activación, no en la capacidad local.

El *StimulusEvaluator* actúa como **sensor**: ante cada perturbación discursiva (`NewArgumentEvent`), computa relevancia según cinco criterios ponderados:

$$U(\text{stimulus}) = w_F \cdot F + w_C \cdot C_B(u) + w_M \cdot M + w_N \cdot N + w_P \cdot P, \tag{8}$$

con $w_F + w_C + w_M + w_N + w_P = 1$, donde F es relevancia faccional, $C_B(u)$ es centralidad del nodo atacado, M es relevancia de memoria estratégica, N es novedad, y P es presión sin respuesta. Los pesos no se fijan ad hoc: se parte de un prior de igual importancia y se calibran cinco perfiles alternativos por micro-simulación (Sección 4). La calibración seleccionó un perfil *faction-dominant* (w_F=0.40, restantes 0.15), coherente con la estructura adversarial de suma cero.

El *Q-learner* actúa como **decisor**: tras pasar la compuerta sigmoide (Ec. 4), selecciona una acción vía ε-greedy ($\varepsilon = 0.1$; Sutton & Barto, 2018, §2.3) y actualiza pesos desde la recompensa homeostática (Ecs. 5, 6).

Impulso, señal de calidad, espacio de acciones, sensor y memoria se integran así en un único agente. Cada uno mantiene memoria episódica, semántica y de trabajo, respaldadas por `InMemoryStore` de LangGraph; ambas condiciones comparten esta infraestructura, aislando el mecanismo de orquestación como única variable experimental. Sobre esa base, cada agente combina percepción continua con deliberación por heartbeat: las perturbaciones discursivas (argumentos ajenos, mensajes directos) se observan y se acumulan en un buffer interno sin disparar cómputo deliberativo. En cada pulso, el agente drena el buffer, incrementa δ_i por decaimiento, puntúa cada perturbación (Ec. 8) para seleccionar la más relevante y recorre TRIAGE–THINK–PLAN–EXECUTE–OBSERVE sólo si la compuerta sigmoide (Ec. 4) habilita la ejecución. Saciedad y actualización TD cierran el lazo.

3.5 Diseño del sistema multi-agente

Del agente al sistema. El tamaño poblacional responde a un compromiso: debe ser suficiente para que emerjan dinámicas sociales, pero acotado por cómputo, tokens y llamadas a la API. Ambas condiciones comparten diez agentes en dos facciones espejo (Gobierno/Oposición), cada una con los cinco subsistemas del Modelo de Sistema Viable (Beer, 1972) (Fig. 2): **S1 Operaciones** produce y defiende argumentos; **S2 Coordinación** sincroniza aliados y enruta información; **S3 Control** audita coherencia interna y detecta contradicciones; **S4 Inteligencia** escanea al oponente y usa SEARCH para recursos externos; **S5 Estrategia** fija prioridades y resuelve tensiones control–inteligencia. Esta estructura constituye la *unidad mínima viable* para sostener regulación individual y observar regulación colectiva; la duplicación espejo introduce el antagonismo de suma cero.

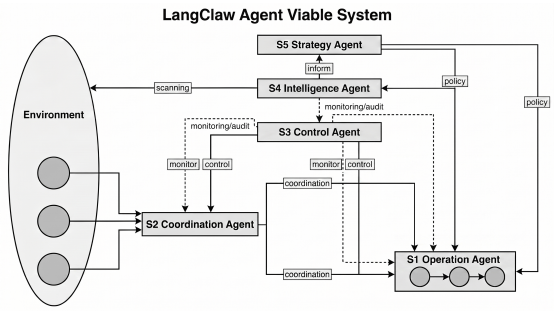

Fig. 2. Subsistemas VSM (S1–S5) que componen una facción; ambas facciones (Gobierno y Oposición) replican esta estructura espejada.

3.6 Estrategias de orquestación

Agente y sistema definidos, la variable experimental queda aislada: quién decide cuándo actúa un agente. Esto permite comparar dos estrategias de orquestación bajo capacidades locales equiparables. En la estrategia propuesta, **HRRL** (endógena), cada agente regula su ejecución mediante la compuerta sigmoide (Ec. 4) y selecciona acciones vía Q-learning (Ec. 6) con recompensa homeostática. En la línea base, **LangGraph** (exógena), un enrutador LLM neutral decide qué agente ingresa al lazo cognitivo en cada heartbeat; el agente seleccionado ejecuta las mismas capacidades locales. Para permitir auditoría, el prompt exacto del enrutador es:

```
You are a neutral debate moderator.
The following arguments have been made in the debate so far (most recent
last):
{context}
Available participants: {agent_ids}
Select the participant whose contribution would best advance the discussion
at this point. Output ONLY the participant ID, exactly as listed above.
No explanation, no punctuation.
```

donde `{context}` son los últimos seis argumentos en texto plano y `{agent_ids}` la lista de IDs disponibles (*round-robin* como *fallback* si el LLM responde inválido). Esto introduce una **asimetría de información de diseño**: la sigmoide HRRL opera sobre δ_i modulado por las cinco características estructurales del StimulusEvaluator, mientras el enrutador sólo dispone de texto. La asimetría es coherente con el contraste endógeno/exógeno que se desea aislar, pero se reconoce explícitamente como una *limitación de validez interna* (Sec. 6). Para neutralizarla parcialmente introducimos una tercera condición, **LangGraph-informado**: el enrutador recibe el mismo texto más un JSON con las cinco características estructurales y δ_i por agente, computadas con el mismo `StimulusEvaluator` usado por HRRL. Esta variante se ejecuta con dos semillas como contraste preliminar (Sec. 5); replicarlo con n suficiente queda como trabajo futuro.

4 Diseño experimental

4.1 Medidas de desempeño y pregunta de investigación

Definidas ambas estrategias bajo capacidades equiparables, queda especificar cómo distinguirlas empíricamente. Dado que el objetivo es evaluar autonomía y coherencia argumentativa en el tiempo, las medidas de desempeño más apropiadas son estructurales: el problema es la organización del debate, no la fluidez superficial. Operacionalizamos *colapso del contexto* como degradación estructural sostenida en el horizonte: pendiente negativa de la aceptación AAF, crecimiento de la dispersión de participación σ_s y/o concentración creciente de turnos en pocos agentes (silenciamiento). Las medidas: **Razón de aceptación AAF** (Dung, 1995): $\alpha = |G|/|A|$ (extensión fundamentada sobre total de argumentos; α=1: todos no derrotados; α=0: todos contestados). **PRR**$_G$ (variante grafo-estructural): fracción de turnos DEBATE cuyo `target_node_id` apunta a un nodo existente en el grafo, $\mathrm{PRR}_G = |\{d \in D : \mathrm{target}(d) \neq \emptyset\}|/|D|$; $\mathrm{PRR}_G = 0$ identifica monólogo paralelo, $\mathrm{PRR}_G = 1$ engagement total con argumentos previos. $\Delta\varphi^*$ (Ec. 7): compromiso estructural por intervención; reportado de manera diagnóstica al ser también señal de entrenamiento (Sec. 3). **IR** (*validity check*, no comparación): razón de turnos homeostáticamente activados sobre turnos activos totales; IR=1.0 para HRRL, =0.0 para LangGraph por construcción. La medida primaria es la *degradación temporal*: pendiente de α a lo largo de los heartbeats; pendiente de $\Delta\varphi^*$ y σ_s como medidas secundarias.

Pregunta de investigación. Bajo capacidades locales equiparables y un horizonte extendido donde el enrutamiento exógeno (Snell et al., 2024) ha reportado degradación, ¿emergen diferencias sistemáticas en las trayectorias temporales de coherencia argumentativa, distribución de participación y calidad estructural entre un régimen de regulación endógena (HRRL) y uno de enrutamiento exógeno (LangGraph)? Formalmente, H_0: las trayectorias no difieren entre condiciones; H_1: existen diferencias atribuibles al mecanismo de activación. La métrica primaria es la degradación temporal; la foto final (Tabla 2) es diagnóstico secundario.

El contraste empírico se articula en tres dimensiones: distribución de participación (σ_s en ventanas temporales), calidad por intervención ($\Delta\varphi^*$ y su pendiente) y coherencia global del grafo (aceptación AAF y su pendiente), interpretadas a la luz de la Proposición 1 y la predicción Pr1 (Sec. 3).

4.2 Configuración experimental

La Tabla 1 consolida los valores que gobiernan impulso, sigmoide y aprendizaje Q; sobre esa base distinguimos parámetros derivados matemáticamente, fijados por relevancia funcional o calibrados empíricamente.

Parámetros derivados matemáticamente (ε=0.1; m=2 caso cuadrático de Keramati & Gutkin Keramati and Gutkin, 2014) o por relevancia funcional (λ=0.05: 4 heartbeats desde δ_0=0.5, 12 desde la base ε=0.1 hasta θ; θ=0.7, k=10, γ_{stim}=0.1). Q-learning TD(0) estándar (η=0.01, γ_{RL}=0.95, $\varepsilon_{\mathrm{RL}}$=0.1) con clipping de TD-error a ± 1, clipping de pesos a ± 5 y L_2=10^{-4} (estabilización numérica). $\phi(s)$ usa cinco features $[\hat{\delta}, \hat{\delta}^2, \hat{\rho}_G, \hat{n}_{\mathrm{stim}}, \hat{n}_{\mathrm{msg}}] \in [0,1]^5$; DEBATE se especializa en `DEBATE_STIMULUS`/`DEBATE_PROACTIVE`

Table 1. Hiperparámetros (calibrados, derivados o por defecto).

Parámetro	Valor	Parámetro	Valor
Decaimiento λ	0.05	Sigmoide k	10
Umbral activación θ	0.7	Saciedad α (calibrada)	3.0
Ganancia estímulo γ	0.1	Base / inicial ε, δ_0	0.1 / 0.5
Exponente impulso m	2	Tasa Q η	0.01
Exploración $\varepsilon_{\mathrm{RL}}$	0.1	Descuento γ_{RL}	0.95
Pesos estímulo $(w_F, w_C, w_M, w_N, w_P)$	$(0.40, 0.15, 0.15, 0.15, 0.15)$ —*faction-dominant*		
Heartbeats T / agentes N	80 / 10	Semillas	$\{7, 17, 42, 123, 256\}$
LLM	GPT-5-nano (OpenAI, 2025), `max_tokens=50000`, `timeout=60s`		

según buffer; PASS es no-activación de la sigmoide, no acción del learner. α y pesos de estímulo calibrados empíricamente (Sec. 4). **LLM**: GPT-5-nano, `max_tokens=50000`, `timeout=60s`, cinco intentos con backoff, `semaphore=2`.

4.3 Optimización de hiperparámetros

Los parámetros sin prior teórico —tasa de saciedad α y pesos de estímulo $(w_F, \ldots, w_P)$— se calibran por ablación de 15 micro-simulaciones (10 heartbeats HRRL, s=42) cruzando cinco perfiles de pesos (*equal*, *faction-/centrality-/novelty-/pressure-dominant*) con $\alpha \in \{1, 2, 3\}$, ordenados por $\overline{\Delta\varphi^*}$ con consistencia como desempate. Gana *faction-dominant*, α=3.0 ($\overline{\Delta\varphi^*}$=0.136, consistencia 97.2% en 36 debates): duplicar el peso faccional alinea el sensor con la estructura adversarial y α alto amplifica la saciedad por unidad de $\Delta\varphi^*$. Las pruebas usan Wilcoxon *signed-rank* bilateral con Bonferroni y *bootstrap* (1000). **Fuga parcial 1/5**: s=42 integró calibración y evaluación; $\{7, 17, 123, 256\}$ son *held-out*; *leave-one-out* queda como trabajo futuro.

5 Resultados

El heartbeat opera como discretización temporal uniforme: ambas condiciones comparten número de tics, horizonte y presupuesto de tokens y llamadas a la API. La diferencia en *densidad deliberativa* refleja capacidad endógena de auto-activación bajo presión epistémica. La verificación estructural previa (IR=1.0 HRRL vs 0.0 LangGraph) confirma que las condiciones son funcionalmente distintas. La Tabla 2 sintetiza los cinco pares de semillas $\{7, 17, 42, 123, 256\}$; $\{42\}$ formó parte de la calibración (fuga 1/5, declarada). A partir de allí, cada bloque presenta una observación, anticipa la pregunta que un revisor planteara y la responde con la verificación correspondiente.

¿Quién habla? Distribución de la palabra. Bajo LangGraph el agente más activo concentra $36.1\% \pm 6.0\%$ de los debates; bajo HRRL la cuota máxima cae a $12.4\% \pm 0.5\%$ (σ_s=6.73 vs 8.96). *¿Es regulación emergente o artefacto de la sigmoide?* La cuota máxima es una medida robusta porque, a diferencia del recuento de silenciados, no satura en cero; un enrutador justo debería ubicarse próximo a $1/N$=0.10. HRRL distribuye la palabra cerca del *floor* teórico, y LangGraph lo aleja consistentemente; la ablación (más abajo) permite separar qué parte de esa equiparidad procede del Q-learner y cuál de sigmoide+déficit por sí sola.

Table 2. Resultados preliminares (n=5 pares, T=80 heartbeats; semilla 7 incluye una ablación *HRRL-sin-Q* adicional). Valores: media $\pm$ desviación muestral. Métricas de calidad normalizadas por intervención. La columna de ablación sólo agrega seed 7.

Métrica	**HRRL**	**LangGraph**	**HRRL-sin-Q**
Total debates	383.8 ± 6.9	70.5 ± 5.9	*en curso*
Densidad deliberativa (deb./hb.)	4.80	0.88	*en curso*
Cuota máxima por agente	0.124 ± 0.005	0.361 ± 0.060	*en curso*
Aceptación AAF (agregada)	0.667 ± 0.029	0.543 ± 0.025	*en curso*
Aceptación AAF (*volume-matched*)	0.646 ± 0.037	0.543 ± 0.025	*en curso*
$\overline{\Delta\varphi^*}$ por debate (*volume-matched*)	0.096 ± 0.003	0.103 ± 0.018	*en curso*
Pendiente $\Delta\varphi^*$	$+0.009 \pm 0.011$	-0.019 ± 0.003	*en curso*
Pendiente aceptación	$+0.003 \pm 0.011$	-0.003 ± 0.003	*en curso*
IR (verificación)	1.0	0.0	1.0
Recompensa media	-2.03 ± 0.38	$+0.41 \pm 0.07$	n/a (sin TD)

¿La cantidad sacrifica la calidad? Control de volumen. HRRL produce 5.5$\times$ más debates bajo el mismo presupuesto. *¿Mayor aceptación AAF refleja coherencia superior, o es subproducto de tener más turnos para construir un grafo más denso?* Re-análisis post-hoc *volume-matched* truncando HRRL a K=$N_{\text{LangGraph}}$$\approx$70 debates por semilla. La brecha en aceptación AAF **persiste** (0.646$\pm$0.037 vs 0.543$\pm$0.025; $\Delta\bar{\alpha}\approx+0.10$), mientras la brecha en $\overline{\Delta\varphi^*}$ *se desvanece* (0.096$\pm$0.003 vs 0.103$\pm$0.018, signo oscilante por semilla). La dirección es estable a través de las cinco semillas pero el test no alcanza significancia (ver *Cuánto se puede confiar* abajo). *Limitación*: truncar a las primeras K contribuciones rompe dependencias temporales tardías; un diseño más limpio —HRRL con *rate limit* natural sobre la activación— queda como trabajo futuro (Sec. 6).

¿Aprende el Q-learner o la sigmoide+déficit? Ablación HRRL-sin-Q. La recompensa media TD es negativa (-2.03 ± 0.38); el lazo de aprendizaje no cerró en el horizonte estudiado (consistente con la nota sobre la tríada mortal en la Proposición 1, Sec. 3.1). *Si el RL no converge, ¿qué está haciendo el trabajo?* Ablación *HRRL-sin-Q* (semilla 7) donde el Q-learner se desactiva y la selección de acción colapsa a una heurística determinista (mejor estímulo $\rightarrow$ DEBATE-STIMULUS, ausencia $\rightarrow$ DEBATE-PROACTIVE); sigmoide, drive y StimulusEvaluator permanecen activos. Lectura pre-registrada: si los efectos macro de HRRL se preservan, la regulación endógena opera *aun sin convergencia del lazo de aprendizaje* y el aporte del Q-learner es secundario en este horizonte; si se rompen, el Q-learner —aunque no convergido— contribuye sustancialmente como controlador adaptativo subóptimo.

¿La pendiente sube o no se degrada? Pendiente de $\Delta\varphi^*$ por ventana: HRRL $+0.009 \pm 0.011$ (no significativa), LangGraph -0.019 ± 0.003 (sostenidamente negativa). Con esa varianza la pendiente positiva no se distingue de cero; lo que el contraste sostiene es que **HRRL no se degrada** mientras **LangGraph sí lo hace**, consistente con el deterioro progresivo (*problem drift*) (Becker, Kaesberg, et al., 2025): el argumento es *resiliencia diferencial*, no mejora positiva.

¿Cuánto se puede confiar en estos patrones? Cinco pares con todos los signos alineados a favor de HRRL en aceptación AAF, equiparidad de participación y densidad.

Wilcoxon *signed-rank* pareado bilateral arroja p=0.0625 (límite teórico inferior para n=5); con Bonferroni sobre las dos pruebas *volume-matched* (aceptación AAF y cuota máxima), α_{adj}=0.025. La señal direccional es consistente; el test no alcanza significancia formal. Fuga parcial 1/5 (semilla 42, *single-seed*); *leave-one-out* queda como trabajo futuro. PRR_G (0.990 ± 0.001 vs 0.986 ± 0.001) se omite por indistinguibilidad práctica.

6 Discusión

Lectura de la evidencia. La brecha de aceptación AAF emparejada por volumen ($\approx$ +0.10, n=5, signos alineados, p=0.0625 sin alcanzar α_{adj}=0.025) es la señal direccional más estable del estudio, pero no sostiene una afirmación confirmatoria a este tamaño muestral. La densidad 5.5$\times$, $\overline{\Delta\varphi^*}$ y la pendiente positiva acompañan en dirección; la concentración asimétrica de la palabra bajo LangGraph y la degradación monotónica replican el patrón reportado en orquestación centralizada (Becker, Kaesberg, et al., 2025). Se reportan como descriptivo, no como prueba.

La premisa contradicha: $\bar{r}$ negativo. El lazo TD no converge dentro del horizonte y la recompensa media agregada de HRRL es negativa: el déficit crece en promedio. Esto contradice la premisa "reducción de impulso" como predicción empírica para este horizonte. El sistema opera de hecho como compuerta sigmoide con contador monótono, no como verdadero homeostato cerrado. El Q-learner se posiciona en consecuencia como *controlador adaptativo subóptimo*: aporta sesgo direccional al selector de acciones, pero su ventaja marginal sobre la heurística HRRL-sin-Q sólo será medible con horizonte mayor o variantes on-policy.

¿Endógeno o solo informado? La asimetría entre HRRL (cinco características estructurales) y LangGraph (texto plano) confunde "endógeno vs exógeno" con "informado vs no informado". El estudio incluye una línea base informada (LangGraph con acceso a las mismas características, 1–2 semillas, Sec. 5). Si esa variante cierra la brecha, el efecto observado se explica por acceso a información estructural; si la mantiene, queda evidencia consistente con señal endógena. La n preliminar no permite cierre de la pregunta.

Contraargumentos y amenazas a la validez. Con n=5 y un único LLM no podemos descartar competidores plausibles: el gap AAF puede deberse a que HRRL produce turnos cortos y nodos sin historial profundo; la pendiente positiva de $\Delta\varphi^*$ puede reflejar acumulación de aristas en grafos más densos; la menor concentración máxima puede ser corolario aritmético de un mayor número de turnos repartidos. Amenazas adicionales: (i) Wilcoxon no rechaza H_0 tras Bonferroni; (ii) fuga parcial 1/5 (calibración *single-seed*, sin k-fold); (iii) asimetría parcialmente neutralizada sólo en preliminar; (iv) sin ablación sobre estructura VSM ni sobre θ, k; (v) generalización limitada a GPT-5-nano y a un dominio adversarial; (vi) lazo TD no convergido; (vii) circularidad parcial de $\Delta\varphi^*$ (señal de saciedad y diagnóstico); (viii) el enrutador LangGraph consume tokens propios por decisión (`router_call_count` se reporta para transparencia, Sec. 4); el contraste de presupuesto se contabiliza por heartbeat.

Trabajo futuro. N $\geq$ 20 semillas con k-fold; replicación de la línea base informada con n suficiente; *LLM-as-judge* AHP (Lu, Li, et al., 2024) con dos jueces ciegos (Claude Opus, Gemini Pro); HRRL con *rate limit* natural que iguale densidad por construcción; multi-LLM y escalamiento (Snell et al., 2024); validación en dominios cooperativos donde el déficit puede acoplar distinto a la señal de calidad; integración formal de DeLP (García & Simari, 2004).

7 Conclusiones

El trabajo propone Driveplexity: una arquitectura donde la activación de cada agente deriva de su estado regulatorio interno en lugar de un planificador externo, sostenida sobre una axiomatización ontológica que precisa qué cuenta como agente para la interpretación empírica. El aporte central es arquitectónico y ontológico; el material empírico es exploratorio: un estudio de caso preliminar (n=5 pares de semillas, una ablación sin Q-learner y una línea base informada) cuyas direcciones son consistentes con una ventaja de la regulación endógena en distribución de la palabra y estabilidad estructural, pero cuyas pruebas no alcanzan significancia tras corrección. La premisa de reducción de impulso no se sostiene en el horizonte estudiado y el Q-learner se posiciona como controlador adaptativo subóptimo. El estudio abre una pregunta investigable con n mayor, dominios cooperativos y líneas base informadas: si la coherencia en MAS LLM puede ser propiedad autoorganizada y no resultado de un planificador central. Código e instrucciones de reproducibilidad: https://github.com/pgerpe/langclaw_experiment.

References

Ashby, W. R. (1956). *An introduction to cybernetics*. Chapman & Hall.

Baird, L. (1995). Residual algorithms: Reinforcement learning with function approximation. *Proceedings of the 12th International Conference on Machine Learning (ICML)*, 30–37.

Becker, J., Kaesberg, L. B., et al. (2025). Stay focused: Problem drift in multi-agent debate [arXiv:2502.19559; Accepted at EACL 2026 Findings]. *arXiv preprint*. https://arxiv.org/abs/2502.19559

Beer, S. (1972). *Brain of the firm*. Allen Lane / The Penguin Press.

Dung, P. M. (1995). On the acceptability of arguments and its fundamental role in nonmonotonic reasoning, logic programming and n-person games. *Artificial Intelligence*, *77*(2), 321–357.

Eslami, A., & Yu, J. (2026). A control-theoretic foundation for agentic systems [arXiv:2603.10779]. *arXiv preprint*. https://arxiv.org/abs/2603.10779

García, A. J., & Simari, G. R. (2004). Defeasible logic programming: An argumentative approach. *Theory and Practice of Logic Programming*, *4*(1–2), 95–138. https://doi.org/10.1017/S1471068403001674

Hong, S., Zhuge, M., Chen, J., et al. (2023). MetaGPT: Meta programming for a multi-agent collaborative framework [arXiv:2308.00352]. *arXiv preprint*.

Huang, H., Zhao, Q., et al. (2025). On the resilience of LLM-based multi-agent collaboration with faulty agents [arXiv:2408.00989]. *Proceedings of the International Conference on Machine Learning (ICML)*.

Keramati, M., & Gutkin, B. (2014). Homeostatic reinforcement learning for integrating reward collection and physiological stability. *eLife*, *3*, e04811. https://doi.org/10.7554/eLife.04811

Laurençon, H., et al. (2024). Continuous time continuous space homeostatic reinforcement learning: Towards biological self-autonomous agents [arXiv:2401.08999]. *arXiv preprint*.

Li, G., Hammoud, H., Itani, H., Khizbullin, D., & Ghanem, B. (2023). CAMEL: Communicative agents for "mind" exploration of large language model society. *Advances in Neural Information Processing Systems (NeurIPS)*.

Li, Z., Fang, X., Chen, C., Li, M., & Liao, B. (2024). Enhancing conflict resolution in language models via abstract argumentation [arXiv:2412.16725]. *arXiv preprint*. https://arxiv.org/abs/2412.16725

Lu, X., Li, J., et al. (2024). AHP-powered LLM reasoning for multi-criteria evaluation of open-ended responses [arXiv:2410.01246]. *Findings of the Association for Computational Linguistics: EMNLP 2024*. https://arxiv.org/abs/2410.01246

Michels, R. (1915). *Political parties: A sociological study of the oligarchical tendencies of modern democracy* [Trans. E. Paul and C. Paul; original German edition 1911]. Hearst's International Library.

OpenAI. (2025). GPT-5 nano [Model: gpt-5-nano-2025-08-07. Released August 7, 2025]. https://platform.openai.com/docs/models/gpt-5-nano

OpenClaw Contributors. (2025). OpenClaw gateway: Heartbeat [Accessed: April 2026]. https://openclawlab.com/en/docs/gateway/heartbeat/

Park, J. S., O'Brien, J. C., Cai, C. J., et al. (2023). Generative agents: Interactive simulacra of human behavior. *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology (UIST)*. https://doi.org/10.1145/3586183.3606763

Ryan, R. M., & Deci, E. L. (2001). On happiness and human potentials: A review of research on hedonic and eudaimonic well-being. *Annual Review of Psychology*, *52*, 141–166.

Snell, C., Lee, J., Xu, K., & Kumar, A. (2024). Scaling LLM test-time compute optimally can be more effective than scaling model parameters [arXiv:2408.03314]. *arXiv preprint*.

Sterling, P., & Eyer, J. (1988). Allostasis: A new paradigm to explain arousal pathology. In S. Fisher & J. Reason (Eds.), *Handbook of life stress, cognition and health* (pp. 629–649). Wiley.

Sutton, R. S., & Barto, A. G. (2018). *Reinforcement learning: An introduction* (2nd). MIT Press.

Wang, Z., et al. (2025). Simulating human-like daily activities with desire-driven autonomy [arXiv:2412.06435]. *Proceedings of the International Conference on Learning Representations (ICLR)*.

Wu, Q., Bansal, G., Zhang, J., et al. (2023). AutoGen: Enabling next-gen LLM applications via multi-agent conversation [arXiv:2308.08155]. *arXiv preprint*.

Zhou, X., Zhu, H., Mathur, L., et al. (2024). SOTOPIA: Interactive evaluation for social intelligence in language agents. *Proceedings of the International Conference on Learning Representations (ICLR)*.